

"GPU 서버 없이 영상 이해 AI가 될까" 소비자용 실리콘에서 실측했다

소매 · 현장 운영 · 온프레미

약 12주 (측정 2 + 실증 4 + 이관 6)

정부 바우처 적합

문제의 대가 · 영상 이해 서버

데이터센터 GPU 필수

— 문제의 대가

매장 카메라나 순찰 현장에서 '방금 화면에 뭐가 지나갔는지'를 이해하려면 최신 영상-언어모델(VLM)이 필요합니다. 문제는 이 모델을 서빙하는 표준 경로가 데이터센터급 GPU라는 점입니다. 영상을 클라우드로 내보내지 않고, 데이터센터 GPU도 없이 현장에 두는 저가 온프레미 유닛에서 이 정도 모델이 실제로 돌아가는지는 아무도 재보지 않은 질문입니다.

— 통찰

최신 VLM을 '쓰는' 것과 저가 하드웨어에 '배포'하는 것은 다른 일입니다. 양자화로 모델을 줄이면 저절로 빨라진다는 가정은 이번 실측에서 정면으로 깨졌습니다. 메모리를 줄이는 축과 속도를 얻는 축은 서로 다른 문제이고, 그 사실을 모른 채 도입하면 '더 작아졌는데 왜 더 느리지'라는 함정에 걸립니다.

— 2i의 방식

공개 Apache-2.0 라이선스 VLM인 microsoft/Mage-VL(4.7B, 시각 인코더 Mage-ViT + Qwen3-4B 언어 백본)을 소비자용 Apple M4 Pro(통합 메모리 48GB)에 직접 올려 bf16·INT8·INT4 세 정밀도를 전부 실측했습니다. 메모리는 양자화로 줄었지만 같은 조건에서 디코드 속도는 오히려 느려졌고, 원인을 커널 단으로 추적해 언어 백본을 mlx-lm의 융합 커널 INT4 경로로 다시 재봤습니다. 결과는 동일 4비트에서 디코드 89.7 tok/s·2.46GB로, 나이브 양자화(0.47 tok/s·4.15GB) 대비 약 190배 더 빠르고 메모리도 더 작은 조합이었습니다. 모델을 고르는 게 아니라 이렇게 재고 검증하는 패키징 엔지니어링이 저희 일입니다.

— 게이지 방식으로 진행합니다 · 측정 → 실증 → 이관

측정 게이트

대상 온프레미 하드웨어에서 bf16 기준선의 메모리 점유·디코드 처리량·응답 지연을 계측해 baseline을 고정합니다.

실증 게이트

INT8·INT4 등 양자화 조합을 실제로 돌려 메모리 절감분과 속도 변화를 함께 재고, 답변 품질이 유지되는지 대조합니다. 속도 이득이 안 나면 커널·런타임 조합을 바꿔 재검증합니다.

이관 게이트

검증된 양자화와 런타임 조합을 온프레미 유닛으로 패키징하고, 스트리밍과 이미지 스코프를 명확히 나눈 운영 매뉴얼과 함께 넘깁니다.

사용 기술

microsoft/Mage-VL (Mage-ViT + Qwen3-4B) ·
transformers + torch + Metal(MPS) · optimum-quanto
weight-only 양자화(bf16/INT8/INT4) · mlx-lm 융합 저비
트 커널 런타임 · Apple Silicon 온프레임 배치. 실측 스코프:
89.7 tok/s는 디코드를 지배하는 언어 백본(Qwen3-4B) 단독
프록시이며, 비전 타워를 포함한 mage_vl 전체의 MLX 포팅은
다음 상용화 작업입니다. 스트리밍 코덱(DCVC)은 CUDA 전용
이라 로컬 미지원입니다.

표준 산출물

- AX 진단 보고서
- 현장 KPI baseline 계측
- 과제 우선순위 로드맵
- 작동하는 PoC
- before/after 측정 리포트
- 본도입 판단 근거
- 운영 시스템
- 사내 이관 교육
- 운영 매뉴얼·문서

— 목표 델타

목표 지표 · 실제 수치는 귀사 데이터로 재측정

지표	현재	목표
디바이스 메모리 (나이트 INT4)	bf16 9.49GB	→ 4.15GB (56% 감소, 실측)
디코드 처리량 (나이트 INT4)	bf16 13.01 tok/s	→ 0.47 tok/s (96% 저하, 실측)
디코드 처리량 (MLX 융합 INT4)	나이트 INT4 0.47 tok/s	→ 89.67 tok/s (약 190배, 언어 백본 기준 실측)
영상 이해 서버	데이터센터 GPU 필수	→ 소비자용 Mac 1대 (이미지·프레임 기준)

▶ 작동하는 증거: 2icorp.github.io/demos/15-edge-vlm-quant/ · 브라우저에서 그 자리에서 계산하는 데모

— 그래서 무엇이 열리는나

양자화만으로는 부족합니다. 양자화와 올바른 융합커널 런타임을 함께 골라야 저가 온프레임 하드웨어에서 작고 '또' 빠르게 돈다는 것
을 실측으로 단았습니다. 언어 백본만으로 디코드 89.7 tok/s(약 190배)를 확인했고, 비전 타워까지 포함한 전체 모델의 MLX 포팅
이 다음 상용화 단계입니다. 2i가 파는 것은 모델이 아니라, 이렇게 진단하고 런타임을 고르고 이관까지 마치는 측정된 패키징입니다.

정부 바우처 활용

정부 AX 바우처의 진단·PoC 트랙에 부합합니다. 기존 학습 데
이터 없이 공개 모델과 귀사 하드웨어만으로 실증이 가능하고,
메모리·처리량이 수치로 남아 중간 점검 근거가 명확합니다. 지
원 규모·요건은 연도별 공고에 따르며, 복잡한 신청·행정은 2i가
함께 처리합니다.

왜 2I인가

대형 SI가 안 건드리는 중소·중견의 소규모·비정형 과제를, 진단
부터 이관까지 한 사람이 책임지고 봅니다. 화려한 제안서 대신
측정된 진단과 검증된 PoC로 신뢰를 먼저 만듭니다.

— 자주 묻는 질문

“Q. 데이터가 정리돼 있지 않아도 되나요?”

네. 측정 게이트가 바로 흩어진 데이터와 현장을 정리해 무엇부터 할지 정하는 단계입니다. 준비가 안 됐다는 것 자체가 출발점입니다.

“Q. 기간과 비용은 어느 정도인가요?”

이 사례 기준 약 12주 (측정 2 + 실증 4 + 이관 6) 정도이며, 범위와 데이터 상태에 따라 조정됩니다. 상당 부분을 정부 AX 바우처로 충당해 실 부담을 크게 낮출 수 있습니다.

“Q. 하다가 안 되면 어떻게 되나요?”

그래서 실증 게이트가 있습니다. 큰돈을 걸기 전에 될지 안 될지를 작은 실증으로 먼저 확인하고, 목표 델타에 못 미치면 확장하지 않습니다.

“Q. 사람 일자리를 없애는 건가요?”

아닙니다. 사람을 대체하는 게 아니라, 반복 업무를 걷어내 사람이 판단과 관계에 집중하도록 속도와 정확도를 보완하는 방식입니다.

먼저 **무료 자가진단** 또는 30분 상담으로 시작하세요. 귀사에 맞는 시작점을 함께 찾습니다. · **2i** AX 컨설팅

본 브로셔는 2i의 역량을 보여주는 시나리오형 예시입니다. 특정 실존 고객의 완료 실적 이 아니며, 목표 수치는 업계 통상 기대치입니다. 실제 진행 시 귀사 데이터로 다시 측정합니다.