

대규모 오디오 콘텐츠 지문식별

잡음·압축·속도변화에 강건한 음원 식별

2i

2026-07-29

초록

방송·매장·스트리밍 환경에서 흘러나오는 짧은 오디오 조각을 듣고 카탈로그의 어느 곡인지 맞히는 문제, 즉 오디오 콘텐츠 식별(content-ID)은 방송 저작권 모니터링과 음원 정산의 핵심 기술이다. 본 논문은 피크쌍 컨스텔레이션 해싱(peak-pair constellation hashing, Wang 2003 - 상용 음원인식 서비스가 쓰는 알고리즘 계열)을 두 개의 공개 데이터셋에서 재현하고 실측한다. 먼저 GTZAN(999개 트랙)에서 알고리즘 자체가 작동하는지 검증했다. 클린 조건에서 top-1 정확도 95.0%(10초 클립), 강한 가산 잡음(SNR -5dB)에서도 72.5%를 유지했고, 32~128kbps MP3 압축 전 구간에서 96.7%로 거의 흔들리지 않았으며, $\pm 10\%$ 속도 변화(피치 보존)에서도 95.0~96.7%를 유지했다. 이어서 '카탈로그가 커져도 버티는가'라는 상업화 관문 질문에 답하기 위해 FMA-small(라이선스가 명시된 8,000개 클립)로 카탈로그를 500곡에서 7,996곡까지 16배 늘리는 누적 스케일 실험을 실행했다. 클린 top-1 정확도는 99.5%에서 99.0%로 거의 무너지지 않았고, SNR 5dB 조건에서는 99.5%를 유지한 반면, 시간 정합이 없는 나이브 스펙트로그램 유사도 베이스라인은 같은 조건에서 17%까지 붕괴했다. 7,996 곡 카탈로그에서 질의 1건의 중단간 지연은 p50 30.97ms, 상주 메모리(RSS)는 7.5GB였다. 가장 중요한 정직한 한계는 이것이다. 현재 인덱스는 샤딩되지 않은 단일 인메모리 딕셔너리이며, 트랙당 메모리 사용량을 그대로 외삽하면 100만 곡 카탈로그에서 약 868GB RSS가 필요하다. 즉 알고리즘은 스케일에서 죽지 않지만, 지금의 인덱스 구조는 파일럿 데모용이며 실제 상용화에는 샤딩된 외부 인덱스 계층이 별도로 필요하다. 이 논문에 실린 모든 수치는 실측값이며, 100만 곡 외삽만 예외적으로 선형 추정임을 명시한다.

목차

1	요약	3
2	배경과 문제	3
3	방법	3
4	데이터와 실험 설정	4
5	결과	4
5.1	GTZAN: 알고리즘이 오디오에서 작동하는가	4
5.2	카탈로그 스케일링: FMA-small, 500곡에서 7,996곡까지	6
5.3	스케일이 실제로 무너지는 지점	7
6	한계와 캐비엣	7
7	데이터와 재현	8
8	참고문헌	8

1 요약

방송·매장·스트리밍 환경에서 흘러나오는 짧은 오디오 조각을 듣고 카탈로그의 어느 곡인지 맞히는 문제, 즉 오디오 콘텐츠 식별(content-ID)은 방송 저작권 모니터링과 음원 정산의 핵심 기술이다. 본 논문은 피크쌍 컨스텔레이션 해싱(peak-pair constellation hashing, Wang 2003 - 상용 음원인식 서비스가 쓰는 알고리즘 계열)을 두 개의 공개 데이터셋에서 재현하고 실측한다. 먼저 GTZAN(999개 트랙)에서 알고리즘 자체가 작동하는지 검증했다. 클린 조건에서 top-1 정확도 95.0%(10초 클립), 강한 가산 잡음(SNR -5dB)에서도 72.5%를 유지했고, 32~128kbps MP3 압축 전 구간에서 96.7%로 거의 흔들리지 않았으며, $\pm 10\%$ 속도 변화(피치 보존)에서도 95.0~96.7%를 유지했다. 이어서 “카탈로그가 커져도 버티는가”라는 상업화 관문 질문에 답하기 위해 FMA-small(라이선스가 명시된 8,000개 클립)로 카탈로그를 500곡에서 7,996곡까지 16배 늘리는 누적 스케일 실험을 실행했다. 클린 top-1 정확도는 99.5%에서 99.0%로 거의 무너지지 않았고, SNR 5dB 조건에서는 99.5%를 유지한 반면, 시간 정합이 없는 나이브 스펙트로그램 유사도 베이스라인은 같은 조건에서 17%까지 붕괴했다. 7,996곡 카탈로그에서 질의 1건의 종단간 지연은 p50 30.97ms, 상주 메모리(RSS)는 7.5GB였다. 가장 중요한 정직한 한계는 이것이다. 현재 인덱스는 사딩되지 않은 단일 인메모리 딕셔너리이며, 트랙당 메모리 사용량을 그대로 외삽하면 100만 곡 카탈로그에서 약 868GB RSS가 필요하다. 즉 알고리즘은 스케일에서 죽지 않지만, 지금의 인덱스 구조는 파일럿 데모용이며 실제 상용화에는 사딩된 외부 인덱스 계층이 별도로 필요하다. 이 논문에 실린 모든 수치는 실측값이며, 100만 곡 외삽만 예외적으로 선형 추정임을 명시한다.

2 배경과 문제

방송사, 유통 플랫폼, 매장 음악 서비스 사업자는 공통적으로 하나의 질문에 답해야 한다. 지금 이 스피커에서, 혹은 이 방송 채널에서 흘러나오는 소리가 우리 카탈로그의 어느 곡인지 몇 초 안에 알아낼 수 있는가. 이 능력이 없으면 저작권 사용료 정산, 방송 광고 검증, 매장 음악 라이선스 준수 감사가 전부 불가능하다. 상업적으로는 ACRCLOUD, Audible Magic류의 서비스가 이 문제를 팔고 있고, 소비자 쪽에서는 Shazam이 같은 계열의 알고리즘으로 널리 알려져 있다.

문제를 형식화하면 다음과 같다. N개 트랙으로 구성된 카탈로그가 사전에 등록(enroll)되어 있다. 질의(query)는 그 카탈로그 안의 한 트랙에서 임의의 시작 위치로 잘라낸 짧은(3~10초) 오디오 조각이며, 실제 환경을 흉내 낸 잡음·압축·재생속도 왜곡을 겪은 상태로 도착한다. 시스템은 이 질의가 어느 트랙에서 왔는지(top-1 식별), 혹은 카탈로그에 없는 트랙이면 정확히 거부해야 한다.

이 문제가 어려운 근본적인 이유는 “질의가 트랙 전체가 아니라 트랙의 일부이고, 그 일부가 트랙 내 어디서 시작하는지 모른다”는 점이다. 트랙 전체를 하나의 특징 벡터(예: 시간축 평균 스펙트로그램)로 표현하고 코사인 유사도로 최근접 이웃을 찾는 나이브한 접근은 이 조건에서 구조적으로 불리하다. 30초 트랙의 평균 스펙트럼과 그 안의 5초 스니펫의 평균 스펙트럼은 애초에 통계적으로 다른 양이고, 트랙 사이의 미세한 음색 차이가 시간 정합 없이는 잡음에 묻힌다. 반면 Shazam류의 피크쌍 해싱은 “질의의 해시들이 카탈로그의 특정 트랙에서 특정 오프셋으로 일관되게 정렬되는가”를 직접 투표로 검증하기 때문에, 짧은 질의 대 긴 카탈로그라는 이 과제의 비대칭성을 정면으로 다룬다. 본 논문은 이 알고리즘을 두 단계로 검증한다. 1단계는 알고리즘이 오디오에서 작동하는지에 대한 순수 검증(GTZAN), 2단계는 카탈로그가 커질 때 정확도·지연·메모리가 어떻게 변하는지에 대한 스케일링 검증(FMA-small)이다.

3 방법

알고리즘은 세 단계로 구성된다. 등록(enroll) 단계에서 각 트랙의 스펙트로그램에서 지문이 될 특징점을 추출해 해시 테이블에 적재하고, 질의(query) 단계에서 같은 방식으로 추출한 해시를 테이블에서 조회한 뒤, 매칭된 결과에 시간 정합 투표를 적용해 최종 트랙을 결정한다.

스펙트로그램과 피크 추출. 오디오를 STFT(짧은시간 푸리에 변환)로 시간-주파수 표현으로 바꾼다. 윈도우 길이(nperseg) 2048샘플, 홉 크기(noverlap=1024, 즉 오버랩 50%)로 22.05kHz 샘플레이트 기준 약 46.4ms 간격의 프레임을 얻고, Hann 창을 적용한다. 각 프레임에서 국소 최댓값(15×15 시간-주파수 근방에서 최대이고, 잡음 바닥(전체 평균 + 1.5×표준편차) 보다 큰 지점)을 “피크”로 뽑는다. 트랙당 피크 수는 크기 기준 상위 1,500개로 캡을 둔다.

피크쌍 해싱. 각 앵커 피크(f_1, t_1)에 대해 시간상 뒤따르는 최대 8개(팬아웃, FANOUT)의 타깃 피크(f_2, t_2)를 40 타임빈(약 1.86초, MAX_DT) 이내에서 골라 쌍을 만들고, 해시 키를 $h = (f_1, f_2, \Delta t)$ (여기서 $\Delta t = t_2 - t_1$)로 정의한다. 해시 테이블의 값(posting)은 (트랙 ID, t_1)이다. 카탈로그 전체를 이렇게 인덱싱하면 하나의 해시 키가 여러 트랙, 여러 시점에서 등장할 수 있으므로 posting 리스트가 붙는다.

매칭과 시간 정합 투표. 질의 클립에서도 동일하게 해시를 추출한 뒤 인덱스에서 조회한다. 매칭된 각 posting마다 오프셋

= $t1_enroll - t1_query$ 를 계산해 트랙별로 오프셋 히스토그램을 쌓는다. 진짜로 그 트랙에서 온 질의라면, 질의 내 모든 해시가 (질의가 트랙 내 어디서 시작했는지에 대응하는) 거의 같은 오프셋 값 근처로 몰리므로 히스토그램에 뚜렷한 봉우리가 생긴다. 반대로 무관한 트랙에 우연히 몇 개의 해시가 매칭돼도 오프셋은 무작위로 흩어진다. 따라서 오프셋 히스토그램에서 가장 큰 단일 빈(bin)의 크기가 가장 큰 트랙을 top-1로 결정한다. 이 절차 자체가 “미지의 시작 위치에서 잘라낸 질의를 식별한다”는 요구를 만족시키는 핵심 메커니즘이다. 매칭이 하나도 없으면 no-match로 처리한다.

대조군(나이트 베이스라인). 비교를 위해 시간 정합이 전혀 없는 베이스라인을 함께 측정했다. 트랙 전체 구간의 시간축 평균 magnitude 스펙트로그램 벡터를 L2 정규화하고, 질의 클립에 대해서도 같은 벡터를 만들어 코사인 유사도 기준 1-최근접이웃(1-NN)으로 트랙을 고른다. 이 베이스라인은 애초에 “30초 트랙 벡터에 3~10초 스니펫을 맞춰야 하는” 이 과제에서 약할 것으로 예상되는 대조군으로 설계했다 - 시간 정합이 없다는 결정적 약점을 정확히 짚기 위한 것이다.

4 데이터와 실험 설정

GTZAN(1단계, 알고리즘 검증). GTZAN은 22.05kHz 모노 16비트, 각 약 30초 분량의 WAV 트랙 1,000개(10개 장르)로 구성된 음악정보검색(MIR) 분야의 사실상 표준 벤치마크다. 원 데이터셋 배포자가 명시한 정식 라이선스는 확인되지 않아, 본 실험에서는 재배포 없이 로컬 알고리즘 검증에만 사용했다. 알려진 손상 파일 1개(jazz.00054)는 스킵해 999개 트랙을 실사용했다.

FMA-small(2단계, 스케일 검증). Free Music Archive(FMA) 기반 FMA-small 데이터셋은 약 30초 분량의 MP3 클립 8,000개로, 트랙별로 Creative Commons 라이선스가 명시되어 있어 GTZAN보다 상업적 인 용에 안전하다. 알고리즘 파라미터는 GTZAN 실험과 완전히 동일하게 고정했고, 새로 만든 부분은 FMA MP3 디코딩과 카탈로그를 단계적으로 누적시키는 스케일 실험 하네스뿐이다 - 알고리즘 자체는 손대지 않았다.

왜곡 프로토콜(전부 실측, 시뮬레이션 아님). 잡음은 화이트 노이즈를 지정한 SNR로 정밀하게 가산했다(수치적으로 정확한 가산 연산이며, 실제 마이크 녹음 잡음을 흉내 낸 통계적 근사가 아니다). MP3 압축은 실제 ffmpeg 서브프로세스로 인코딩한 뒤 다시 디코딩하는 왕복 처리를 거쳤다(128/64/32kbps). 속도 변화는 실제 ffmpeg atempo 필터로 처리했으며, 이 필터는 피치를 보존한 채 시간축만 신축시키는 타임스트레치다(GTZAN에서는 0.90~1.10x, FMA 스케일 실험에서는 0.96~1.04x).

GTZAN 실험 설계. 클립 길이(3/5/10초) 스윙과 SNR 스윙은 각 조건마다 200개 질의(시드 고정, 무작위 샘플)로, MP3·속도 스윙은 ffmpeg 서브프로세스 비용 때문에 60개 질의로 평가했다. 인덱스는 카탈로그 999곡 전체를 한 번 빌드해 재사용했다(빌드 시간 18.1초).

FMA 스케일 실험 설계(누적/중첩 설계). 카탈로그를 [500, 1000, 2000, 4000, 7996]으로 단계적으로 늘리면서, 모든 단계에서 동일한 200개 질의 트랙(최초 500곡 슬라이스에서 한 번 선정, 이후 모든 더 큰 카탈로그에도 항상 포함됨)을 재사용했다. 이렇게 질의 집합을 고정하는 설계의 목적은 “카탈로그가 커지며 방해곡(distractor)이 늘어난 것 자체가 정확도를 얼마나 깎아먹는가”만을 순수하게 분리해 측정하는 것이다. 각 카탈로그 크기 단계에서 클린 조건과 SNR 5dB 조건을 모두 평가했고, 메모리 가드(상주 메모리가 특정 상한을 넘을 것으로 예상되면 그 단계를 정직하게 스킵)를 두었으나 요청한 모든 단계를 문제없이 완료했다. 가장 큰 단계(7,996곡)에서 MP3 디코딩에 실패한 트랙 4개는 스킵으로 정직하게 집계했다.

5 결과

5.1 GTZAN: 알고리즘이 오디오에서 작동하는가

10초 클린 클립에서 해시 방식의 top-1 정확도는 95.0%였다(무작위 기준선은 999곡 카탈로그에서 0.10%). 클립 길이가 짧아질수록(3초, 5초) 두 방식 모두 정확도가 낮아지지만, 해시 방식은 94.0%로 거의 버틴 반면 나이트 베이스라인은 77.0%까지 떨어졌다 - 짧은 클립일수록 시간 정합이 없는 방식의 약점이 더 크게 드러난다는 뜻이다.

클립 길이	n	해시 top-1	나이트 top-1
3초	200	94.0%	77.0%
5초	200	94.0%	86.5%
10초	200	95.0%	95.0%

잡음 강건성이 이 실험의 핵심 대비를 보여준다. SNR을 클린에서 -5dB까지 낮추는 동안 해시 방식은 93.0%에서 72.5%로 완만하게 하락했지만, 나이트 베이스라인은 87.5%에서 0.0%로 완전히 무너졌다. 즉 나이트 베이스라인은 원래도 시간 정합이 없어 클린 조건에서조차 약했고(87.5%), 잡음이 조금만 섞여도 급격히 붕괴한다.

SNR	n	해시 top-1	나이브 top-1
클린	200	93.0%	87.5%
20dB	200	93.5%	85.0%
10dB	200	94.0%	66.0%
5dB	200	94.0%	18.0%
0dB	200	91.5%	2.0%
-5dB	200	72.5%	0.0%




그림 1: GTZAN SNR 스왑 - 해시 vs 나이브 top-1

MP3 압축 강건성은 예상을 벗어난 결과였다. 128kbps에서 32kbps까지 전 구간에서 해시 top-1이 96.7%로 거의 변화가 없었다(나이브도 83.3~85.0%로 상대적으로 완만하게만 하락했다). 비트레이트가 낮을수록 고주파 컨스텔레이션 피크가 인코더의 저역통과 필터링으로 사라져 정확도가 떨어질 것으로 예상했으나, 이 실험 범위(32~128kbps)에서는 해시 방식이 거의 흔들리지 않았다. 잡음과 압축을 동시에 건 복합 스트레스 조건(SNR 10dB + MP3 64kbps)에서도 해시 top-1은 96.7%를 유지했다(나이브는 78.3%).

비트레이트	n	해시 top-1	나이브 top-1
128kbps	60	96.7%	85.0%
64kbps	60	96.7%	85.0%
32kbps	60	96.7%	83.3%
복합(SNR 10dB+64kbps)	60	96.7%	78.3%

속도(템포) 변화에도 놀랍도록 강건했다. $\pm 10\%$ 범위(0.90x~1.10x)에서 해시 top-1은 1.0x 기준(96.7%) 대비 최대 1.7%p 안에서만 흔들렸다. 피치가 보존된 상태에서 팬아웃으로 고른 앵커-타깃 쌍의 시간차(Δt)가 대체로 작아, $\pm 10\%$ 시간축 스케일이 정수 타임빈으로 라운딩될 때 원래 값과 같아지는 경우가 많았을 것으로 추정한다. 다만 이 실험은 $\pm 10\%$ 까지만 측정했고, 더 큰 템포 변화에서도 이 강건성이 유지되는지는 확인하지 않았다.

속도	n	해시 top-1	나이브 top-1
0.90x	60	95.0%	86.7%
0.95x	60	96.7%	86.7%
1.00x	60	96.7%	86.7%
1.05x	60	96.7%	86.7%
1.10x	60	96.7%	86.7%

인덱스와 지연도 함께 측정했다. 999곡 카탈로그에서 distinct 해시 키 수는 2,321,084개, posting 수는 5,170,998개였다. 10초 클립 기준 해시 조회의 종단간(추출+조회) 평균 지연은 9.878ms, 나이브 베이스라인은 5.342ms였다.

5.2 카탈로그 스케일링: FMA-small, 500곡에서 7,996곡까지

GTZAN 실험이 “알고리즘이 작동하는가”를 답했다면, 방송 모니터링을 사겠다는 바이어가 실제로 던지는 다음 질문은 “카탈로그가 커져도 정확도·지연·메모리가 버티는가”다. FMA-small 클립을 500곡에서 7,996곡까지 16배 누적시키며 같은 200개 질의를 재평가한 결과는 다음과 같다.

카탈로그 크기	해시 top-1(클린)	해시 top-1(SNR5dB)	나이브 top-1(클린)	해시 지연 p50/p95(ms)	해시 키푼팅 수	RSS(MB)
500	99.5%	100.0%	93.0%	5.78 / 9.41	1,260,548 / 2,148,514	811
1,000	99.5%	100.0%	92.5%	6.96 / 14.05	2,029,914 / 4,387,425	2,364
2,000	99.0%	100.0%	90.0%	10.08 / 17.24	3,003,522 / 8,693,744	3,417
4,000	99.0%	100.0%	87.5%	16.96 / 29.82	4,258,509 / 17,291,207	4,850
7,996	99.0%	99.5%	86.5%	30.97 / 63.44	5,606,046 / 33,068,129	7,477




그림 2: 카탈로그 크기별 top-1 정확도

가장 눈에 띄는 대비는 SNR 5dB 조건이다. 카탈로그가 커질수록 나이브 베이스라인은 500곡에서도 이미 취약했던 잡음 조건이 더 악화되어(구체적으로는 500곡 37.5%에서 7,996곡 17.0%까지 하락) 거의 무작위 수준으로 붕괴한 반면, 해시 방식은 같은 조건에서 99.5~100.0%를 유지했다. 이 결과는 GTZAN에서 확인한 “시간 정합 투표가 잡음 강건성의 진짜 엔진”이라는 결론이 카탈로그 규모와 독립적으로 성립함을 보여준다.

속도 변화 강건성도 큰 카탈로그(7,996곡)에서 재확인했다. 0.96x~1.04x 구간에서 해시 top-1은 98.5~99.5%로 유지됐다(나이브는 87.0~87.5%로 상대적으로 안정적이지만 절대 수준이 훨씬 낮다).

속도	n	해시 top-1	나이브 top-1
0.96x	200	98.5%	87.0%
0.98x	200	99.5%	87.5%
1.00x	200	99.5%	87.0%
1.02x	200	99.5%	87.5%
1.04x	200	99.0%	87.0%




그림 3: 카탈로그 크기별 해시 조회 지연 p50

5.3 스케일이 실제로 무너지는 지점

정확도는 카탈로그가 16배 커지는 동안(500→7,996곡) 클린 기준 99.5%에서 99.0%로 거의 무너지지 않았다. 지연은 해시 조회 p50이 5.78ms에서 30.97ms로 5.36배 증가했다 - 카탈로그 크기 증가율(16배)보다는 낮은 성장률이다. 해시 조회는 이론적으로 “실제 매칭되는 posting 수”에 좌우되므로, 카탈로그 크기에 정확히 선형이 아니라 선형 이하로 완만하게 늘어난 것은 이 인덱스 구조가 최소한 어느 정도의 확장성을 갖는다는 신호로 읽을 수 있다. 반면 메모리는 RSS가 811MB에서 7,477MB로 9.21배 늘어, 트랙당 약 0.889MB의 한계 메모리 비용을 보였다. 이 실험은 현재 구현이 샤딩되지 않은 단일 인메모리 딕셔너리 인덱스라는 점을 정확히 짚기 위한 것이었고, 바로 이 지점이 실제로 스케일이 무너지는 축임을 정량적으로 확인했다.

6 한계와 캐비엣

가장 중요한 한계부터 말한다. 트랙당 약 0.889MB의 메모리 사용량을 그대로 선형 외삽하면 100만 곡 카탈로그는 약 868GB RSS가 필요하다는 계산이 나온다. 이는 실측이 아니라 명시적인 선형 추정이며, 실제 상용 방송 카탈로그(수백만~수천만 곡)를 감당하려면 지금의 단일 인메모리 딕셔너리 구조로는 부족하고, 샤딩되거나 디스크/외부 저장소 기반의 인덱스 계층(예: 분산 키-값 저장소나 전용 근사 최근접 이웃 인덱스)이 별도로 설계되어야 한다. 알고리즘 자체가 스케일에서 정확도를 잃지는 않는다는 것과, 지금의 인덱스 구현이 그 규모를 감당할 수 있다는 것은 서로 다른 주장이며, 본 논문은 전자만 검증했다.

두 번째로, 이 실험이 검증한 카탈로그 규모(최대 7,996곡)는 실제 상용 방송 카탈로그보다 여전히 2~4자리 수 작다. 스케일 실험의 결론은 “이 정도 범위에서는 정확도가 무너지지 않는다”는 관측이며, 더 큰 자릿수에서도 같은 경향이 유지된다고 확정할 수는 없다.

세 번째로, 이 실험이 다룬 왜곡은 가산 화이트 잡음, MP3 압축, 재생속도 변화 세 가지뿐이다. 실제 방송 환경 특유의 왜곡 - 라디오 방송 체인의 다단 컴프레션, DJ 멘트가 음악에 겹치는 상황, 페이드인/아웃, 라이브 공연 버전과 스튜디오 버전의 차이, 다중 음원이 동시에 재생되는 카페·매장 환경에서의 분리 문제 - 는 이 실험이 다루지 않은 잔여 변수다.

네 번째로, MP3 압축 강건성이 32~128kbps 전 구간에서 거의 흔들리지 않은 결과는 GTZAN과 FMA 클립이 대체로 저역/중역에 에너지가 몰려 있어 낮은 비트레이트에서도 핵심 컨스텔레이션 피크가 살아남았을 가능성이 있다는 것으로, 더 낮은 비트레이트나 고주파 콘텐츠 위주의 트랙(예: 신스/일렉트로닉)에서는 결과가 달라질 수 있으며 본 실험은 이를 검증하지 않았다. 마찬가지로 속도 강건성도 $\pm 10\%$ 까지만 측정했고, 더 큰 템포 변화에서의 거동은 확인되지 않았다.

다섯 번째, 데이터 라이선스에 관한 정직한 표기다. GTZAN은 MIR 연구의 사실상 표준 벤치마크지만 원저작자가 명시한 정식 라이선스가 확인되지 않아, 본 논문에서는 재배포 없이 로컬 알고리즘 검증에만 사용했다. FMA-small은 트랙별로 Creative Commons 라이선스가 명시되어 있어 공개 인용에 더 안전한 선택이며, 이 때문에 스케일 실험의 데이터셋으로 의도적으로 선택했다.

마지막으로, 가장 큰 스케일 단계(7,996곡)에서 MP3 디코드에 실패한 트랙 4개를 스킵했다. 이 실패를 조용히 묻지 않고 정직하게 집계에서 제외한 것을 명시한다.

기술과 무관한 병목도 있다. 알고리즘이 얼마나 강건하든, 실제 상용 서비스가 되려면 라이선스된 레퍼런스 카탈로그 확보가 필요하며 이는 기술이 아니라 사업적 병목이다.

7 데이터와 재현

GTZAN. 22.05kHz 모노 WAV 트랙 1,000개(10개 장르, 각 약 30초). Hugging Face 미러(marsyas/gtzan)로 배포되는 MIR 표준 벤치마크. 원 논문: Tzanetakis & Cook (2002). 원저작자가 명시한 공식 라이선스는 확인되지 않음 - 본 논문은 로컬 알고리즘 검증에만 사용했고 재배포하지 않는다.

FMA-small. Free Music Archive 기반, 약 30초 분량 MP3 클립 8,000개, 트랙별 Creative Commons 라이선스. 원 논문: Defferrard, Benzi, Vanderghelynst & Bresson (2017), "FMA: A Dataset for Music Analysis" (공개 저장소 mdeff/fma).

실측 vs 추정 구분. 본 논문에 보고된 정확도·지연·메모리·해시 개수는 전부 실측값이다. 가산 잡음은 지정한 SNR로 수치적으로 정확하게 가산한 실측 왜곡이고(근사 시뮬레이션이 아니다), MP3 압축과 속도 변화는 실제 ffmpeg 서브프로세스로 인코드/디코드하거나 atempo 필터를 적용한 실측 왕복 처리다. 유일한 예외는 100만 곡 카탈로그에서의 약 868GB RSS 추정치로, 이는 측정된 트랙당 메모리 비용(약 0.889MB/곡)을 선형으로 외삽한 값이며 실측이 아니다.

재현 방법. 알고리즘은 STFT(nperseg=2048, noverlap=1024), 15×15 국소 최댓값 피크 피킹(잡음 바닥 = 평균+1.5×표준편차, 트랙당 상위 1,500개 캡), 피크쌍 해싱(팬아웃 8, 최대 시간차 40타임빈)의 조합으로 약 200줄 내의 표준 신호처리 코드(STFT, 로컬 극값 탐지, 해시 테이블, 오프셋 히스토그램 투표)로 재현 가능하다. 파라미터 전부를 본문 2절에 명시했으므로, scipy 등의 표준 신호처리 라이브러리와 ffmpeg만으로 동일한 실험을 독립적으로 재현할 수 있다.

8 참고문헌

1. Wang, A. (2003). An Industrial-Strength Audio Search Algorithm. Proceedings of the 4th International Conference on Music Information Retrieval (ISMIR).
2. Tzanetakis, G., & Cook, P. (2002). Musical genre classification of audio signals. IEEE Transactions on Speech and Audio Processing, 10(5), 293-302. (GTZAN 데이터셋)
3. Defferrard, M., Benzi, K., Vanderghelynst, P., & Bresson, X. (2017). FMA: A Dataset for Music Analysis. Proceedings of the 18th International Society for Music Information Retrieval Conference (ISMIR).
4. Free Music Archive. <https://freemusicarchive.org> (FMA-small 원본 소스, 트랙별 Creative Commons 라이선스).