

백테스트 규율: 성과를 부풀리는 세 가지 함정

룩어헤드 · 생존편향 · 다중검정, 합성 시계열로 실측 (투자자문 아님)

2i

2026-07-29

초록

백테스트에서 근사한 성과가 실거래에서 사라지는 일은 시장이 번덕스러워서가 아니라, 대부분 백테스트를 짜는 방식 자체에 성과를 부풀리는 구조적 결함이 숨어 있기 때문이다. 이 논문은 세 가지 대표적인 부풀림 기전, 즉 룩어헤드 편향(look-ahead bias), 생존편향(survivorship bias), 다중검정에 의한 데이터 스누핑(data snooping)을 통제된 실험으로 각각 분리해 얼마나 큰 착시를 만드는지 실측했다. 모든 실험은 실제 시장 데이터가 아니라 로컬에서 생성한 합성 랜덤워크(기하 브라운 운동, GBM) 가격열 위에서 수행했으며, 목적은 특정 전략의 수익성을 주장하는 것이 아니라 부풀림 기전 자체를 숫자로 드러내는 것이다. 같은 봉의 미래 정보를 쓰는 룩어헤드 버그 하나만으로 연율화 샤프비율이 약 21.1까지 치솟았고, 하루만 지연시켜 정직하게 계산하면 0.07로 떨어졌다. 무작위 상장폐지를 반영한 전체 유니버스의 5년 연복리성장률은 평균 10.1%였지만, 오늘 살아있는 종목만으로 되짚어 계산한 생존자 전용 백테스트는 13.9%로 3.8퍼센트포인트 부풀려졌다. 같은 하나의 시계열 위에서 무작위로 생성한 이동평균 교차 전략을 더 많이 시도할수록(5개에서 2,000개까지) 표본 내 최고 샤프비율은 0.34에서 0.90까지 매끄럽게 증가했지만, 그 최고 전략을 그대로 표본 밖에서 재현한 샤프비율은 5개 구간 모두에서 0에 가까운 잡음 수준(-0.07~0.17)에 머물렀다. 이 결과는 연구·방법론 시연이며 투자자문이 아니다. 실거래 전략의 수익성을 주장하지 않으며, 모든 수치는 합성 데이터에서 얻은 것이다.

목차

1 요약	3
2 배경: 백테스트가 실전에서 무너지는 이유는 방법이지 시장이 아니다	3
3 세 가지 부풀림 기전	3
3.1 룩어헤드 편향: 미래를 살짝 훑어보는 코드	3
3.2 생존편향: 죽은 종목이 데이터에서 조용히 사라진다	3
3.3 다중검정: 충분히 많이 시도하면 우연히 좋아 보이는 것이 나온다	4
4 실험 설정: 합성 시계열로 기전만 분리한다	4
5 결과	4
5.1 룩어헤드 편향: 인덱스 하나가 만드는 21배의 착시	4
5.2 생존편향: 살아남은 자만 세면 3.8퍼센트포인트가 사라진다	5
5.3 다중검정: 더 많이 찾을수록 표본 내 성과는 좋아지지만 진짜 성과는 그대로다	6
6 실전 체크리스트: 세 함정을 막는 최소한의 절차	6
7 재현	7
8 참고문헌	7

1 요약

백테스트에서 근사한 성과가 실거래에서 사라지는 일은 시장이 변덕스러워서가 아니라, 대부분 백테스트를 짜는 방식 자체에 성과를 부풀리는 구조적 결함이 숨어 있기 때문이다. 이 논문은 세 가지 대표적인 부풀림 기전, 즉 룩어헤드 편향(look-ahead bias), 생존편향(survivorship bias), 다중검정에 의한 데이터 스누핑(data snooping)을 통제된 실험으로 각각 분리해 얼마나 큰 착시를 만드는지 실측했다. 모든 실험은 실제 시장 데이터가 아니라 로컬에서 생성한 합성 랜덤워크(기하 브라운 운동, GBM) 가격열 위에서 수행했으며, 목적은 특정 전략의 수익성을 주장하는 것이 아니라 부풀림 기전 자체를 숫자로 드러내는 것이다. 같은 봉의 미래 정보를 쓰는 룩어헤드 버그 하나만으로 연율화 샤프비율이 약 21.1까지 치솟았고, 하루만 지연시켜 정직하게 계산하면 0.07로 떨어졌다. 무작위 상장폐지를 반영한 전체 유니버스의 5년 연복리성장률은 평균 10.1%였지만, 오늘 살아있는 종목만으로 되짚어 계산한 생존자 전용 백테스트는 13.9%로 3.8퍼센트포인트 부풀려졌다. 같은 하나의 시계열 위에서 무작위로 생성한 이동평균 교차 전략을 더 많이 시도할수록(5개에서 2,000개까지) 표본 내 최고 샤프비율은 0.34에서 0.90까지 매끄럽게 증가했지만, 그 최고 전략을 그대로 표본 밖에서 재현한 샤프비율은 5개 구간 모두에서 0에 가까운 잡음 수준(-0.07~0.17)에 머물렀다. 이 결과는 연구·방법론 시연이며 투자자문이 아니다. 실거래 전략의 수익성을 주장하지 않으며, 모든 수치는 합성 데이터에서 얻은 것이다.

2 배경: 백테스트가 실전에서 무너지는 이유는 방법이지 시장이 아니다

퀀트 전략을 설계해 본 사람이라면 익숙한 장면이 있다. 백테스트 창에서 샤프비율 2를 넘는 우아한 곡선을 보고, 실거래에 배포한 뒤 몇 달이 지나면 그 곡선이 온데간데없이 사라진다. 이 현상을 설명하는 가장 흔한 반응은 “시장이 변했다”이다. 물론 시장 레짐은 실제로 바뀐다. 그러나 실무에서 반복적으로 관찰되는 성과 붕괴의 상당 부분은 레짐 변화보다 훨씬 지루하고, 훨씬 고칠 수 있는 원인에서 온다. 바로 백테스트를 구성하는 방식 자체에 성과를 부풀리는 구조적 결함이 들어있는 경우다.

이 구분이 중요한 이유는 처방이 완전히 다르기 때문이다. 레짐 변화가 원인이라면 답은 더 로버스트한 모델, 더 많은 데이터, 리스크 관리 고도화처럼 본질적으로 어려운 문제다. 방법론적 결함이 원인이라면 답은 훨씬 단순하다. 신호가 실제로 그 시점에 알 수 있었던 정보만 쓰는지 확인하고, 당시 존재했던 전체 유니버스로 다시 계산하고, 몇 개의 파라미터 조합을 시도했는지 세어서 그 검정 횟수를 통계적으로 반영하면 된다. 문제는 이 결함들이 백테스트 코드 안에서 대체로 조용히 숨어 있다는 점이다. 코드는 어러 없이 돌아가고, 숫자는 그럴듯하며, 결함이 있다는 사실을 알려주는 경고 메시지는 어디에도 뜨지 않는다.

이 논문은 그런 결함 중 학계와 실무 양쪽에서 가장 자주 인용되는 세 가지, 룩어헤드 편향, 생존편향, 다중검정을 골라 각각을 독립된 통제 실험으로 분리했다. 세 기전을 한 실험에 섞으면 어느 것이 얼마나 기여했는지 알 수 없으므로, 의도적으로 서로 영향을 주지 않는 별도의 합성 데이터 위에서 각각을 시연한다. 세 실험 모두 실제 종목이나 실제 시장 데이터를 쓰지 않는다. 사용한 것은 numpy로 생성한 순수한 랜덤워크이며, 이 랜덤워크의 참(true) 기대수익률과 참 변동성은 우리가 직접 정한 값이므로, “진짜 답”을 알고 있는 상태에서 백테스트 방법이 그 답을 얼마나 왜곡하는지를 정확히 측정할 수 있다. 이것이 합성 데이터를 쓰는 이유다. 실제 시장 데이터로는 참값을 알 수 없어 부풀림의 크기를 분리해서 썰 방법이 없지만, 우리가 생성 과정을 통제하는 합성 데이터로는 가능하다.

3 세 가지 부풀림 기전

3.1 룩어헤드 편향: 미래를 살짝 훑어보는 코드

룩어헤드 편향은 백테스트가 그 시점에는 존재하지 않았던 정보를 신호 계산에 사용하는 모든 경우를 가리킨다. 가장 노골적인 형태는 실수로 같은 봉(bar)의 증가를 신호 계산과 수익 계산 양쪽에 동시에 쓰는 인덱싱 버그다. 예를 들어 “당일 종가가 전일보다 오르면 당일 롱, 내리면 당일 숏”이라는 규칙을 그대로 벡터 연산으로 구현하면, 신호를 결정하는 정보(당일 종가)가 그 신호로 얻는 수익(역시 당일 종가 기준 수익률)과 같은 시점에서 나온다. 이 규칙은 사실상 “오늘 오를지 내릴지 미리 알고 그 방향으로 미리 진입한다”는 것과 같다. 실전에서는 절대 불가능한 정보 접근이지만, 백테스트 코드에서는 배열 인덱스 하나만 밀리면 자연스럽게 생겨난다. 덜 노골적인 형태로는 재무제표 발표일을 실제 공개일이 아니라 회계 마감일로 쓰는 경우, 데이터 벤더가 사후에 소급 수정한 값(revised data)을 그 시점 데이터인 것처럼 쓰는 경우, 슬리피지 없이 종가에 정확히 체결된다고 가정하는 경우 등이 있다. 공통점은 모두 “그 순간에는 몰랐을 정보”가 backtest 안으로 스며든다는 것이다.

3.2 생존편향: 죽은 종목이 데이터에서 조용히 사라진다

생존편향은 사용하는 유니버스 정의 자체가 이미 결과를 알고 있는 상태에서 구성된다는 문제다. 대부분의 시세 데이터 벤더는 오늘 기준으로 여전히 거래되는 종목의 리스트를 제공한다. 상장폐지되거나 인수합병되거나 파산한 종목은 “현재 종목 리스트”에서 조용히 빠져 있다. 분석가가 이 현재 리스트를 가지고 5년 전으로 거슬러가 백테스트를 돌리면, 그 5년 동안 실제로는 존재

했지만 지금은 사라진 수백 개의 실패 종목이 계산에서 통째로 빠진다. 이는 무작위 누락이 아니다. 사라진 종목들은 체계적으로 성과가 나뉘는 쪽에 몰려 있다. 파산이나 상장폐지는 실적이 좋아서 일어나는 일이 아니기 때문이다. 그 결과 생존자만으로 계산한 평균 수익률은 당시 실제로 그 시장에 투자했다면 얻었을 수익률보다 항상 높은 쪽으로 편향된다. 이 문제는 펀드 성과 연구에서 오래전부터 지적되어 왔으며(Brown, Goetzmann, Ibbotson & Ross, 1992), 개별 종목 백테스트에서도 동일한 메커니즘이 그대로 작동한다.

3.3 다중검정: 충분히 많이 시도하면 우연히 좋아 보이는 것이 나온다

다중검정 문제, 흔히 데이터 스누핑이라 부르는 이 함정은 앞의 두 기전과 성격이 다르다. 룩어헤드와 생존편향은 코드 한 줄의 실수지만, 다중검정은 코드가 전부 정확해도 발생한다. 문제는 “몇 개를 시도했는가”를 세지 않는 데 있다. 하나의 시계열 위에서 이동평균 교차 전략의 파라미터를 5개만 시도하면 우연히 표본 내 성과가 좋은 것이 하나쯤 나올 수 있고, 2,000개를 시도하면 우연히 아주 좋아 보이는 것이 거의 항상 나온다. 이는 그 시계열에 실제로 그런 패턴이 있어서가 아니라, 순수하게 표본 변동성 안에서 가장 운이 좋았던 파라미터 조합을 골랐기 때문이다. 동전을 100번 던지는 실험을 2,000명이 각자 진행하면, 그중 몇 명은 연속으로 15번 앞면이 나오는 놀라운 결과를 얻는다. 그 사람이 특별한 동전 던지기 능력을 가진 것이 아니라, 충분히 많은 사람이 시도했기 때문에 극단값이 반드시 등장하는 것뿐이다. 백테스트에서 파라미터를 스캔하는 행위도 동일한 구조를 가진다. 시도 횟수 N 이 커질수록, 진짜 효과가 전혀 없어도 “표본 내 최고 성과”의 기댓값은 계속 커진다. 이 현상을 교정하지 않고 최고 성과 하나만 골라 “발견한 전략”이라고 보고하는 것이 다중검정에 의한 성과 부풀림이다(Bailey, Borwein, López de Prado & Zhu, 2014).

4 실험 설정: 합성 시계열로 기전만 분리한다

세 실험 모두 numpy만으로 로컬에서 생성한 합성 가격열을 쓰며, 어떤 실제 시장 데이터나 네트워크 호출도 사용하지 않는다. 재현성을 위해 각 실험은 30개의 독립된 시드로 반복하고 평균과 표준편차를 함께 보고한다.

룩어헤드 실험은 연율 기대수익률 6%, 연율 변동성 20%인 기하 브라운 운동에서 1,000거래일짜리 가격열을 생성한다. 버그가 있는 전략은 당일 수익률의 부호를 그날의 포지션으로 그대로 쓴다(포지션 = sign(당일 수익률), 수익 = 포지션 × 당일 수익률). 이는 당일 종가를 미리 알아야만 가능한 전략이며, 부호와 수익률을 곱하면 항상 수익률의 절댓값이 되어 손실이 원천적으로 나올 수 없는 구조다. 교정된 전략은 전날 수익률의 부호를 그대로 다음 날 포지션으로 쓴다(포지션 = sign(전날 수익률)). 이는 실행 가능한 백테스트이지만, 순수 랜덤워크에는 자기상관이 없으므로 어떤 실제 우위도 기대할 수 없다.

생존편향 실험은 500개의 독립된 종목을 5년(1,260거래일) 동안 시뮬레이션한다. 종목별 연율 기대수익률은 평균 6%, 종목 간 표준편차 12%로 무작위로 부여하고, 연율 변동성은 28%로 통일한다. 각 종목은 자신의 최고가 대비 낙폭이 60%를 넘으면 매일 1%의 확률로 상장폐지되며, 상장폐지된 종목은 그 시점 가격에 영구히 고정된다(회복 불가능한 손실로 처리). 전체 유니버스 계산은 500개 종목 모두를 시작 시점부터 동일가중으로 담아 5년 뒤 최종가치까지 그대로 추적한다. 생존자 전용 계산은 5년 뒤에도 상장폐지되지 않고 살아있는 종목만 골라, 그 부분집합만으로 동일가중 포트폴리오를 다시 구성한다. 이는 “현재 상장된 종목 리스트”만 가진 데이터 벤더를 쓰는 실무 관행을 그대로 흉내낸 것이다.

다중검정 실험은 무편향(연율 기대수익률 0%, 연율 변동성 20%) 랜덤워크 1,200거래일을 생성해 처음 60%(720일)를 표본 내(in-sample), 나머지 40%(480일)를 표본 밖(out-of-sample)으로 나눈다. 표본 내 구간에서 무작위로 생성한 (빠른 이동평균, 느린 이동평균) 파라미터 조합을 N 개 시도하고($N = 5, 20, 100, 500, 2,000$), 각 조합의 표본 내 샤프비율을 계산해 가장 높은 것을 고른다. 그다음 그 정확히 같은 파라미터 조합을 표본 밖 구간에 그대로 적용해 재현 성과를 측정한다. 기대수익률을 정확히 0으로 설계한 이유는 참값을 알고 있는 상태에서 시작하기 위함이다. 진짜 우위가 전혀 없는 시계열에서, 얼마나 그럴듯한 표본 내 성과가 “발견”되는지를 재는 것이 이 실험의 목적이다. 교정 기법으로는 두 가지를 함께 적용한다. 하나는 본페로니(Bonferroni) 방식으로, 단일 검정 유의수준 0.05를 시도 횟수 N 으로 나눈 임계값($0.05/N$)을 적용하는 보수적 교정이다. 다른 하나는 배일리과 로페즈 데 프라도(2014)가 제안한 디플레이티드 샤프비율(deflated Sharpe ratio, DSR)로, N 번의 독립 시도에서 무편향 가정 하에 기대되는 “최고 샤프비율”의 크기를 극값이론 근사로 계산하고, 실제로 관측한 최고 샤프비율이 그 기준선을 얼마나 초과하는지를 표준정규분포로 환산해 판정한다.

5 결과

5.1 룩어헤드 편향: 인덱스 하나가 만드는 21배의 착시

같은 봉 정보를 쓰는 버그가 있는 전략은 30개 시드 평균 연율화 샤프비율 21.1(표준편차 0.59)을 기록했다. 이는 현실에서 존재하는 어떤 전략도 도달하지 못하는 수준이며, 애초에 손실이 구조적으로 불가능하게 설계됐기 때문에 나온 값이다. 하루만

자연시켜 정직하게 계산하면 평균 샤프비율은 0.069(표준편차 0.49)로 떨어진다. 이는 0 주변에서 흩어져 있는 잡음 수준이며, 랜덤워크에 진짜 자기상관이 없다는 설계와 정확히 일치한다. 같은 대비를 연복리성장률(CAGR)로 보면 더 극적이다. 버그가 있는 전략의 평균 CAGR은 1,132%(연 11.32배 성장)였고, 교정된 전략의 평균 CAGR은 -0.15%로 거의 정확히 0이었다.




그림 1: 록어헤드 버그 유무에 따른 연율화 샤프비율

이 결과가 시사하는 바는 단순하다. 록어헤드 편향은 정도의 문제가 아니라 존재-비존재의 문제다. 신호와 수익 계산에 같은 시점의 정보가 섞이면, 그 오염의 정도에 따라 착시의 크기가 21배가 될 수도, 1.3배가 될 수도 있다. 실무에서 마주치는 록어헤드 버그는 대부분 이렇게 노골적이지 않고, 인덱스가 하루가 아니라 몇 시간, 혹은 하나의 재무제표 발표 지연만큼만 밀려 있는 미묘한 형태로 나타난다. 그런 미묘한 형태일수록 발견하기 어렵고, 발견하기 전까지는 백테스트 성과를 정직한 값으로 믿게 만든다.

5.2 생존편향: 살아남은 자만 세면 3.8퍼센트포인트가 사라진다

500개 종목 시뮬레이션에서 5년 동안 평균 101.5개(약 20.3%)가 상장폐지됐다. 전체 유니버스(상장폐지된 종목의 실제 손실을 포함)로 계산한 평균 CAGR은 10.1%(표준편차 0.94퍼센트포인트)였다. 오늘 살아있는 398.5개 종목만으로 되짚어 계산한 생존자 전용 CAGR은 13.9%(표준편차 0.98퍼센트포인트)였다. 두 값의 차이, 즉 생존편향이 만들어낸 순수한 착시는 연 3.8퍼센트포인트다.




그림 2: 전체 유니버스 대 생존자 전용 5년 CAGR

3.8퍼센트포인트가 작아 보일 수 있지만, 복리로 여러 해에 걸쳐 누적되는 연간 수익률 차이라는 점을 고려하면 상당한 크기다. 20년을 투자한다고 가정하면 10.1% 대 13.9%의 CAGR 차이는 최종 자산 규모에서 약 2배에 가까운 차이를 만든다. 더 중요한 점은 이 실험에서 상장폐지 확률을 낙폭에 연동시켰다는 것이다. 즉 나쁜 성과를 낸 종목이 상장폐지될 확률이 더 높도록 설계했다. 이는 실제 시장에서 상장폐지, 인수, 파산이 일어나는 방식과 정확히 같은 방향이다. 잘 나가는 회사가 갑자기 상장폐지되는 경우는 드물고, 실적이 무너진 회사가 상장폐지되는 경우가 압도적으로 많다. 그래서 생존자만 남기는 필터링은 무작위 누락이 아니라 "나뻐댈 관측치를 체계적으로 제거"하는 필터링이며, 이 방향성이 편향의 크기를 결정한다.

5.3 다중검정: 더 많이 찾을수록 표본 내 성과는 좋아지지만 진짜 성과는 그대로다

다중검정 실험의 결과는 아래 표와 같다. 표본 내 최고 샤프비율은 시도 횟수 N이 늘수록 매끄럽게 증가하지만, 그 정확히 같은 전략을 표본 밖에 그대로 적용한 샤프비율은 5개 구간 모두에서 0 주변에 머문다.

시도 횟수 N	표본 내 최고 샤프(연율)	표본 밖 재현 샤프(연율)	무편향 하 기대 최고 샤프	단순 유의확률 (naive p)	본페로니 기각률(5%)	DSR “무능력” 확률
5	0.34	0.17	0.71	0.316	0.0%	0.694
20	0.61	0.09	1.12	0.196	0.0%	0.767
100	0.78	-0.04	1.50	0.138	0.0%	0.840
500	0.85	0.01	1.81	0.114	0.0%	0.911
2,000	0.90	-0.07	2.04	0.103	0.0%	0.946




그림 3: 시도 횟수 N에 따른 표본 내 최고 샤프 대 표본 밖 재현 샤프

세 가지를 함께 읽어야 이 표의 의미가 드러난다. 첫째, 표본 내 최고 샤프비율은 N=5일 때 0.34에서 N=2,000일 때 0.90까지 거의 세 배로 늘어난다. 이 시계열의 참 기대수익률은 정확히 0으로 설계했으므로, 이 증가는 전략의 개선이 아니라 순수하게 “더 많이 뒤져서 우연히 좋은 것을 찾아낼 기회가 늘어난 것”이다. 둘째, 그 정확히 같은 파라미터 조합을 표본 밖에서 재현한 샤프비율은 N과 무관하게 -0.07에서 0.17 사이의 좁은 범위에 머물러 있다. N이 커져도 표본 밖 성과가 함께 좋아지지 않는다는 것은, 표본 내에서 찾아낸 “우위”가 표본 밖으로 전혀 이전되지 않는다는 뜻이다. 셋째, 시도 횟수를 반영하지 않는 단순 유의성 검정(단일 검정 기준 유의수준 5%)은 N이 커질수록 점점 더 자주(6.7%에서 46.7%까지) “통계적으로 의미 있다”고 잘못 판정한다. 이는 정확히 다중검정 문제가 예측하는 실패 양상이다. 반면 본페로니 교정(유의수준을 N으로 나눈 기준)과 디플레이티드 샤프비율은 모든 N에서 기각률 0%를 유지하며, 무편향으로 설계된 이 데이터의 진짜 성질을 정확히 짚어낸다. 디플레이티드 샤프비율이 산출하는 “무능력 확률”도 N이 커질수록 0.69에서 0.95까지 함께 높아지는데, 이는 시도 횟수가 늘어날수록 관측된 최고 성과를 더 회의적으로 봐야 한다는 직관을 정확히 정량화한다.

6 실전 체크리스트: 세 함정을 막는 최소한의 절차

세 실험이 공통으로 가리키는 처방은 화려한 신기술이 아니라 지루한 절차다. 실전에서 백테스트를 검토할 때 아래 항목을 확인하는 것만으로 세 부풀림 기전의 대부분을 걸러낼 수 있다.

- 룩어헤드 방어:** 신호를 계산하는 시점의 인덱스와 그 신호로 얻는 수익을 계산하는 시점의 인덱스가 서로 다른지 명시적으로 확인한다. 재무제표·공시 데이터는 실제 공개일을 쓰고 회계 마감일을 쓰지 않는다. 데이터가 사후 소급 수정됐다면(revised data) 그 시점에 실제로 관측 가능했던 원본 값(point-in-time 데이터)을 별도로 보관해 사용한다. 백테스트 프레임워크에 신호 계산과 수익 계산을 강제로 한 봉식 분리하는 지연 레이어를 코드로 박아 두면, 사람이 실수로 인덱스를 밀리는 것을 원천적으로 막을 수 있다.

- **생존편향 방어:** 벤더의 “현재 상장 종목” 리스트가 아니라 각 시점의 실제 유니버스(point-in-time universe)를 쓴다. 상장폐지·인수합병된 종목의 마지막 거래가 또는 인수가를 최종 수익률에 반드시 포함한다. 데이터 벤더가 생존편향 없는 유니버스를 제공하는지 계약 시점에 명시적으로 확인한다(“현재 상장 종목만 제공”이라는 문구가 있다면 그 데이터로 만든 백테스트는 구조적으로 편향돼 있다고 가정한다).
- **다중검정 방어:** 백테스트 과정에서 시도한 파라미터 조합, 변형, 피처의 총 개수를 처음부터 기록한다. 최종적으로 보고하는 샤프비율은 단일 검정 기준이 아니라 시도 횟수를 반영한 교정 기준(본페로니 또는 디플레이티드 샤프비율)으로 재평가한다. 표본 내에서 고른 전략은 반드시 완전히 분리된 표본 밖 구간, 이상적으로는 표본 분할 이후에 새로 관측된 데이터로 재현되는지 확인한다. 표본 내 최적화와 표본 밖 검증을 같은 데이터로 여러 번 반복하면(“표본 밖에서 안 좋으니 표본 내로 돌아가 다시 튜닝”) 표본 밖 구간도 사실상 다중검정에 오염된다는 점을 기억한다.

7 재현

세 실험 모두 numpy와 scipy만으로 동작하며 외부 네트워크 호출이나 실제 시장 데이터를 전혀 사용하지 않는다. 각 실험은 30개의 독립된 난수 시드로 반복해 평균과 표준편차를 함께 보고했으며, 모든 지표(샤프비율, CAGR, 표본 내/표본 밖 성과, 유의확률, 디플레이티드 샤프비율)는 코드가 직접 계산한 값이고 모델이나 실행 주체의 자기 보고가 아니다. 세 실험을 합쳐도 노트북급 CPU에서 수 초 내에 끝나는 가벼운 계산이다. 디플레이티드 샤프비율은 배일리·로페즈 데 프라도(2014)의 근사식을 그대로 구현했으며, 무편향 하 최고 샤프비율의 기댓값은 오일러-마스케로니 상수를 포함한 극값이론 근사식을 썼다. 재현에 필요한 시드, 파라미터, 합성 데이터 생성 과정은 모두 이 논문의 실험 스크립트에 고정돼 있다.

이 논문의 모든 수치는 합성 랜덤워크 데이터에서 얻은 방법론 시연 결과이며, 어떤 실거래 전략의 수익성이나 시장 예측을 주장하지 않는다. **이 내용은 연구·방법론이며 투자자문이 아니다.**

8 참고문헌

1. Bailey, D. H., & López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *Journal of Portfolio Management*, 40(5).
2. Bailey, D. H., Borwein, J., López de Prado, M., & Zhu, Q. J. (2014). Pseudo-Mathematics and Financial Charlatanism: The Effects of Backtest Overfitting on Out-of-Sample Performance. *Notices of the American Mathematical Society*, 61(5).
3. Brown, S. J., Goetzmann, W., Ibbotson, R. G., & Ross, S. A. (1992). Survivorship Bias in Performance Studies. *Review of Financial Studies*, 5(4).
4. Harvey, C. R., Liu, Y., & Zhu, H. (2016). ...and the Cross-Section of Expected Returns. *Review of Financial Studies*, 29(1).
5. Aronson, D. (2006). *Evidence-Based Technical Analysis: Applying the Scientific Method and Statistical Inference to Trading Signals*. Wiley.
6. Pardo, R. (2008). *The Evaluation and Optimization of Trading Strategies*, 2nd ed. Wiley.