

신호 판단의 캘리브레이션된 리스크-스코어

하드 임계 대신 신뢰할 수 있는 확률로: ECE · 온도 · isotonic 실측

2i

2026-07-29

초록

신호 판단 시스템은 대부분 분류기 점수에 하드 임계값을 걸어 '맞다/아니다'를 결정한다. 그러나 앞선 연구에서 오픈셋 RF 지문 인증을 하드 인증 게이트로 쓰는 것은 실패했다. 단일 관측 기준 미지 거부율이 실전에 쓰기에는 너무 낮았고, 그 결론은 인증이라는 산출물 자체가 정직하지 않은 형태라는 뜻이었다. 정직한 형태는 인증을 아예 통과/차단으로 끝내지 않고, 다른 신호 (위치, 이력, 다른 센서)와 함께 융합되는 **리스크-스코어** 하나로 흘려보내는 것이다. 그런데 이 리스크-스코어가 융합 입력으로 쓸모가 있으려면 분류기가 내놓는 확률이 실제 정답률과 맞아야 한다. 즉 '80% 확신'이라고 말한 판단들이 실제로 80% 맞아야 한다. 이것이 캘리브레이션(calibration)이며, 딥러닝 문헌에서는 모델이 체계적으로 과신한다는 사실이 반복적으로 보고돼 있으나, 우리가 실제로 쓰는 **고전 DSP 특징 + LightGBM** 신호 분류기가 그런지는 별도로 재 봐야 하는 질문이다.

목차

1 요약	3
2 배경	3
3 방법	4
3.1 기대보정오차(ECE)와 신뢰도 다이어그램	4
3.2 보정 방법 세 가지	4
4 데이터·설정	4
5 결과	5
5.1 보정 전후 ECE	5
5.2 신뢰도 다이어그램: 어디서 과신하는가	5
5.3 순위는 보존되는가	6
6 한계와 운영 합의	6
7 재현	7
8 참고문헌	7

1 요약

신호 판단 시스템은 대부분 분류기 점수에 하드 임계값을 걸어 “맞다/아니다”를 결정한다. 그러나 앞선 연구에서 오픈셋 RF 지문 인증을 하드 인증 게이트로 쓰는 것은 실패했다. 단일 관측 기준 미지 거부율이 실전에 쓰기에는 너무 낮았고, 그 결론은 인증이라는 산출물 자체가 정직하지 않은 형태라는 뜻이었다. 정직한 형태는 인증을 아예 통과/차단으로 끝내지 않고, 다른 신호(위치, 이력, 다른 센서)와 함께 융합되는 **리스크-스코어** 하나로 흘려보내는 것이다. 그런데 이 리스크-스코어가 융합 입력으로 쓸모가 있으려면 분류기가 내놓는 확률이 실제 정답률과 맞아야 한다. 즉 “80% 확신”이라고 말한 판단들이 실제로 80% 맞아야 한다. 이것이 캘리브레이션(calibration)이며, 딥러닝 문헌에서는 모델이 체계적으로 과신한다는 사실이 반복적으로 보고돼 있으나, 우리가 실제로 쓰는 **고전 DSP 특징 + LightGBM** 신호 분류기가 그런지는 별도로 재 봐야 하는 질문이다.

본 논문은 그 질문을 공개 데이터셋 DroneRF(AI-Sa'd 등, 카타르대학교, CC BY 4.0)로 직접 측정했다. 24차원 물리 특징(RSSI, 엔벨로프 통계, PAPR, 반송파 주파수 오프셋, 고차 큐물런트, 스펙트럴 형태)으로 배경 대 드론 이진 탐지기를 학습하고, 5개 시드에 걸쳐 훈련/보정/테스트를 50/25/25로 분할해 raw 확률의 기대보정오차(ECE)를 측정한 뒤, 보정 분할에서 (a) Platt 스케일링, (b) 1-파라미터 온도 스케일링, (c) isotonic 회귀를 각각 적합하고 held-out 테스트에서 다시 ECE와 Brier 점수를 측정했다. 결과는 명확했다. 원시 확률의 ECE는 평균 0.0446(표준편차 0.0062)이었고, 세 보정 방법 모두 이를 낮췄다. 가장 큰 개선은 isotonic 회귀로 ECE 0.0188(표준편차 0.0034), 약 58% 감소였다. Platt과 온도 스케일링은 각각 ECE 0.0223, 0.0228로 약 49~50% 감소였다. 적합된 온도 T는 평균 1.599(표준편차 0.099)로 1보다 뚜렷이 컸는데, 이는 이 분류기가 체계적으로 과신하는 방향으로 미보정돼 있었음을 정량적으로 확인한다. 순위(AUROC)는 Platt과 온도 스케일링에서 소수점 다섯째 자리까지 완전히 보존되었고(0.9374 → 0.9374), isotonic에서는 0.9374에서 0.9363으로 미미하게(약 0.001) 낮아졌다. 즉 표준 보정 기법은 판단 자체를 바꾸지 않으면서 그 판단에 붙는 확신의 숫자만 정직하게 고친다. 결론적으로, 하드 인증이 막힌 자리에 캘리브레이션된 리스크-스코어를 놓는다는 설계는 이 신호 분류기에서 실측으로 뒷받침된다.

2 배경

앞선 연구는 오픈셋 RF 지문 인증을 단독 하드 게이트로 쓰는 접근을 실측으로 검증했고, 결론은 NO-GO였다. 등록된 신호를 정확히 알아맞히는 폐쇄셋 성능은 쓸 만했지만, 등록되지 않은 미지 신호를 걸러내는 오픈셋 거부율이 단일 관측(K=1, 야전에 가장 가까운 조건)에서 너무 낮았고, 이는 그 시스템을 “이 신호가 맞으면 통과, 아니면 차단”이라는 단독 인증 장치로 배치하기에는 오탐·미탐 비용이 감당하기 어렵다는 뜻이었다. 그 결과가 남긴 실질적 질문은 “그럼 이 분류기 출력을 아예 버려야 하는가”가 아니라 “이 분류기 출력을 정직한 형태로 어떻게 쓸 것인가”였다.

정직한 형태는 단독 인증이 아니라 **리스크-스코어**다. 이 신호가 특정 클래스일 확률을 숫자 하나로 내놓고, 이 숫자를 위치 정보, 과거 이력, 다른 센서의 판단과 함께 융합 플랫폼에 입력으로 흘려보낸다. 이 설계는 오픈셋 거부율이 낮다는 약점을 정면으로 피해간다. 이 신호 하나만으로 최종 결정을 내리지 않기 때문에, 이 신호의 확신도가 낮은 경우에도 시스템 전체가 붕괴하지 않는다. 대신 다른 신호가 더 강하면 최종 판단이 그 방향으로 기울고, 이 신호가 유일한 근거일 때만 리스크-스코어 자체가 판단을 좌우한다.

그런데 이 설계가 성립하려면 반드시 지켜야 하는 전제가 하나 있다. 융합 입력으로 쓰이는 숫자가 **신뢰할 수 있는 확률**이어야 한다. 분류기가 “이 신호는 드론일 확률이 90%”라고 말했을 때, 그 90%라는 표시된 신뢰도가 실제로 그 신호가 드론인 경험적 빈도와 가까워야 한다. 그렇지 않으면 융합 알고리즘은 잘못된 강도로 이 신호를 반영한다. 예컨대 분류기가 체계적으로 과신하는 방향으로 미보정돼 있다면(원시 확신도가 실제 정답률보다 항상 높게 나온다면), 이 신호는 융합에서 실제보다 더 큰 가중치를 부여받고, 그 결과 다른 신호가 맞는 상황에서도 최종 판단이 이 신호 쪽으로 과도하게 끌려간다. 반대로 분류기가 과소신뢰 방향이라면 정작 강한 신호일 때도 융합에서 충분히 반영되지 않는다. 하드 인증에서는 임계값 하나만 잘 고르면 이 문제가 어느 정도 가려지지만, 리스크-스코어 융합에서는 확신도 숫자 자체가 산출물이므로 이 문제를 가릴 곳이 없다.

이것이 캘리브레이션(calibration)이 필요한 이유다. 신경망 계열 분류기가 체계적으로 과신한다는 사실은 여러 문헌에서 반복적으로 보고돼 있고, 그 교정 기법(온도 스케일링, Platt 스케일링, isotonic 회귀)도 널리 알려져 있다. 그러나 우리가 실제로 쓰는 파이프라인, 즉 손으로 설계한 물리 특징 위에 그라디언트 부스팅 트리(LightGBM)를 얹은 고전 신호 분류기가 같은 문제를 갖는지, 그리고 표준 보정 기법이 이 분류기에도 같은 효과를 내는지는 별도로 측정해야 하는 질문이다. GBDT 계열은 신경망과 학습 방식이 다르므로(리프 노드의 경험적 확률을 그대로 출력) 과신 패턴이 신경망과 같은 방향, 같은 크기로 나타날지 자명하지 않다. 본 논문은 이 질문을 실측으로 답한다.

3 방법

3.1 기대보정오차(ECE)와 신뢰도 다이어그램

캘리브레이션의 표준 정의는 다음과 같다. 분류기가 확률 p 를 출력하는 모든 사례를 모았을 때, 그 사례들의 실제 정답률(경험적 정확도)이 p 와 같아야 완전히 보정되었다고 한다. 이를 측정하기 위해 예측 확률 구간을 동일 폭의 bin(bin)으로 나누고, 각 bin에 속한 사례들의 평균 예측 확신도(mean confidence)와 실제 정답률(empirical accuracy)을 비교한다. 기대보정오차(Expected Calibration Error, ECE)는 각 bin의 확신도-정확도 차이를 그 bin에 속한 사례 수로 가중 평균한 값이다.

$$ECE = \sum_m (n_m / N) * |acc_m - conf_m|$$

여기서 M 은 bin의 개수, n_m 은 m 번째 bin에 속한 사례 수, N 은 전체 사례 수, acc_m 과 $conf_m$ 은 각각 m 번째 bin의 경험적 정확도와 평균 확신도다. 본 논문은 $M=15$ 개의 동일 폭 bin(0.0~1.0을 15구간으로 분할)을 사용했다. ECE가 0이면 완전 보정, 값이 클수록 확신도와 실제 정답률의 괴리가 크다. 신뢰도 다이어그램(reliability diagram)은 이 bin별 확신도와 정확도를 그래프로 그린 것으로, 대각선($y=x$)에서 벗어난 정도가 곧 그 구간의 보정 오차를 시각적으로 보여준다.

ECE와 함께 Brier 점수(예측 확률과 실제 라벨의 평균 제곱 오차)를 함께 보고한다. ECE는 구간별 집계 통계라 bin 경계 선택에 민감할 수 있는 반면, Brier 점수는 사례 단위로 계산되는 연속적 지표라 두 지표가 같은 방향을 가리키는지 교차 확인하는 용도로 쓴다. 순위 성능은 AUROC(수신자 조작 특성 곡선 아래 면적)로 별도 측정한다. 보정이 판단의 실질(누가 더 위험한 신호인지 정렬하는 능력)을 훼손하지 않는지 확인하기 위해서다.

3.2 보정 방법 세 가지

훈련된 분류기의 원시 확률을 보정 분할(calibration split, 훈련에도 테스트에도 쓰이지 않은 별도 데이터)에서 다음 세 방법으로 다시 매핑한다.

(a) Platt 스케일링. 원시 확률 p 를 로짓(logit) $z = \log(p/(1-p))$ 로 변환한 뒤, 보정 분할의 라벨로 z 에 대한 1차원 로지스틱 회귀 sigmoid($A \cdot z + B$)를 적합한다. 계수 A 와 B 는 최대우도추정으로 정해진다. A 와 B 두 개의 자유도를 가진다.

(b) 온도 스케일링(temperature scaling). 같은 로짓 z 를 스칼라 온도 T 로 나눈 뒤 시그모이드를 적용한다: $p_T = \text{sigmoid}(z/T)$. 편향(bias) 향이 없는 1-파라미터 방법으로, 보정 분할에서 음의 로그우도(NLL)를 최소화하는 T 를 스칼라 최적화로 구한다. $T > 1$ 이면 원시 로짓이 실제보다 극단적(과신)이었다는 뜻이고, T 를 나눔으로써 확률 분포를 1(완전 확신)과 0(완전 불확실) 쪽에서 중간으로 눌러 넓힌다.

(c) Isotonic 회귀. 원시 확률 p 를 실제 라벨에 단조증가(monotonic non-decreasing) 함수로 매핑하는 비파라메트릭 방법이다. Platt과 온도 스케일링이 특정 함수 형태(시그모이드)를 가정하는 반면, isotonic 회귀는 단조성만 가정하고 나머지는 데이터가 정하게 둔다. 자유도가 높아 보정 분할이 충분히 크면 더 정교하게 맞출 수 있지만, 보정 분할이 작으면 과적합 위험도 그만큼 크다.

세 방법 모두 원시 확률(또는 그 로짓)의 **단조 함수**라는 공통점이 있다. 이는 중요한 성질로 이어진다. 순위를 바꾸지 않는다는 것이다. A 와 T 가 양수인 한 Platt과 온도 스케일링은 정확히 순위를 보존하는 변환이고, isotonic 회귀도 단조성을 강제하므로 순위를 어기지 않는다(단, 서로 다른 원시 점수가 같은 보정 후 값으로 합쳐지는 동률 tie가 생길 수 있어 그 경우에 한해 AUROC가 아주 미세하게 흔들릴 수 있다). 4절에서 이를 실측으로 확인한다.

4 데이터·설정

데이터는 공개 데이터셋 **DroneRF**(AI-Sa'd 등, 카타르대학교, Mendeley 저장소, DOI 10.17632/f4c2b4n755, 라이선스 CC BY 4.0, 출처 표시 조건으로 상업적 인용 가능)를 사용했다. 이 데이터셋은 앞선 오픈셋 인증 연구에서도 사용된 것과 같은 소스이며, 본 논문은 그 연구의 특징 추출 접근(24차원 물리 특징)을 재사용해 캘리브레이션이라는 다른 질문에 적용했다.

원시값은 세그먼트당 1000만 개의 실수값 ADC 진폭 샘플이며, 이를 4096샘플의 비중첩 윈도우로 분할하고 결정론적 스트라이드로 서브샘플링해 총 9000개의 윈도우를 구성했다. 배경(잡음만, is_drone=0) 1800개, 드론 신호(Bebop·AR-drone·Phantom의 9개 비행모드 합, is_drone=1) 7200개로, 데이터셋 자체의 구조에서 온 클래스 불균형이다(임의로 만든 것이 아니다). 과제는 **배경 대 드론 이진 탐지**로 정의했다. 캘리브레이션 지표(ECE, Brier)는 이진 분류에서 정의가 가장 단순하고 해석이 직접적이라, 이 과제를 캘리브레이션 측정의 1차 대상으로 선택했다.

각 윈도우에서 24차원 특징을 추출한다. RSSI(평균 전력, dB) 1개, 엔벨로프 통계(평균, 표준편차, 비대칭도, 첨도, 변동계수) 5개와 PAPR 1개, 순시주파수 기반 반송파 주파수 오프셋(CFO) 통계(평균, 표준편차, 첨도) 3개, 고차 큐물런트(Swami와 Sadler,

2000년 방법: C20, C21, C40, C41, C42, C63) 6개, Welch PSD 기반 스펙트럴 형태 특징(중심주파수 오프셋, 대역폭, 평탄도, 엔트로피, 4개 대역 에너지비) 8개다. 분류기는 LightGBM(300개 트리, num_leaves=31, learning_rate=0.05)이며 특징은 훈련 분할의 평균·표준편차로 표준화했다.

5개의 무작위 시드(42, 7, 123, 2026, 99)에 걸쳐 각각 새로 훈련/보정/테스트 분할을 50%/25%/25%로 라벨 층화(stratified) 방식으로 나눴다. 시드마다 훈련 분할로 LightGBM을 새로 학습하고, 보정 분할로 세 보정 방법(Platt, 온도, isotonic)을 각각 적합하고, 어떤 학습·적합에도 쓰이지 않은 테스트 분할에서 ECE·Brier·AUROC를 측정했다. 5개 시드에 걸친 평균과 표준편차를 최종 결과로 보고한다.

5 결과

5.1 보정 전후 ECE

5개 시드에 걸친 평균 ECE는 다음과 같았다.

방법	ECE (평균)	ECE (표준편차)	개선율
보정 전(raw)	0.0446	0.0062	-
Platt 스케일링	0.0223	0.0022	50.0%
온도 스케일링	0.0228	0.0025	48.9%
Isotonic 회귀	0.0188	0.0034	57.9%




그림 1: 기대보정오차

세 보정 방법 모두 원시 ECE를 절반 안팎으로 줄였다. Isotonic 회귀가 가장 큰 개선을 보였고(57.9% 감소), Platt과 온도 스케일링은 거의 동일한 수준으로 개선했다(각각 50.0%, 48.9%). Platt과 온도 스케일링이 비슷한 크기의 개선을 보인 것은 이 데이터에서는 편향(B)이 크게 필요하지 않았다는 뜻이며, 이는 적합한 온도 T의 평균값(1.599)이 뚜렷하게 1보다 크다는 사실과도 맞는다. 온도 $T > 1$ 은 원시 로짓을 나누어 확률 분포를 중간값 쪽으로 눌러 넓히는 방향이며, 이는 이 분류기가 체계적으로 과신(over-confident) 방향으로 미보정돼 있었음을 정량적으로 뜻한다. 5개 시드 전체에서 T는 1.4376에서 1.7289 사이였고, 1보다 작은 시드는 하나도 없었다. 즉 과신 방향의 편향은 시드에 따라 흔들리는 잡음이 아니라 일관된 패턴이다.

5.2 신뢰도 다이어그램: 어디서 과신하는가

ECE가 하나의 숫자로 압축한 정보를 신뢰도 다이어그램으로 풀어보면, 과신이 균일하게 퍼져 있지 않다는 것을 알 수 있다.

첫 번째 시드(42)의 테스트 분할을 예로 들면, 확신도 0.8~0.87 구간(평균 확신도 0.8335)에 속한 예측들의 실제 정답률은 0.6441에 불과했다. 즉 이 분류기가 "83% 확신한다"고 말한 사례들이 실제로는 64%만 맞았다는 것이다. 반대로 확신도 0.93 이상 구간(평균 확신도 0.9946)은 실제 정답률 0.9816으로 거의 대각선에 붙어 있었다. 이는 이 분류기의 과신이 전체 확신도 범위에서 균일하지 않고, 중~고 확신도 구간(0.8 안팎)에서 특히 두드러진다는 뜻이다. Isotonic 보정 후 같은 구간의 정답률은 0.8986으로 대각선에 훨씬 가까워졌다. 표에서 확신도 0.50 구간은 이 시드의 테스트 분할에서 표본이 1개뿐이라(isotonic 보정으로 그 구간에 재배치된 표본 수가 작다) 정답률이 1.0으로 튀는 소표본 잡음이 섞여 있으며, 이는 보정 방법의 실패가 아니라 해당 구간의 표본 부족을 그대로 반영한 것이다.




그림 2: 신뢰도 다이어그램: 예측 신뢰도 구간별 실제 정확도

5.3 순위는 보존되는가

방법	AUROC (평균)	AUROC (표준편차)
보정 전(raw)	0.93741	0.00502
Platt 스케일링	0.93741	0.00502
온도 스케일링	0.93741	0.00502
Isotonic 회귀	0.93633	0.00537

Platt과 온도 스케일링은 소수점 다섯째 자리까지 원시 AUROC를 완전히 보존했다. 이는 2.2절에서 설명한 이론적 성질(양의 스칼라·시그모이드에 의한 단조 변환은 순위를 바꾸지 않는다)이 실측에서도 정확히 확인된 것이다. Isotonic 회귀는 평균 0.93741에서 0.93633으로 약 0.0011 낮아졌는데, 이는 isotonic 회귀가 서로 다른 원시 확률값을 같은 계단(step)의 보정 값으로 합치면서 생기는 동률(tie) 효과이며, 실질적인 판단력 손실이라 보기엔 너무 작다. Brier 점수도 같은 방향을 가리켰다 (보정 전 0.0832 → Platt 0.0797 → 온도 0.0795 → isotonic 0.0803). Brier 점수의 개선폭(4~5%)은 ECE의 개선폭(49~58%)보다 훨씬 작는데, 이는 자연스럽다. Brier 점수는 정확도 자체에도 좌우되는 지표라 애초에 분류기의 판별력이 높은(AUROC 0.937) 상황에서는 절대적인 개선 여지가 크지 않지만, ECE는 오직 확신도와 정답률의 정렬만 측정하므로 같은 판별력 아래에서도 보정이 크게 개선할 수 있는 여지가 남아 있다.

6 한계와 운영 합의

운영 합의. 이 결과가 뜻하는 실무적 결론은 단순하다. 신호 판단 시스템이 분류기 출력을 리스크-스코어로 융합 플랫폼에 넘길 때, 원시 확률을 그대로 넘기지 말고 보정 분할에서 적합한 Platt 또는 isotonic 매핑을 거쳐서 넘겨야 한다. 이 교정에는 판단력을 희생하는 비용이 실질적으로 없다(AUROC가 사실상 보존된다). 반면 이득은 분명하다. 확신도 0.8 근방의 판단들이 실제로는 64%만 맞는다는 사실을 모른 채 이 판단을 다른 신호와 0.83의 무게로 융합하는 것과, 이를 보정해 실제 정답률에 가까운 무게(0.65 안팎)로 융합하는 것은 최종 리스크-스코어의 신뢰도에 실질적인 차이를 만든다. 특히 다중 센서 융합 아키텍처에서는 각 센서의 확신도가 서로 다른 스케일로 왜곡돼 있으면 융합 규칙(가중 평균, 베이지안 결합 등) 자체가 암묵적으로 잘못된 가중치를 학습하거나 잘못 설계된다. 보정은 이 왜곡을 융합 이전 단계에서 제거하는, 상대적으로 저비용의 수정이다.

Platt과 isotonic 중 어느 것을 택할지는 보정 분할의 크기와 원하는 보정의 정밀도 사이의 트레이드오프다. 본 실험에서는 isotonic이 ECE를 더 크게 줄였지만, 이는 보정 분할이 2250개 표본(테스트 분할과 같은 크기)으로 비교적 넉넉했기 때문일 가능성이 있다. 보정 데이터가 훨씬 적은 운용 환경(예: 신규 배치 초기, 라벨이 드문 조건)에서는 자유도가 높은 isotonic 회귀가 과적합할 위험이 커지고, 이 경우 2개 파라미터만 적합한 Platt 스케일링이 더 안정적일 수 있다. 이 트레이드오프는 이번 실험이 직접 측정하지 않았으며, 후속 실험이 필요한 열린 질문이다.

한계. 본 실험은 이진 탐지(배경 대 드론) 과제 하나에만 캘리브레이션을 측정했다. 앞선 오픈셋 인증 연구가 다뤘던 다중 클래스 식별이나 오픈셋 거부 과제의 캘리브레이션은 별도로 측정해야 하며, 다중 클래스 ECE는 정의와 계산이 이진 경우보다 복잡하다 (top-1 확신도만 볼지, 클래스별로 나눠 볼지 등 선택이 남는다). 데이터셋도 하나(DroneRF)이며, 배경 클래스가 단일 환경 (카타르대학교 실험실)에서 캡처된 잡음이라 배치 환경이 달라지면 배경의 통계적 성질이 달라질 수 있고, 이 경우 보정된 매핑도 그 환경에서 다시 적합해야 한다. 다시 말해 보정은 데이터셋과 배치 환경에 종속적인 절차이며, 한 번 적합해서 영구히 쓸 수 있는 고정값이 아니다. 5개 시드에 걸친 표준편차(ECE 0.002~0.006 수준)는 작아 결과가 시드에 크게 흔들리지 않음을 보여주지만, 이는 데이터셋을 재분할하는 데서 오는 변동성만을 반영하며 서로 다른 배치 환경 사이의 변동성은 포함하지 않는다.

7 재현

```
# 1) 특징 추출: 24차원 물리 특징(RSSI, 엔벨로프 통계, PAPR, CFO, 고차 큐물런트,
# 스펙트럴 형태 -- 2.1절 정의와 동일 로직, 본 실험 스크립트에 자기완결적으로 포함)
# 2) 5개 시드에 걸쳐 훈련/보정/테스트(50/25/25, 라벨 증화) 반복:
# - 훈련 분할로 LightGBM(300 트리, num_leaves=31) 학습
# - 보정 분할로 Platt(로지스틱 회귀)·온도(1-파라미터 NLL 최소화)·isotonic 회귀 적합
# - 테스트 분할에서 ECE(15-bin)·Brier-AUROC 측정
python3 calib_experiment.py
```

전체 실행은 CPU 단독으로 몇 초 내에 끝난다(9000개 윈도우, 24차원 특징, 5개 시드 x LightGBM 300트리 x 4가지 확률 세트에 대한 ECE 계산). 별도 GPU나 격리된 가상환경이 필요하지 않다.

8 참고문헌

1. M. Al-Sa'd, A. Al-Ali, A. Mohamed, T. Khattab, A. Erbad. "RF-based drone detection and identification using deep learning approaches." Future Generation Computer Systems, 2019. Dataset: DroneRF, Mendeley Data, DOI 10.17632/f4c2b4n755, CC BY 4.0, Qatar University.
2. C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger. "On Calibration of Modern Neural Networks." ICML, 2017. 온도 스케일링과 신경망 과신 문제의 정보 레퍼런스.
3. J. Platt. "Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods." Advances in Large Margin Classifiers, 1999. Platt 스케일링의 원 논문.
4. B. Zadrozny, C. Elkan. "Transforming Classifier Scores into Accurate Multiclass Probability Estimates." KDD, 2002. Isotonic 회귀 기반 확률 보정의 정보 레퍼런스.
5. A. Niculescu-Mizil, R. Caruana. "Predicting Good Probabilities with Supervised Learning." ICML, 2005. 다양한 분류기 계열의 캘리브레이션 특성 비교.
6. A. Swami, B. M. Sadler. "Hierarchical digital modulation classification using cumulants." IEEE Transactions on Communications, 2000. 본 실험의 고차 큐물런트 특징의 근거.