

고전 DSP+GBM 대 딥러닝: 신호 과제 결정 지도

어느 신호 과제에서 고전 기법이 이기고 어디서 딥러닝이 이기는가, 실측 기반

2i

2026-07-29

초록

무선 신호처리 커뮤니티에는 널리 퍼진 통념이 있다. 딥러닝이 결국 모든 과제에서 고전 신호처리(DSP)와 그래디언트 부스팅(GBM)을 이긴다는 것이다. 이 논문은 그 통념을 검증 가능한 주장으로 좁혀서 실측했다. 변조분류, 고정 오탐률 간섭탐지, 드론 무선 신호 오프셋 거부, 채널추정, 무선 지문(RF fingerprint) 융합, 동일 채널 신호분리까지 여섯 개 과제에서 같은 데이터·같은 분할·같은 지표로 고전 방법과 딥러닝을 공정하게 맞세웠다. 결과는 단일 명제가 아니라 과제에 따라 갈렸다. 표준 공개 데이터셋 RadioML2016.10a 6dB 부분집합에서 변조분류는 고전(28차원 물리 특징 + LightGBM, 정확도 0.855)이 딥러닝(1.39M 파라미터 트랜스포머, 0.681)을 뚜렷하게 이겼고, 학습 데이터를 늘려도 이 우위는 실측된 구간(539~2,000)에서 뒤집히지 않았다. 고전 곡선은 9,900개까지 완만히 정체했지만, 그 지점의 딥러닝 재측정은 완료되지 않아 교차점이 실제로 존재하는지는 이 데이터 범위 안에서 확인되지 않았다. 고정 오탐률을 요구하는 간섭탐지에서는 고전 CFAR(constant false-alarm-rate) 계열이 잡음 바닥이 흔들리는 상황에서도 목표 오탐률을 구조적으로 지켰지만, 제약 없는 이진 딥러닝 탐지기는 같은 조건에서 오탐률이 1.0으로 폭발했다. 공개 데이터셋 DroneRF(CC BY 4.0)로 재현한 드론 무선신호 오프셋 거부에서는 고전 특징 + 마할라노비스 거부가 단일 관측($K=1$) 기준으로 딥러닝 대비 미지 장치 거부율이 5.7배 높았다. 반대로 딥러닝이 뚜렷하게 이긴 과제도 있었다. 동일 채널에 겹친 두 무선 신호를 분리하는 과제에서 학습형 분리기(Conv-TasNet 변형)는 SI-SDRi +3.01dB를 기록했지만 고전 독립성분분석(ICA) 기반 방법은 -14.25dB로 오히려 혼합 신호보다 나빴다. 무선 지문 융합에서도 딥러닝 임베딩이 자체 고전 융합 기준선을 이겼으나(AUROC 0.9994 대 0.945, $K=50$ 융합), 이 승리는 여러 겹의 조건이 붙는다. 채널추정은 방법론 결함이 있는 초기 실험에서 애매한 신호만 나왔고 확정된 결론은 아직 없다. 이 논문의 목적은 어느 한쪽을 응원하는 것이 아니라, 어느 신호 과제에서 무엇이 실제로 이기는지를 숫자와 그 숫자의 한계까지 함께 공개하는 것이다.

목차

1 요약	3
2 배경	3
3 평가 방법론	3
4 과제별 결과	4
4.1 변조분류 — 고전이 이긴다	4
4.2 고정 오탐률 간섭탐지 — 고전이 구조적으로 유리하다	5
4.3 드론 무선신호 오픈셋 거부 — 저-K에서 고전이 이긴다	6
4.4 채널추정/등화 — 아직 결론이 나지 않았다	7
4.5 무선 지문(RF fingerprint) 융합 — 딥러닝이 이기지만, 여러 겹의 조건이 붙는다	7
4.6 동일 채널 신호분리 — 딥러닝이 명확하게 이긴다	7
5 종합 결정 지도	8
6 한계	9
7 데이터와 재현	9
8 참고문헌	9

1 요약

무선 신호처리 커뮤니티에는 널리 퍼진 통념이 있다. 딥러닝이 결국 모든 과제에서 고전 신호처리(DSP)와 그래디언트 부스팅(GBM)을 이긴다는 것이다. 이 논문은 그 통념을 검증 가능한 주장으로 좁혀서 실측했다. 변조분류, 고정 오탐률 간섭탐지, 드론 무선 신호 오픈셋 거부, 채널추정, 무선 지문(RF fingerprint) 융합, 동일 채널 신호분리까지 여섯 개 과제에서 같은 데이터·같은 분할·같은 지표로 고전 방법과 딥러닝을 공정하게 맞붙였다. 결과는 단일 명제가 아니라 과제에 따라 갈렸다. 표준 공개 데이터셋 RadioML2016.10a 6dB 부분집합에서 변조분류는 고전(28차원 물리 특징 + LightGBM, 정확도 0.855)이 딥러닝(1.39M 파라미터 트랜스포머, 0.681)을 뚜렷하게 이겼고, 학습 데이터를 늘려도 이 우위는 실측된 구간(539~2,000)에서 뒤집히지 않았다. 고전 곡선은 9,900개까지 완만히 정제했지만, 그 지점의 딥러닝 재측정은 완료되지 않아 교차점이 실제로 존재하는지는 이 데이터 범위 안에서 확인되지 않았다. 고정 오탐률을 요구하는 간섭탐지에서는 고전 CFAR(constant false-alarm-rate) 계열이 잡음 바닥이 흔들리는 상황에서도 목표 오탐률을 구조적으로 지켰지만, 제약 없는 이진 딥러닝 탐지기는 같은 조건에서 오탐률이 1.0으로 폭발했다. 공개 데이터셋 DroneRF(CC BY 4.0)로 재현한 드론 무선신호 오픈셋 거부에서는 고전 특징+마할라노비스 거부가 단일 관측($K=1$) 기준으로 딥러닝 대비 미지 장치 거부율이 5.7배 높았다. 반대로 딥러닝이 뚜렷하게 이긴 과제도 있었다. 동일 채널에 겹친 두 무선 신호를 분리하는 과제에서 학습형 분리기(Conv-TasNet 변형)는 SI-SDRi +3.01dB를 기록했지만 고전 독립성분분석(ICA) 기반 방법은 -14.25dB로 오히려 혼합 신호보다 나빴다. 무선 지문 융합에서도 딥러닝 임베딩이 자체 고전 융합 기준선을 이겼으나(AUROC 0.9994 대 0.945, $K=50$ 융합), 이 승리는 여러 겹의 조건이 붙는다. 채널추정은 방법론 결함이 있는 초기 실험에서 애매한 신호만 나왔고 확정된 결론은 아직 없다. 이 논문의 목적은 어느 한쪽을 응원하는 것이 아니라, 어느 신호 과제에서 무엇이 실제로 이기는지를 숫자와 그 숫자의 한계까지 함께 공개하는 것이다.

2 배경

무선 신호처리 분야에서 딥러닝은 지난 몇 년 사이 기본 선택지처럼 취급되어 왔다. 변조 분류든 간섭탐지든 무선 지문 인식이든, 학회 논문과 벤더 자료 다수가 “딥러닝이 고전 방법을 능가한다”는 결과를 보여준다. 그러나 이런 비교의 상당수는 공정하지 않다. 딥러닝 쪽에는 대량의 학습 데이터와 GPU 튜닝 시간이 주어지고, 고전 쪽에는 튜닝되지 않은 얇은 특징이나 단순 임계값이 대응 상대로 놓인다. 반대의 오류도 흔하다. 딥러닝을 과소학습 상태로 두거나, 고전 방법에 유리한 저데이터 조건에서만 비교하는 경우다. 두 방향 모두 “누가 이기는가”라는 질문에 정직한 답을 주지 못한다.

이 논문이 던지는 질문은 좁고 구체적이다. **동일한 데이터, 동일한 분할, 동일한 지표 위에서, 무선 신호처리의 각 세부 과제별로 고전 DSP+GBM과 딥러닝 중 무엇이 실제로 이기는가.** “딥러닝이 낫다” 또는 “고전이 낫다”라는 하나의 문장으로 답할 수 있는 질문이 아니라는 것이 이 연구의 첫 번째, 그리고 가장 중요한 발견이다. 승자는 과제마다 갈렸고, 그 이유도 과제마다 달랐다. 어떤 과제는 데이터 규모가 작아 고전이 유리했고, 어떤 과제는 물리적으로 결정론적인 문제라서 학습된 표현이 애초에 필요 없었고, 어떤 과제는 하드웨어의 미묘한 서명처럼 사람이 손으로 설계한 특징으로는 잡기 어려운 패턴이 있어 딥러닝이 필요했다.

이 논문의 가치는 어느 쪽이 이겼다는 결론 자체보다, 그 결론에 이르기까지 실제로 지킨 측정 규율에 있다. 모든 수치는 실행된 실험에서 나온 것이며, 아직 실행되지 않은 실험의 예상 결과는 결과로 인용하지 않는다. 합성 데이터로 얻은 수치와 실측 공개 데이터셋으로 얻은 수치는 항상 구분해서 표시한다. 방법론에 결함이 있었던 초기 실험은 그 결함까지 함께 기록한다. 이것이 이 논문 전체를 관통하는 원칙이다.

3 평가 방법론

여섯 개 과제 각각에 대해 다음 원칙을 지켰다.

동일 데이터·동일 분할·동일 지표. 고전 방법과 딥러닝은 같은 학습/평가 분할, 같은 입력 창 크기, 같은 평가지표를 공유한다. 한쪽에만 유리한 전처리나 데이터 증강은 두지 않는다.

고정 오탐률(fixed false-alarm-rate) 규율. 탐지 성격의 과제에서는 “검출률 몇 퍼센트”라는 숫자 자체를 최종 결과로 쓰지 않는다. 임계값을 낮추면 검출률은 누구나 올릴 수 있고 대가는 오탐이기 때문이다. 임계값은 간섭이 없는 학습 구간 통계에서 목표 오탐률을 만족하도록 역산하고, 그 임계값을 테스트 구간에 변경 없이 적용한다. 이는 레이더 신호처리의 표준 CFAR(constant false-alarm-rate) 규율을 그대로 따른 것이다.

오라클 대 순진한(naive) 기준선 구분. 채널추정 실험에서 실제로 마주친 문제인데, 딥러닝이 “이겼다”고 보인 사례 일부가 사실은 더 강한 고전 기준선(참 채널 통계를 아는 오라클급 MMSE)이 아니라 더 약한 기준선(순진한 최소자승, LS)과의 비교에서 나온 것이었다. 이 문제를 인지한 뒤로는 항상 고전 쪽에도 성능 사다리(순진한 방법부터 오라클급까지)를 두고, 어느 기준선 대비 승리인지를 명시한다.

합성 대 실측 데이터의 명시적 구분. 무선 신호를 실측하려면 실제 무선 하드웨어와 캡처 장비가 필요하고, 모든 과제에 그런 실측 캡처가 존재하지는 않는다. 합성 데이터로 얻은 결과는 그 자체로 무의미하지 않지만, 실측 결과와 같은 무게로 인용하지 않는다. 각 절에서 데이터 출처를 밝힌다.

GPU 실행이 완료되지 않은 항목은 결과로 인용하지 않는다. 코드와 실험 설계가 준비되었더라도 실제로 실행되어 완료된 결과 파일이 없으면 “미검증”으로 표시하고, 확정된 숫자처럼 서술하지 않는다.

4 과제별 결과

4.1 변조분류 — 고전이 이긴다

무선 변조 방식(BPSK, QPSK, 16QAM 등)을 신호 자체에서 분류하는 과제다. 표준 공개 벤치마크인 **RadioML2016.10a**의 6dB SNR 부분집합(11개 변조 클래스, 128샘플 IQ 창, 학습 539개/테스트 1,100개 고정 분할)에서 고전 방법(순시 진폭·위상, 반송파 주파수 오프셋, Swami-Sadler 고차 큐물런트 등 28차원 물리 특징 + 트리 앙상블 분류기)과 딥러닝(1.39M 파라미터 혼합전문가 트랜스포머, raw IQ 입력, 600에폭 수렴 학습)을 같은 학습/테스트 분할에서 비교했다.

방법	정확도(11-way)
LDA (28개 물리 특징)	0.668
RandomForest	0.840
XGBoost	0.848
LightGBM	0.855
CatBoost	0.848
딥러닝 (트랜스포머, 600에폭 수렴)	0.681
우연 수준	0.091

같은 28개 특징 위에서 최근의 모던 표(tabular) 학습 모델들과도 비교했다. TabPFN v2가 0.848로 근접했지만 LightGBM을 넘지 못했고, 딥 표 모델 계열(TabM 0.781, RealMLP 0.778)과 스택킹 앙상블(AutoGluon 0.818)도 그래디언트 부스팅 트리를 넘지 못했다. 이는 “더 나은 표 모델”이 답이 아니라, 이 데이터 규모에서는 그래디언트 부스팅 트리 앙상블 자체가 이미 포화 지점에 가깝다는 뜻이다.

데이터 규모를 늘리면 뒤집히는가. 딥러닝의 열세가 단순히 데이터 부족 때문이라면, 학습 데이터를 늘리면 역전될 것이라는 가설을 별도로 검증했다. 같은 6dB 데이터에서 학습 표본 수만 늘려 가며 재측정했다.

학습 표본 수	고전(LightGBM)	딥러닝(트랜스포머)	격차(딥러닝-고전)
539	0.728	0.368	-0.360
2,000	0.794	0.581	-0.213
5,000	0.814	미측정	-
9,900	0.844	미측정	-

측정된 전 구간에서 고전이 앞섰지만, 딥러닝은 데이터가 늘어날수록 빠르게 격차를 좁혔다(격차 -0.360 → -0.213). 고전 방법은 0.84 부근에서 완만하게 정체(plateau) 하는 양상을 보였고, 5,000개와 9,900개 지점의 딥러닝 재측정은 이 실험에서는 완료되지 않아 교차점이 실제로 존재하는지는 이 데이터 범위(≤9,900, 단일 SNR) 안에서는 관측되지 않았다. 정직하게 밝히자면, 이 표의 N=539 고전 정확도(0.728)는 바로 위 표의 같은 N=539 지점(0.855)과 다른 값이다. 두 실험은 같은 원본 데이터를 쓰지만 표본추출 절차가 달라 생긴 차이이며, 이 규모-교차 실험의 목적은 절대 정확도가 아니라 두 곡선의 상대적 기울기이므로 결론에는 영향을 주지 않는다.

별도로, 딥러닝 사전학습(마스킹된 IQ 구간 복원, 비지도)이 라벨이 적은 상황에서 도움이 되는지도 확인했다. 라벨 1%(99개)에서 무작위 초기화 0.212 대비 사전학습 0.273(+0.062), 라벨 10%(990개)에서 0.504 대비 0.554(+0.050)로 일관되게 소폭 도움이 되었으나, 전체 라벨(9,900개)에서는 오히려 무작위 초기화가 근소하게 앞섰다(0.797 대 0.787). 저라벨 국소 이득은 실재하지만, 이 결과가 위 6a 절의 전체 승패를 뒤집지는 않는다.




그림 1: 학습 데이터 규모에 따른 정확도

4.2 고정 오탐률 간섭탐지 — 고전이 구조적으로 유리하다

공장·의료기기 주변의 무선 간섭(재밍, 비인가 송신, 반송파 주파수 오프셋 등)을 탐지하는 과제에서, 진짜 승부는 정확도 숫자가 아니라 **오탐률이 실제로 고정되어 있는가**다. 두 개의 합성 벤치에서 이를 측정했다. 하나는 O-RAN/5G 스타일 다중 슬라이스 시나리오(개념 검증 수준, 표준 준수 검증 아님)이고, 다른 하나는 잡음 바닥 드리프트(noise-floor drift)를 의도적으로 주입해 오탐률 고정에 분포 변화 아래에서도 실제로 지켜지는지를 본 벤치다.

첫 번째 벤치에서 셀평균 CFAR(CA-CFAR)와 반송파 주파수 오프셋 추정기를 결합한 고전 탐지기는 목표 오탐률 5%(실측 오탐률 5.29%)에서 다음 검출률을 기록했다.

간섭 유형	검출률(Pd)	슬라이스 위치추정 정확도
광대역 재밍(barrage)	0.929	0.929
부분대역 재밍(25%)	0.986	0.991
단일 톤	1.000	1.000
반송파 주파수 오프셋만	1.000	1.000
전체	0.980	0.982 (우연 기준선 0.167)

이 벤치에는 딥러닝 대응 실험이 없어 고전 단독 수치다. 흥미롭게도 총 주입 전력이 가장 큰 광대역 재밍이 검출률이 가장 낮았다(0.929). 전력비 기반 CFAR 통계가 전 대역을 뒤덮는 재밍에서는 참조 셀(reference cell)의 잡음 추정치까지 함께 끌어올려 통계량이 압축되는, CFAR 계열에 잘 알려진 “마스킹” 현상이다.

두 번째 벤치는 실제 승부처를 보여준다. 여러 CFAR 변형(CA/OS/GO/SO-CFAR)과 제약 없는 이진 딥러닝 탐지기, 그리고 CFAR 제약을 학습에 명시적으로 반영한 학습형 탐지기(이하 제약형 딥러닝)를, 학습 시 보지 못한 강도 구간에서 재평가하고 12dB 잡음 바닥 드리프트를 추가로 주입해 목표 오탐률이 실제로 지켜지는지 측정했다.

방법	목표 오탐률 0.01에서 드리프트 후 실제 오탐률	목표 오탐률 0.001에서 드리프트 후 실제 오탐률
CA-CFAR	0.0	0.0
OS-CFAR	0.0	0.0
GO-CFAR	0.0	0.0
SO-CFAR	0.0	0.0
순환정상성(cyclostationary) 탐지기	0.100	0.007
제약 없는 이진 딥러닝 탐지기	1.000	1.000
CFAR 제약형 딥러닝(제약형)	0.040	0.003

이 표가 이 과제에서 고전 방법이 실제로 우위를 갖는 지점을 정확히 보여준다. CA/OS/GO/SO-CFAR 계열은 잡음 바닥이 12dB 나 흔들리는 조건에서도 목표 오탐률을 그대로 지켰다. 이는 CFAR라는 이름 자체가 약속하는 성질(오탐률을 일정하게 유지)이 재보정 없이도 구조적으로 성립함을 뜻한다. 반대로 제약 없는 이진 딥러닝 탐지기는 같은 드리프트 아래에서 목표 오탐률 0.01 짜리 임계값이 실제 오탐률 1.0으로 폭발했다. 모든 창을 간섭으로 판정한다는 뜻이며, 오탐률 보장이 완전히 무너졌다는 뜻이다. CFAR 규율을 손실 함수에 명시적으로 반영한 제약형 딥러닝은 그 중간 지점(0.04, 0.003)에 위치했다. 즉 “오탐률 고정”은 정확도 숫자 하나로 요약할 수 있는 성질이 아니라, 분포가 변해도 그 보장이 유지되는가를 따로 측정해야 하는 성질이며, 이 측정에서 순수한 고전 CFAR가 가장 강한 보장을 제공했다.

4.3 드론 무선신호 오픈셋 거부 — 저-K에서 고전이 이긴다

드론 조종신호를 탐지·식별하고, 학습 때 보지 못한 새로운 드론(미지 장치)을 거부하는 과제다. 공개 데이터셋 **DroneRF**(Al-Sa'd 등, Qatar University, Mendeley DOI 10.17632/f4c2b4n755, **CC BY 4.0** 라이선스로 상업적 인용 가능)를 이용해 고전 파이프라인(24차원 물리 특징: RSSI, 포락선 통계, 반송파 주파수 오프셋, 고차 큐물런트, 스펙트럴 형태 + LightGBM + 마할라노비스 거리 기반 오픈셋 거부)을 재구현하고, 같은 장르의 딥러닝 실험(ECAPA-TDNN 임베딩 + 대조학습, 다른 데이터셋인 CardRF 사용)과 같은 K(융합에 쓰는 관측 수) 스윙으로 비교했다.

K(융합 관측 수)	고전 미지 장치 거부율	고전 AUROC	딥러닝 미지 장치 거부율	딥러닝 AUROC
1	0.424	0.648	0.074	0.565
5	0.581	0.720	0.129	0.708
10	0.725	0.811	0.408	0.761
20	0.875	0.937	0.917	0.829
50	1.000	1.000	1.000	0.914




그림 2: 드론 오픈셋 거부: K=1

단일 관측(K=1, 융합 없음)에서 고전 방법의 미지 장치 거부율은 딥러닝의 5.7배였다. 딥러닝 임베딩은 단일 패킷에서는 사실상 신호를 뽑아내지 못했고(대조학습 손실이 붕괴한 상태), 24차원 손수 설계 특징은 단일 관측에서도 이미 유의미했다. K=5, 10 구간에서도 고전이 앞섰고, K=20에서는 딥러닝이 근소하게 우위(0.917 대 0.875)로 바뀌었으며, K=50에서는 둘 다 사실상 포화(1.0/1.0)됐다. 다만 K=20, 50 구간은 미지 표본 수가 40개, 16개로 작아 이 구간의 “동률”은 방법 우위의 증거로 읽기보다 표본 크기의 한계로 읽어야 한다.

정직한 비교 한계를 명시한다. 이것은 동일 데이터셋에서의 직접 A/B가 아니다. 고전 실험은 DroneRF(3종 드론, 2개 기지 클래스/1개 미지 클래스)를, 딥러닝 실험은 CardRF(6개 컨트롤러, 4개 기지/2개 미지, 동일 제조사 4종 포함)를 썼다. 과제의 장르(드론 무선신호 오픈셋 거부, 같은 마할라노비스 거부 레시피)는 같지만 데이터와 클래스 구조가 다르므로, “고전이 딥러닝을 이겼다”는 같은 장르 내 비교로 읽어야 하며 동일 데이터 위의 직접 대조는 아니다. 또한 이 고전 파이프라인은 세부 제조사

판별(3클래스 정확도 0.5685, 다수클래스 기준선 0.444)에서는 강하지 않았다. 존재/부재 판정과 오픈셋 거부에는 강하지만, 세밀한 제조사 구분에는 이 24차원 특징으로 부족했다는 뜻이다.

4.4 채널추정/등화 — 아직 결론이 나지 않았다

수신 신호에서 무선 채널의 영향을 추정하고 되돌리는 과제다. 이 과제는 이 논문에서 가장 정직하게 “모른다”고 말해야 하는 지점이다. 초기 실험은 채널 추정(NMSE 지표)과 전체 수신 성능(BER 지표)이라는 서로 다른 두 과제를 하나의 판정으로 섞었고, 딥러닝이 이긴 것으로 집계된 사례 일부가 실제로는 참 채널 통계를 아는 오라클급 MMSE와의 비교가 아니라 더 약한 순진한 최소자승(LS) 기준선과의 비교였다는 방법론 결함이 나중에 발견됐다. 그 결함이 있는 상태의 집계 결과는 99개 비교 조건 중 고전 승 37, 딥러닝 승 11, 동률 51이었으나, 이 숫자 자체를 결론으로 인용하지 않는다.

방법론을 고친 후속 설계(추정 과제와 수신 과제를 완전히 분리하고, 순진한 LS부터 오라클급까지 고전 성능 사다리를 두고, 8축 분포 밖(OOD) 매트릭스를 추가)은 코드까지 준비됐으나, 이 논문 작성 시점까지 실제 GPU 실행이 완료되지 않았다. 따라서 채널추정에서 고전과 딥러닝 중 무엇이 이기는지는 **미검증** 상태로 남긴다. 방향성 있는 짐작은 가능하지만(고전/오라클급 MMSE가 여전히 강할 것이라는 가설이 방법론 결함을 고친 재설계의 출발점이었다), 이것을 확정된 결과처럼 서술하지 않는 것이 이 논문의 원칙이다.

4.5 무선 지문(RF fingerprint) 융합 — 딥러닝이 이기지만, 여러 겹의 조건이 붙는다

같은 하드웨어가 만들어내는 미세한 아날로그 임퍼펙션(무선 지문)으로 장치를 인증하는 과제다. 공개 연구 데이터셋 **WiSig**(CC BY-NC-SA, 비상업·연구 목적 한정)에서 여러 패킷을 하나의 인증 결정으로 융합하는(K-패킷 융합) 방식으로 고전 특징(비지도, GPU 불필요, 설명 가능)과 학습형 임베딩(ECAPA-TDNN 계열, GPU 학습 필요)을 비교했다.

K(융합 패킷 수)	고전 AUROC	딥러닝 AUROC
1	0.549	0.696~0.739
10	0.766	미측정
20	0.863	미측정
50	0.945	0.9994
100	0.979	미측정

K=50 융합 기준으로 딥러닝이 고전 자체 기준선을 이겼다(0.9994 대 0.945). 그러나 이 승리에는 최소 세 겹의 조건이 붙는다.

첫째, 이 승리는 우리 자신의 K=50 고전 기준선 대비이며, 외부 문헌의 단일-결정 기준으로는 이기지 못한다. 단일 패킷(K=1, 융합 없음) 기준으로만 직접 비교 가능한 지점에서, 이 딥러닝 임베딩은 AUROC 0.696~0.739였다. 이는 문헌에서 보고된 참조치(엄격한 cross-receiver 오픈셋 기준 AUROC 0.9692)에 크게 못 미친다.

둘째, 이 K=50 수치는 사후 감사에서 방법론적 우려가 제기됐다. 융합에 쓰인 50개 관측이 서로 독립적인 50번의 인증 시도가 아니라, 같은 캡처 세션에서 나온 상관관계가 있는 연속 패킷일 가능성이 데이터 구조상 배제되지 않았다. 이 경우 0.9994는 “독립된 50번의 인증 결정”이 아니라 신호대잡음비가 누적된 “단일 세션 매칭”이라는, 훨씬 쉬운 과제의 상한일 수 있다.

셋째, 실제 접근제어(access control) 관점의 엄격한 운영점에서는 두 방법 모두 약하다. 침입자를 걸러내는 실제 보안 지표(오타를 0.1%에서의 탐지율, TAR@FAR=1e-3)로 보면, 자체 프로토콜 기준 K=1에서 0.16%, K=100에서도 43%에 머물렀다. 더 엄격한 세션 인증 제품형태 조건(등록/검증을 서로 다른 미지 장치·날짜로 분리)에서는 K=50 기준 TAR@FAR=1e-3이 22.35%로, 앞서 인용한 K=50 수치(87.65%)의 약 4분의 1에 그쳤다. 상업적으로 라이선스가 자유로운 독립 데이터셋(INRIA, CC BY)으로 일반화 검증을 해도 K=1 AUROC는 0.868로 분리성 자체는 나쁘지 않지만, 같은 엄격한 접근제어 지표(TAR@FAR=1e-3)는 2.9%에 그쳤다.

이 세 가지를 종합하면, “무선 지문 인식에서 딥러닝이 고전을 이겼다”는 문장은 벤치마크 총위(같은 방식으로 전 K=50 대 K=50)에서만 참이고, 외부 SOTA 단일-결정 기준이나 실제 보안 운영점 기준으로는 성립하지 않는다. 벤치마크 승리와 제품으로서의 성립은 다른 질문이며, 이 지점이 딥러닝의 승리 가운데 가장 조건이 많이 붙는 승리다.

4.6 동일 채널 신호분리 — 딥러닝이 명확하게 이긴다

주파수가 거의 겹치는 두 개의 무선 신호를 하나의 수신 신호에서 분리하는 과제다. 실제 다중 발신원 데이터셋(RFSS)의 라이선스가 명확하지 않아 학습에 쓰기에는 보수적으로 부적절하다고 판단해, 같은 문제 구조(두 개의 선형 변조 신호가 작은 반송파

주파수 오프셋으로 겹침, 신호대간섭비를 스위)를 자체 합성한 혼합 신호로 실험했다. 학습형 분리기는 음성 분리 아키텍처인 Conv-TasNet을 복소 IQ 입력에 맞게 조정된 구조(1차원 인코더 → 팽창 합성곱(dilated TCN) 분리기 → 마스크 → 디코더, 순열 불변 학습)이고, 고전 기준선은 단일 수신기의 I/Q 두 실수 채널을 두 개의 관측으로 취급한 FastICA(독립성분분석) + 힐베르트 변환이다.

GPU에서 완료된 실측 결과는 명확했다.

방법	SI-SDRi(dB, 높을수록 좋음)
고전(FastICA + 힐베르트 변환)	-14.25
딥러닝(Conv-TasNet 변형)	+3.01




그림 3: 동일 채널 신호분리: SI-SDRi

고전 방법은 분리 후 신호가 혼합 신호 자체보다도 나빠졌다(음수 SI-SDRi). 단일 수신기의 I/Q 두 채널을 두 개의 독립 관측으로 취급하는 것 자체가 2-소스 독립성분분석에 필요한 조건을 구조적으로 만족하지 못하기 때문이며, 이는 예상된 약점이지 실험 오류가 아니다. 딥러닝 분리는 혼합 신호 대비 확실한 개선(+3.01dB)을 보였다. 이 과제는 여섯 개 과제 가운데 딥러닝이 가장 조건 없이 이긴 지점이다. 다만 이 결과 역시 실제 다중 발신원 공개 데이터셋이 아니라 같은 구조의 합성 혼합 신호에서 얻은 것이라는 점은 분명히 밝힌다.

5 종합 결정 지도

여섯 개 과제를 한 장으로 요약하면 다음과 같다.

과제	데이터	승자	비고
변조분류	실측 공개 (RadioML2016.10a)	고전	데이터 9,900개까지 뒤집히지 않음
고정 오탐률 간섭탐지	합성	고전	오탐률 보장이 드리프트에서도 유지
드론 오프셋 거부(저-K)	실측 공개 (DroneRF/CardRF, 장르 비교)	고전	K≥20에서는 딥러닝이 근소 우위
채널추정/등화	실측+합성 혼합	미검증	방법론 결함 있는 초기 결과만 존재
무선 지문 융합	실측 공개(WiSig, 비상업)	딥러닝(다중 조건)	외부 SOTA·실제 보안 지표로는 역전
동일 채널 신호분리	합성(자체)	딥러닝	가장 조건 없는 딥러닝 승리

이 지도에서 읽어야 할 것은 “고전이 3승, 딥러닝이 2승, 1무승부”라는 스코어보드가 아니다. 승패를 가른 것은 각 과제의 **구조**였다. 학습 데이터가 작고(수백~수천 표본) 물리적으로 해석 가능한 특징이 존재하는 과제(변조분류, 간섭탐지, 드론 오프셋)에서는 고전이 유리했다. 신호에 정답이 되는 결정론적 물리 모델이 아니라 학습된 표현이 필요한, 데이터가 풍부하고 표현 학습 자체가 과제인 경우(동일 채널 신호분리, 무선 지문의 미세한 하드웨어 서명)에서는 딥러닝이 유리했다. 채널추정처럼




그림 4: 과제별 최고 성능: 고전 대 딥러닝

아직 공정한 실험이 끝나지 않은 과제는 정직하게 미검증으로 남긴다. “딥러닝이 신호처리 전반에 걸쳐 고전을 대체한다”는 명제는 이 여섯 개 과제의 실측 근거로는 지지되지 않는다.

6 한계

이 논문의 결론에는 명시적으로 짚어야 할 한계가 있다.

1. 간섭탐지, 간섭 위치추정, O-RAN/5G 시나리오는 전부 합성 데이터다. 실제 전파 환경의 다중경로, 상관된 그림자감쇄(shadowing), 실제 표준 프로토콜 연동은 반영되지 않았다. 이 절의 수치는 개념 검증 수준으로 읽어야 한다.
2. 동일 채널 신호분리는 실제 다중 발신원 공개 데이터셋이 아니라 같은 문제 구조를 자체 합성한 혼합 신호에서 얻었다. 실제 데이터셋의 라이선스가 불명확해 보수적으로 학습에 사용하지 않았다.
3. 무선 지문 융합의 핵심 데이터셋(WiSig)은 비상업·연구 목적 한정 라이선스다. 이 절의 수치는 벤치마크 근거로는 유효하나, 그대로 상업 제품 근거 자료로 인용할 수 없다.
4. 드론 오픈셋 비교는 동일 데이터셋 위의 직접 A/B가 아니라, 같은 장르의 서로 다른 데이터셋(고전=DroneRF, 딥러닝=CardRF) 간 비교다. 완전한 대조를 위해서는 두 방법을 같은 데이터셋에서 재실행해야 한다.
5. 채널추정은 방법론 결함이 발견된 초기 실험 외에 확정된 결과가 없다. 방법론을 고친 재설계는 코드까지 준비했으나 이 논문 작성 시점까지 실행이 완료되지 않았다.
6. 무선 지문의 K=50 융합 수치는 사후 감사에서 세션 간 상관 가능성이 제기됐다. 독립적인 50회 관측이 아니라 상관된 연속 패킷일 가능성을 완전히 배제하지 못한 상태다.

7 데이터와 재현

이 논문에서 인용한 공개 데이터셋은 다음과 같다.

- **RadioML2016.10a** — 표준 변조분류 벤치마크(O’Shea & West). 6dB SNR 부분집합, 11개 클래스.
- **DroneRF** — Al-Sa’d 등, Qatar University, Mendeley DOI 10.17632/f4c2b4n755, **CC BY 4.0**(상업적 인용 가능, 출처 표시 조건).
- **WiSig** — 무선 지문 연구용 다중 수신기 공개 데이터셋, **CC BY-NC-SA**(비상업·연구 목적 한정).
- **INRIA 데이터셋** — 무선 지문 독립 일반화 검증에 사용, **CC BY**(상업 인용 가능).
- **CardRF** — 드론 컨트롤러 무선신호 데이터셋, 연구 목적 한정(라이선스 미검증, 상업 인용 시 자체 캡처 권장).

모든 실험은 고정 시드로 재현 가능하게 설계했고, 승패 판정은 사람이나 모델의 자기 보고가 아니라 코드가 계산한 지표(정확도, AUROC, macro-F1, SI-SDR, 실측 오류율)로만 확정했다. 방법론 결함이 발견된 실험(채널추정 v1, 초기 간섭탐지 스모크)은 그 결함의 성격까지 함께 기록해, 같은 실수를 반복하지 않도록 했다.

8 참고문헌

1. O’Shea, T. J., West, N. (2016). Radio Machine Learning Dataset Generation with GNU Radio. Proceedings of the GNU Radio Conference (RadioML2016.10a 데이터셋).
2. Swami, A., Sadler, B. M. (2000). Hierarchical digital modulation classification using cumulants. IEEE Transactions on Communications, 48(3), 416-429.

3. Al-Sa'd, M. F. et al. (2019). RF-based drone detection and identification using deep learning approaches: An initiative towards a large open source drone database. *Future Generation Computer Systems*, 100, 86-97 (DroneRF 데이터셋, Mendeley DOI 10.17632/f4c2b4n755, CC BY 4.0).
4. Rohling, H. (1983). Radar CFAR thresholding in clutter and multiple target situations. *IEEE Transactions on Aerospace and Electronic Systems*, AES-19(4), 608-621.
5. Skolnik, M. I. *Introduction to Radar Systems*, 3rd ed., McGraw-Hill, chapter 6 (검출 이론과 CFAR).
6. Moose, P. H. (1994). A technique for orthogonal frequency division multiplexing frequency offset correction. *IEEE Transactions on Communications*, 42(10), 2908-2914.
7. Luo, Y., Mesgarani, N. (2019). Conv-TasNet: Surpassing ideal time-frequency magnitude masking for speech separation. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 27(8), 1256-1266.
8. Le Roux, J. et al. (2018). SDR-half-baked or well done? *Proceedings of ICASSP 2019* (SI-SDR 지표).
9. arXiv:2607.02567 — cross-receiver open-set 무선 지문 인식 참조치 (CRODA-ST, strict cross-rx open-set AUROC 0.9692).