

고전 특징 기반 설비 예측정비: 진동과 음향

해석 가능한 고전 특징 + GBM으로 회전설비 이상을 잡는다, 진동은 실측·음향은 합성 검증

2i

2026-07-29

초록

회전설비(베어링, 펌프, 모터)의 결함을 조기에 잡아내는 예측정비(predictive maintenance, PdM) 문제를 딥러닝이 아니라 고전적인 신호처리 특징과 그래디언트 부스팅 모델로 풀 수 있는지를 실측했다. 진동 신호는 공개 표준 베어링 결함 데이터셋(CWRU, Case Western Reserve University Bearing Data Center)의 실제 12kHz 가속도계 측정치를 사용했고, 음향 신호는 아직 실제 마이크 녹음을 확보하지 못해 절차적으로 합성한 데이터를 사용했다. 이 둘을 같은 논문엔 나란히 두는 이유는 방법론이 동일하기 때문이다. 포락선 스펙트럼(envelope spectrum), 캡스트럼, 웨이블릿 대역 에너지 같은 물리 기반 특징을 추출해 LightGBM으로 분류하고, 단순 시간영역 통계량만 쓰는 베이스라인과 비교했다. 진동 실측에서는 깨끗한 신호에서 두 접근 모두 정확도 1.000을 기록했지만, 신호 대 잡음비(SNR)를 -5dB까지 낮추자 전체 특징 세트는 0.636을 유지한 반면 단순 베이스라인은 0.186까지 무너졌다. 음향 합성 데이터에서도 같은 패턴이 재현됐다. 5종 결함 분류에서 전체 특징(133개) 정확도는 클린 0.903, -5dB 0.492였고, RMS 하나만 쓰는 베이스라인은 클린 0.312, -5dB 0.302로 애초에 쓸 만한 신호를 갖지 못했다. 별도로, 고정 오탐률(fixed false-alarm-rate) 이상탐지 방식인 CA-CFAR(cell-averaging constant false-alarm-rate)를 합성 무선 간섭탐지 벤치에서 검증해 목표 오탐률 5%를 실측 5.29%로 거의 정확히 지켰고, 그 조건에서 검출률 98.0%를 얻었다. 이 논문의 핵심 주장은 정확도 숫자 자체가 아니라, 물리 기반 고전 특징이 잡음 앞에서 왜 더 우아하게 무너지는지, 그리고 그것이 실제 현장 조건에서 왜 중요한지에 있다. 음향 결과는 반드시 합성 데이터로 얻은 것으로 표시하며, 실제 산업 음향 공개 데이터셋 MIMII를 이용한 검증이 다음 단계임을 명시한다.

목차

1	요약	3
2	배경	3
3	방법	3
3.1	진동 및 음향 특징 파이프라인	3
3.2	고정 오염률 이상탐지: CA-CFAR	4
4	데이터와 설정	4
4.1	진동 데이터셋 - 실측 (CWRU)	4
4.2	음향 데이터셋 - 합성, 실측 아님 (MIMII가 다음 단계)	4
4.3	고정 오염률 검증 데이터셋 - 합성 (별도 도메인)	5
5	결과	5
5.1	진동(CWRU, 실측): 깨끗한 데이터에서는 차이가 없다	5
5.2	진동(CWRU, 실측): 잡음이 진짜 승부처다	5
5.3	음향(합성): 같은 패턴, 다른 데이터	6
5.4	실측 대 합성: 나란히 놓고 정직하게 비교	6
5.5	고정 오염률 이상탐지 (CA-CFAR, 별도 합성 도메인)	7
6	한계	7
7	데이터와 재현	7
8	참고문헌	8

1 요약

회전설비(베어링, 펌프, 모터)의 결함을 조기에 잡아내는 예측정비(predictive maintenance, PdM) 문제를 딥러닝이 아니라 고전적인 신호처리 특징과 그래디언트 부스팅 모델로 풀 수 있는지를 실측했다. 진동 신호는 공개 표준 베어링 결함 데이터셋(CWRU, Case Western Reserve University Bearing Data Center)의 실제 12kHz 가속도계 측정치를 사용했고, 음향 신호는 아직 실제 마이크 녹음을 확보하지 못해 절차적으로 합성한 데이터를 사용했다. 이 둘을 같은 논문에 나란히 두는 이유는 방법론이 동일하기 때문이다. 포락선 스펙트럼(envelope spectrum), 캡스트럼, 웨이블릿 대역 에너지 같은 물리 기반 특징을 추출해 LightGBM으로 분류하고, 단순 시간영역 통계량만 쓰는 베이스라인과 비교했다. 진동 실측에서는 깨끗한 신호에서 두 접근 모두 정확도 1.000을 기록했지만, 신호 대 잡음비(SNR)를 -5dB까지 낮추자 전체 특징 세트는 0.636을 유지한 반면 단순 베이스라인은 0.186까지 무너졌다. 음향 합성 데이터에서도 같은 패턴이 재현됐다. 5종 결함 분류에서 전체 특징(133개) 정확도는 클린 0.903, -5dB 0.492였고, RMS 하나만 쓰는 베이스라인은 클린 0.312, -5dB 0.302로 애초에 쓸 만한 신호를 갖지 못했다. 별도로, 고정 오탐률(fixed false-alarm-rate) 이상탐지 방식인 CA-CFAR(cell-averaging constant false-alarm-rate)를 합성 무선 간섭탐지 벤치에서 검증해 목표 오탐률 5%를 실측 5.29%로 거의 정확히 지켰고, 그 조건에서 검출률 98.0%를 얻었다. 이 논문의 핵심 주장은 정확도 숫자 자체가 아니라, 물리 기반 고전 특징이 잡음 앞에서 왜 더 우아하게 무너지는지, 그리고 그것이 실제 현장 조건에서 왜 중요한지에 있다. 음향 결과는 반드시 합성 데이터로 얻은 것으로 표시하며, 실제 산업 음향 공개 데이터셋 MIMII를 이용한 검증이 다음 단계임을 명시한다.

2 배경

설비 예측정비는 산업 AI에서 가장 오래된 응용 분야 중 하나이면서 동시에 가장 자주 과대포장되는 분야다. 베어링이나 기어의 초기 결함은 진동과 소음에 물리적으로 특정한 흔적을 남긴다. 베어링의 외륜, 내륜, 볼에는 각각 기하학적으로 계산 가능한 특성 주파수(BPFO, BPFI, BSF, FTF)가 있고, 결함이 생기면 회전할 때마다 그 주파수에서 충격이 반복된다. 이 물리는 40년 넘게 축적된 회전기계 진단 문헌에서 이미 잘 정리되어 있다. Randall과 Antoni가 정리한 포락선 스펙트럼 분석은 지금도 베어링 제조사들이 현장에서 쓰는 산업 표준 진단 기법이다.

그렇다면 왜 딥러닝이 아니라 고전 방법으로 접근하는가. 이 문제는 표현 학습(representation learning)이 필요한 문제가 아니라, 이미 물리적으로 잘 알려진 신호 패턴을 잘 뽑아내는 특징 공학(feature engineering) 문제에 가깝다. 여기에는 세 가지 현실적인 이유가 있다.

첫째, 해석 가능성이다. 현장 엔지니어와 설비 관리자는 “모델이 왜 이상이라고 판단했는가”라는 질문에 답할 수 있어야 한다. 포락선 스펙트럼에서 외륜 결함 주파수 대역의 에너지가 튀었다는 설명은 즉시 이해되고 검증 가능하다. 딥러닝 임베딩이 왜 그런 판단을 내렸는지는 설명하기 훨씬 어렵다.

둘째, 비용이다. LightGBM 같은 그래디언트 부스팅 모델은 학습과 추론 모두 CPU에서 수십 초 안에 끝난다. GPU도, 대규모 라벨링된 학습 데이터셋도 필요 없다. 설비 한 대, 센서 한 개 단위로 배포해야 하는 산업 현장에서는 이 비용 차이가 프로젝트의 실현 가능성 자체를 가른다.

셋째, 엣지 배포 가능성이다. 특징 추출과 트리 기반 모델은 저전력 엣지 디바이스에서 실시간으로 돌릴 수 있다. 반면 딥러닝 기반 접근은 대체로 더 무겁고, 엣지에서 안정적으로 돌리려면 양자하나 프루닝 같은 추가 작업이 필요하다.

이 논문은 위 주장을 산문으로만 펴지 않고, 실제로 파이프라인을 끝까지 돌려서 숫자로 검증한다. 그리고 그 숫자가 어디까지 진짜이고 어디부터 합성인지를 정직하게 구분한다.

3 방법

3.1 진동 및 음향 특징 파이프라인

진동과 음향 두 모달리티에 같은 설계 철학을 적용했다. 원시 파형에서 물리적으로 의미 있는 특징을 뽑아내고, 이를 가벼운 트리 앙상블 모델에 넣는다.

포락선 스펙트럼(envelope spectrum). 힐베르트 변환으로 신호의 포락선을 구하고, 그 포락선의 FFT에서 베어링 결함 주파수(BPFO/BPFI/BSF/FTF) 대역의 에너지 비율을 읽어낸다. 이 대역은 각 신호의 실측 회전속도(RPM)와 베어링 기하 정수(볼 개수, 접촉각, 피치 지름 비)로부터 계산한다. 이것이 국소 결함이 매 회전마다 반복하는 충격 신호의 주기적 진폭 변조를 직접 잡아내는, 진동·음향 예측정비의 핵심 특징이다.

캡스트럼(cepstrum). 실수 캡스트럼의 앞쪽 비-DC 계수를 뽑는다. 캡스트럼은 스펙트럼의 로그를 다시 푸리에 변환한 것으로, 주파수 영역에서 규칙적으로 반복되는 하모닉 구조(기어 물림, 회전 주기성)를 압축해서 표현한다.

웨이블릿 대역 에너지. 도비시(Daubechies) db4 웨이블릿으로 4레벨 분해해 각 대역 (근사 A4, 상세 D4/D3/D2/D1)의 에너지 비율을 특징으로 쓴다. 웨이블릿은 시간-주파수 지역화가 필요한 과도(transient) 성분, 즉 충격성 결함 신호를 잡는 데 강점이 있다.

음향 전용 특징. 음향 모달리티는 공중 전파 마이크 신호이므로 진동과 다른 보완적 특징을 추가한다. 로그-멜 밴드 에너지, MFCC(멜 주파수 캡스트럼 계수), 스펙트럴 중심·롤오프·평탄도·커토시스 같은 스펙트럼 형태 특징이다. STFT, 멜 필터뱅크, MFCC는 별도 오디오 라이브러리 없이 NumPy/SciPy로 직접 구현했다.

시간영역 통계. RMS, 표준편차, 커토시스, 스큐니스, 크레스트 팩터, 피크투피크 등 전통적인 진동 모니터링 지표도 함께 넣는다. 다만 비교 실험에서는 이 시간영역 통계 “만” 쓰는 극단적으로 단순한 베이스라인을 따로 구성해, 물리 기반 특징이 실제로 얼마나 더 벌어주는지를 분리해서 본다.

모델은 **LightGBM**(`n_estimators=200`, `max_depth=5`)을 지도학습 분류에, 비지도 이상탐지에는 **IsolationForest**를 정상 데이터만으로 학습시켜 사용했다. 둘 다 CPU에서 수십 초 내에 학습이 끝나는 경량 모델이다.

3.2 고정 오탐률 이상탐지: CA-CFAR

산업 신호 모니터링에서 “검출률 몇 퍼센트”라는 숫자는 그 자체로는 의미가 없다. 임계값을 낮추면 검출률은 누구나 올릴 수 있고, 그 대가는 오탐이다. 오탐이 잦은 경보 시스템은 현장에서 꺼진다. 그래서 산업 신호 모니터링에서는 오탐률을 먼저 고정하고, 그 조건에서 검출률을 보고하는 것이 유일하게 정직한 화법이다.

이를 위해 표준 레이더 신호처리 기법인 **셀평균 CFAR(CA-CFAR, cell-averaging constant-false-alarm-rate)**를 적용했다. CA-CFAR는 검사 대상 셀 주변의 참조 셀(reference cell)들로 배경 잡음 수준을 추정하고, 그 추정치에 대한 상대 비율로 임계값을 정한다. 임계값은 잡음만 있는(간섭이 없는) 학습 구간에서 목표 오탐률(Pfa)을 만족하도록 역산하고, 그 임계값을 테스트 구간에 그대로, 사후 조정 없이 적용한다. 이것이 CFAR 방식이 다른 임계값 기법과 구분되는 핵심 규율이다: 라벨을 보고 임계값을 다시 맞추지 않는다.

4 데이터와 설정

4.1 진동 데이터셋 - 실측 (CWRU)

Case Western Reserve University Bearing Data Center의 공개 베어링 결함 데이터셋을 사용했다. 이 데이터셋은 학계에서 베어링 결함 진단 연구의 표준 벤치마크로 널리 쓰인다.

- 센서: 드라이브측 가속도계, 6205-2RS JEM SKF 딥그루브 볼베어링, 샘플링 레이트 12kHz.
- 4개 클래스(정상, 내륜 결함, 볼 결함, 외륜 결함, 모두 0.007인치 단일점 방전가공 결함) × 4개 부하/RPM 조건 = 16개 원시 파일.
- 부하 0/1/2/3hp에 각각 명목 RPM 1797/1772/1750/1730이 대응한다.
- 데이터셋 자체의 알려진 특이사항 두 가지를 코드에서 명시적으로 처리했다. 파일 하나(98번)는 RPM 필드가 없어 명목 RPM으로 대체했고, 각 파일의 신호와 RPM 변수는 정확한 키(`X0{id}_DE_time`, `X0{id}RPM`) 매칭으로 골라내 인접 파일의 구조체가 잘못 섞여 들어가지 않도록 했다.
- **누수 없는 분리:** 윈도우 단위가 아니라 부하 조건 단위로 학습/테스트를 나눴다. 학습은 0/1/2hp(12개 파일), 테스트는 학습에서 전혀 보지 못한 3hp(4개 파일)다. 같은 연속 녹음에서 뽑은 인접 윈도우를 학습과 테스트에 함께 넣는 흔한 벤치마킹 오류를 피했다.
- 2048샘플(약 171ms) 길이의 비중첩 윈도우 1,537개(학습 1,122 / 테스트 415)를 구성했다.

4.2 음향 데이터셋 - 합성, 실측 아님 (MIMII가 다음 단계)

이 실험을 위해 다운로드하거나 사용한 실제 마이크 녹음은 없다. 모든 클립은 회전기계 음향 물리를 절차적으로 합성한 것이다.

- 축 회전 기본 주파수(25~60Hz, RPM 1500~3600 대응)와 2~4차 하모닉.
- 기어 물림 톤(치수는 샘플마다 20~40개로 무작위화).
- 표준 9볼 딥그루브 베어링 기하(CWRU 6205 시험 베어링과 같은 기하 계열의 공식만 재사용, CWRU 데이터나 녹음은 전혀 사용하지 않음)로 계산한 BPFO/BPFI/BSF 결함 차수.
- 결함 신호는 구조적 공진 캐리어에 대한 진폭변조(AM) 측파대로 구현했다. 외륜 결함은 BPFO에서, 내륜 결함은 BPFI와 1x에서 이중 변조(내륜 특유의 부하영역 신호), 기어 마모는 기어 물림 톤에 1x 측파대, 불균형은 측파대 없이 1x/2x

진폭만 증가시키는 방식이다. 이는 회전기계 진단 문헌에서 문서화된 표준 구분 신호이며, 클래스마다 임의로 만든 잡음이 아니다.

- 배경에는 광대역 가우시안 잡음과 무작위 HVAC/팬 톤 잡음을 더했다.
- 샘플마다 RPM, 부하, 마이크 거리(거리 감쇠와 거리 의존 저역통과), SNR을 무작위화했다.

5개 클래스(정상, 외륜 결함, 내륜 결함, 기어 마모, 불균형), 클래스당 300클립으로 70/30 계층 분리한 학습/테스트 세트(총 1,500클립)를 구성했고, 잡음 강건성 테스트를 위해 고정 SNR 조건에서 클래스당 100클립씩 별도 세트 두 개를 추가했다.

정직한 실측 후속 계획: MIMII(Purohit et al., 실제 공장에서 녹음한 팬·펌프·슬라이더·밸브 음향에 이상 라벨이 붙은 데이터셋, CC-BY-4.0, zenodo.org/record/3384388)나 DCASE Task2(산업 기계 이상 탐지 태스크)가 이 특징+GBM 파이프라인을 실제 마이크 녹음으로 검증할 다음 단계다. 이 실험은 파이프라인이 물리적으로 타당하고 동작한다는 것을 보여줄 뿐, 실제 기계를 측정했다고 주장하지 않는다.

4.3 고정 오염률 검증 데이터셋 - 합성 (별도 도메인)

CA-CFAR 기반 고정 오염률 탐지는 회전설비 데이터가 아니라 별도의 합성 무선 간섭탐지 벤치에서 검증했다. 이는 방법론(참조 셀 대비 임계값 역산)이 신호 모니터링 일반에 적용되는 범용 기법임을 보이기 위한 것이며, 이 논문의 진동·음향 예측정비 결과와는 독립된 데이터셋임을 명시한다. 4가지 유형의 간섭(광대역 잡음, 부분대역 재밍, 단일톤, 반송파 주파수 오프셋)을 물리 모델로 합성해 4,000회 시행, 6개 슬라이스(24,000개 윈도우)로 구성했고, 목표 오염률 5%로 학습 구간의 무간섭 데이터에서 임계값을 역산한 뒤 테스트 구간에 변경 없이 적용했다.

5 결과

5.1 진동(CWRU, 실측): 깨끗한 데이터에서는 차이가 없다

held-out 부하(3hp) 테스트에서 4클래스 결함 분류 정확도는 전체 특징(35개)과 단순 베이스라인(4개, RMS/표준편차/커토시스/크레스트팩터) 모두 **1.000**을 기록했다. 비지도 이상탐지(정상 데이터만으로 학습한 IsolationForest)의 AUROC도 전체 특징 1.000, 단순 베이스라인 0.998로 거의 동일했다. CWRU의 0.007인치 단일 심도 결함 분류는 학계에서 이미 “너무 쉬운” 벤치마크로 알려져 있고, 이 결과가 그것을 재확인한다. 즉 클린 데이터에서의 완벽한 점수는 그 자체로 의미 있는 차별점이 아니다.

정직한 질문은 이것이다. 어느 특징 세트가 실제로 복잡성을 정당화하는가.

5.2 진동(CWRU, 실측): 잡음이 진짜 승부처다

클린 데이터로 학습한 고정 모델에, held-out 부하 조건의 테스트 윈도우에 백색 가우시안 잡음을 주입해 SNR을 단계적으로 낮추고 같은 모델/스케일러로 재평가했다.

SNR (dB)	전체 특징 (35개) 정확도	단순 베이스라인 (4개) 정확도
20	0.990	1.000
10	0.855	1.000
5	0.855	0.867
0	0.851	0.520
-5	0.636	0.186

이 표가 이 논문의 실제 발견이다. 높은 SNR에서는 4개 특징만 쓰는 단순 베이스라인이 오히려 살짝 더 낫다. 결정 경계가 더 단순해서 과적합할 것이 적기 때문이다. 그러나 SNR 5dB 아래로 내려가면 붕괴한다. 0dB에서 0.520, -5dB에서 0.186까지 떨어져 4클래스 기준 우연 수준(0.25)에 가까워진다. 반면 전체 35개 특징 세트는 0dB에서 0.851, -5dB에서 0.636으로 훨씬 우아하게 퇴화한다.

이 차이의 원인은 명확하다. 포락선 스펙트럼과 캡스트럼 특징은 결함의 **주기적, 협대역** 신호를 잡아내는데, 이런 신호는 광대역 가산 잡음에 상대적으로 강하게 버틴다. 반면 원시 시간영역 통계(크레스트팩터, 커토시스)는 잡음 샘플 하나하나에 직접적으로, 강하게 흔들린다. 이것이 정확히 회전기계 진단 문헌이 수십 년간 포락선 분석을 옹호해온 근거이며, 예측정비에서 고전 특징 공학이 실제로 값을 내는 지점이다. **깨끗한 실험실 데이터에서의 정확도가 아니라, 현실적인 현장 잡음 아래에서의 강건성이 진짜 가치다.**




그림 1: 잡음 강건성 곡선

5.3 음향(합성): 같은 패턴, 다른 데이터

음향 합성 데이터에서도 5개 시드에 대한 평균±표준편차로 같은 패턴이 재현됐다.

5클래스 결함 분류.

특징 세트	테스트 정확도	Macro-F1
전체 특징(133개)	0.790 ± 0.014	0.788 ± 0.014
RMS 단일 베이스라인(1개)	0.333 ± 0.017	-

5클래스 우연 수준은 0.20이다. 전체 특징 세트는 이를 4배 웃돌지만, RMS 하나만 쓰는 베이스라인은 우연 수준을 겨우 넘는다. RMS는 결함이 만드는 진폭 변화와 무작위화된 부하/거리/SNR 잡변수를 뒤섞어버려서, 결함 종류가 아니라 대체로 “크게 들리나 작게 들리나”만 가른다.

비지도 이상탐지. 정상 데이터만으로 학습한 IsolationForest의 AUROC는 **0.645 ± 0.022**였다. 우연 수준(0.5)은 확실히 넘지만, 진동/CWRU 스크립트가 도달한 거의 천장 수준의 AUROC에는 크게 못 미친다. 이는 예상된 결과다. 합성 음향 결함은 의도적으로 더 미묘하게(공유된 광대역 배경 잡음 속에 묻힌 AM 측파대) 설계했기 때문이다. 이것은 정직하고 포화되지 않은 수치이며, 골라낸 좋은 숫자가 아니다.

잡음 강건성.

조건	전체 특징(133개) 정확도	RMS 단일 베이스라인 정확도
클린 (SNR 25dB)	0.903 ± 0.015	0.312 ± 0.020
저SNR (SNR -5dB)	0.492 ± 0.016	0.302 ± 0.012




그림 2: 음향

간극이 핵심이다. 깨끗한 SNR에서는 전체 특징 세트가 베이스라인의 거의 3배(0.90 대 0.31)다. RMS 단일 베이스라인은 SNR 수준과 거의 무관하게 우연 수준 근처에 평평하게 머문다. 애초에 쓸 만한 신호를 가진 적이 없었기 때문이다. RPM, 부하, 거리가 함께 무작위화된 상태에서 하나의 소리 크기 스칼라만으로는 5개의 서로 다른 음향적 결함 기전을 구분할 수 없다. 전체 특징 세트의 정확도는 -5dB에서 대략 반으로 줄어든다 (0.90 → 0.49). 멜/MFCC/스펙트럼 대역이 배경 잡음에 잠기고




그림 3: 클린 대비 저SNR 성능

5.5 고정 오염률 이상탐지 (CA-CFAR, 별도 합성 도메인)

CA-CFAR 기반 탐지기를 목표 오염률 5%로 학습 구간의 무간섭 null 데이터에서 임계값을 역산하고 테스트 구간에 그대로 적용했다. 테스트 구간의 무간섭 윈도우에서 실측된 오염률은 **5.29%**로, 목표에서 크게 벗어나지 않았다. 이 조건에서 4가지 간섭 유형에 대한 전체 검출률(Pd)은 **0.980**, 슬라이스 위치추정 정확도는 **0.982**였다 (무작위 추측 기준선 0.167). 이 결과는 회전설비 데이터가 아니라 별도의 합성 무선 간섭탐지 벤치에서 얻은 것이며, 고정 오염률 프레임워크가 산업 신호 모니터링 일반에 적용 가능한 범용 기법임을 보이는 보조 증거로 제시한다.

6 한계

정직한 한계를 숨기지 않는다.

- 음향 결과는 전부 합성이다.** 이것이 이 논문에서 가장 크고, 가리기 어려운 한계다. 물리(결함 차수 AM 측파대, 기어 물림 변조, 불균형 하모닉 우세)는 교과서에 충실하지만, 실제 기계 음향은 절차적 합성기가 담아내지 못하는 구조적 공진, 반사, 다중 소음원 간섭, 비-가우시안 배경 잡음을 함께 지닌다. **MIMI나 DCASE Task2 실측 녹음 검증은 이 파이프라인의 필수 다음 단계이며, 그 전까지 이 논문의 음향 정확도 숫자를 현장 성능의 대표값으로 취급해서는 안 된다.**
- 단일 데이터셋, 단일 베어링, 단일 결함 심도.** CWRU는 학계 표준 벤치마크지만 하나의 베어링 모델/기하와 방전가공으로 만든 실험실 결함이다. 실제 설비군은 다양한 베어링 종류와 혼합된 결함 심도, 방전가공처럼 순간적이지 않고 자연스럽게 진행되는 결함을 갖는다.
- 센서 통합이 없다.** 이 실험은 사전 녹음된 파일을 소비할 뿐이다. 실제 제품에는 실제 가속도계/마이크 데이터 경로(엠티 샘플링, 안티앨리어싱, 부차 위치 일관성)가 필요하다. 부차 위치는 진동 전달 경로를 물리적으로 바꾸는, 진동 예측정비의 잘 알려진 현장 실패 요인이다.
- 기계별 캘리브레이션이 없다.** 포락선 결함 특징은 기계/순간마다의 RPM과 베어링 기하를 안다고 가정한다. 실제 제품은 타코미터 신호나 진동 신호 자체에서의 오더 트래킹, 그리고 설치마다 다른 "정상" 기준선을 잡는 캘리브레이션 단계가 필요하다.
- 런투페일러(run-to-failure) 조기경보 검증이 없다.** 이 실험은 고정 심도에서의 결함-대-정상 분류이며, 예측정비의 실제 가치인 "충분한 리드타임을 두고 저하를 포착했는가"를 검증하지 않는다. 이는 런투페일러 추세 데이터(예: IMS/FEMTO 베어링 데이터셋)를 이용한 후속 실험이 필요한 별개의 문제다.
- 잡음 모델이 합성이다(진동에서도).** 백색 가우시안 잡음은 현실적인 강건성 시험을 위한 첫 근사일 뿐이다. 실제 현장 잡음은 구조적 공진, 전기적 간섭, 다른 회전설비에서 나오는 비정상(non-stationary) 배경음을 포함한다. 더 현실적인 강건성 시험은 백색 가우시안이 아니라 실측 공장 배경 잡음을 주입하는 것이다.

이 가운데 어느 것도 딥러닝이 필요한 문제가 아니다. 모두 센서 통합, 기하 일반화, 장기 데이터 확보의 문제이며, 이는 이 논문 전체의 고전 우선(classical-first) 접근과 일관된다.

7 데이터와 재현

진동(CWRU) - 실측, 재현 가능. engineering.case.edu에서 공개 배포하는 원본 .mat 파일을 직접 내려받아 사용했다 (미러나 스크래핑 없음). CWRU Bearing Data Center 이용약관에 따라 학술/연구 목적 무료 이용이 가능하다. 센서는 드라 이브측 가속도계, 6205-2RS JEM SKF 딥그루브 볼베어링, 12kHz 샘플링이다. 재현 시 부하 조건 단위 분리(0/1/2hp 학습, 3hp 테스트)를 반드시 지켜야 하며, 윈도우 단위로 무작위 분리하면 누수가 발생해 부풀려진 결과를 얻는다.

음향 - 합성, 코드 공개. 실제 녹음을 전혀 사용하지 않았으므로 데이터셋 링크가 없다. 대신 합성 절차(회전 기본 주파수, 기어 물림, 베어링 결함 차수, AM 변조 방식, 배경 잡음 모델)를 위 3.2절에 재현 가능한 수준으로 기술했다. 실측 검증을 원하는 독자는 MIMII(zenodo.org/record/3384388, CC-BY-4.0) 또는 DCASE Task2 데이터셋으로 같은 특징 추출 및 분류 파이프라인을 재실행할 수 있다.

고정 오탐률(CA-CFAR) - 합성, 별도 도메인. 회전설비 데이터와 무관한 합성 무선 간섭탐지 벤치에서 얻은 보조 결과이며, 참조 셀 기반 임계값 역산이라는 방법론의 일반적 적용 가능성을 보이는 목적으로만 인용해야 한다.

8 참고문헌

1. Randall, R. B., Antoni, J. (2011). Rolling element bearing diagnostics: A tutorial. *Mechanical Systems and Signal Processing*, 25(2), 485-520.
2. Case Western Reserve University Bearing Data Center. 공개 베어링 결함 진동 데이터셋. engineering.case.edu (학술/연구 목적 무료 이용).
3. Purohit, H. et al. (2019). MIMII Dataset: Sound Dataset for Malfunctioning Industrial Machine Investigation and Inspection. zenodo.org/record/3384388 (CC-BY-4.0).
4. DCASE Challenge, Task 2: Malfunctioning Industrial Machine Investigation and Inspection.
5. Rohling, H. (1983). Radar CFAR thresholding in clutter and multiple target situations. *IEEE Transactions on Aerospace and Electronic Systems*, AES-19(4), 608-621.
6. Skolnik, M. I. *Introduction to Radar Systems*, 3rd ed., McGraw-Hill, chapter 6 (검출 이론과 CFAR).
7. Moose, P. H. (1994). A technique for orthogonal frequency division multiplexing frequency offset correction. *IEEE Transactions on Communications*, 42(10), 2908-2914.