

장비 없는 WiFi-CSI 재실·낙상 감지

카메라 없이 기존 WiFi로 재실과 낙상을 실측 공개 데이터에서 검증

2i

2026-07-29

초록

이 논문은 카메라나 웨어러블 없이, 이미 설치된 WiFi 링크의 채널 상태 정보(Channel State Information, CSI)만으로 방안의 재실과 사람 활동, 낙상을 구분할 수 있는지를 두 개의 공개 실측 데이터셋에서 검증한다. 딥러닝 없이 부반송파 분산·도플러 스펙트럼·포락선 특징 158개를 손으로 설계하고 그라디언트 부스팅(LightGBM)으로 분류한 결과, UT-HAR 벤치마크에서 7종 활동 분류 정확도 95.2%, 낙상 탐지 AUROC 0.990(정밀도 0.976 기준 재현율 0.911)을 얻었다. 별도로 OPERAnet의 실제 Intel 5300 CSI 캡처에서는 빈 방과 걷기·앉기서기 활동의 10초 윈도우 모션 에너지가 자릿수 단위로 분리되어(걷기 대 빈 방 52배, 앉기서기 대 빈 방 13배) 재실 판별 AUROC 1.000을 기록했다. 두 결과 모두 실측 데이터이며 합성 데이터는 방법론적으로 불가피한 한 곳에만, 그 사실을 명시한 채 사용했다. 동시에 이 논문은 한계를 숨기지 않는다. 두 데이터셋 모두 단일 방·단일 세션이라 방을 옮기면 재보정이 필요하고, 정지한 채 재실 중인 사람과 빈 방을 구분하는 호흡 수준의 미세운동은 아직 공개 데이터로 검증되지 않았다. 이 연구는 기술의 타당성을 보여주는 연구 데모이며, 임상 인증을 받은 의료기기가 아니다.

목차

1	요약	3
2	배경	3
3	방법	3
3.1	CSI 진폭 전처리	3
3.2	특징 추출 (158개, 학습된 표현 없음)	4
3.3	재실 판별 체인 (OPERAnet)	4
4	데이터와 설정	4
4.1	UT-HAR / SenseFi 벤치마크	4
4.2	OPERAnet (CC0, 실측)	5
5	결과	5
5.1	UT-HAR: 7종 활동 분류	5
5.2	UT-HAR: 낙상 대 비낙상	5
5.3	OPERAnet: 재실 판별	5
6	한계	5
7	데이터와 재현	7
8	참고문헌	7

1 요약

이 논문은 카메라나 웨어러블 없이, 이미 설치된 WiFi 링크의 채널 상태 정보(Channel State Information, CSI)만으로 방 안의 재실과 사람 활동, 낙상을 구분할 수 있는지를 두 개의 공개 실측 데이터셋에서 검증한다. 딥러닝 없이 부반송파 분산·도플러 스펙트럼·포락선 특징 158개를 손으로 설계하고 그래디언트 부스팅(LightGBM)으로 분류한 결과, UT-HAR 벤치마크에서 7종 활동 분류 정확도 95.2%, 낙상 탐지 AUROC 0.990(정밀도 0.976 기준 재현율 0.911)을 얻었다. 별도로 OPERAnet의 실제 Intel 5300 CSI 캡처에서는 빈 방과 걷기·앉기서기 활동의 10초 윈도우 모션 에너지가 자릿수 단위로 분리되어(걷기 대 빈 방 52배, 앉기서기 대 빈 방 13배) 재실 판별 AUROC 1.000을 기록했다. 두 결과 모두 실측 데이터이며 합성 데이터는 방법론적으로 불가피한 한 곳에만, 그 사실을 명시한 채 사용했다. 동시에 이 논문은 한계를 숨기지 않는다. 두 데이터셋 모두 단일 방·단일 세션이라 방을 옮기면 재보정이 필요하고, 정지한 채 재실 중인 사람과 빈 방을 구분하는 호흡 수준의 미세운동은 아직 공개 데이터로 검증되지 않았다. 이 연구는 기술의 타당성을 보여주는 연구 데모이며, 임상 인증을 받은 의료기기가 아니다.

2 배경

낙상은 노인 인구에서 가장 흔한 상해 원인 중 하나이고, 요양시설과 독거 노인 가정에서 낙상을 얼마나 빨리 감지하느냐가 이후 회복 경과를 크게 바꾼다. 재실 감지는 그보다 넓은 문제로, 건물의 냉난방 스케줄링부터 매장의 혼잡도 파악까지 걸쳐 있다. 두 문제를 푸는 가장 흔한 접근은 카메라다. 그러나 카메라는 사생활 침해 우려 때문에 침실이나 화장실 같은 공간에 설치하기 어렵고, 웨어러블 센서는 노인이 착용을 잊거나 낙상 순간에 벗겨져 있을 위험이 있다. 두 한계 모두 “사람이 아무것도 착용하지 않고, 아무것도 새로 설치하지 않아도 되는” 감지 방식에 대한 수요를 만든다.

WiFi 채널 상태 정보는 이 수요에 대한 오래된 후보다. 무선 신호는 벽과 가구뿐 아니라 사람의 몸에도 반사되고, 사람이 움직이면 그 반사 경로가 바뀌면서 수신기가 관측하는 채널의 진폭과 위상이 흔들린다. 이 흔들림에서 사람의 존재와 움직임을 읽어내는 것이 WiFi 센싱의 핵심 아이디어다. 상용 WiFi 칩(AP·라우터·노트북 무선랜 카드)은 802.11n 이후 CSI를 하드웨어 레벨에서 이미 계산하고 있으므로, 이론적으로는 새 센서를 달 필요가 없다. 문제는 이 신호가 매우 잡음이 많고, 방마다 가구 배치와 벽 재질에 따라 통계적 특성이 달라진다는 점이다.

최근 몇 년간 이 분야의 연구는 딥러닝 쪽으로 급격히 기울었다. CNN과 트랜스포머 기반 모델이 CSI 진폭이나 위상 시계열을 직접 입력받아 활동을 분류하는 논문이 다수 발표되었고, 그 자체로 유효한 결과를 냈다. 하지만 이 논문이 묻는 질문은 다르다. 딥러닝 없이, 즉 신호처리 이론에서 나온 손으로 설계한 특징과 고전적인 그래디언트 부스팅 모델만으로도 실용적인 수준의 재실·활동·낙상 감지가 가능한가. 이 질문이 의미 있는 이유는 세 가지다. 첫째, 손으로 설계한 특징은 왜 모델이 특정 판단을 내렸는지 설명하기 쉽다. 부반송파 분산이 높았다거나 도플러 에너지가 특정 대역에 몰렸다는 식의 설명이 가능하다. 둘째, 그래디언트 부스팅은 GPU 없이 저전력 엣지 장치에서도 실시간으로 돌 수 있다. 셋째, 학습에 필요한 데이터가 훨씬 적다. 딥러닝 모델은 수천에서 수만 개의 레이블 있는 시퀀스를 요구하지만, 158개의 통계 특징으로 학습하는 그래디언트 부스팅은 수백 개의 윈도우로도 충분히 수렴한다. 이는 배포 현장마다 소량의 보정 데이터만으로 재학습이 가능하다는 뜻이며, 뒤에서 다시 다룰 “방마다 재보정이 필요하다”는 한계를 실제로 감당할 수 있게 만드는 이유이기도 하다.

3 방법

3.1 CSI 진폭 전처리

WiFi CSI는 각 부반송파(subcarrier)마다, 각 송수신 안테나 쌍마다 하나의 복소수 값으로 표현된다. 이 논문에서 다루는 두 데이터셋 중 UT-HAR는 진폭만 재배포되어 있어(위상은 원 저작물에도 포함되지 않았다), 3개 안테나 × 30개 부반송파 = 90개 채널의 진폭 시계열을 그대로 사용했다. 각 윈도우는 250개 시점을 담고 있다. OPERAnet은 원 CSI 복소값을 그대로 확보할 수 있었으므로, 같은 수신기가 관측한 두 안테나 신호를 켤레곱(conjugate multiplication)해 공통 하드웨어 위상잡음(주파수 오프셋, 클럭 지터)을 소거하는 표준 기법을 적용한 뒤, 강건 이상치 제거(Hampel 필터)로 임펄스성 잡음을 걸러내고, 모션 에너지(위상 잔차의 표준편차)를 계산했다. 이 켤레곱-소거 기법은 위상 기반 WiFi 센싱 문헌에서 널리 쓰이는 방법을 우리 파이프라인에 맞게 재구현한 것이다.

3.2 특징 추출 (158개, 학습된 표현 없음)

UT-HAR 파이프라인은 각 250×90 윈도우에서 다음 특징들을 추출한다. 부반송파별로 안테나 평균 진폭의 평균·분산·왜도·첨도(30채널 × 4 = 120개), 90개 채널 전체를 aggregate한 통계(16개), 위상 차분 분산의 대체 지표로서 안테나 간 진폭 다양성 분산(원 재배포 데이터에 위상이 없어 대체 지표를 쓴다는 점을 감추지 않고 명시한다, 3개), 상위 주성분에 대한 도플러/스펙트로그램 밴드 에너지와 지배 주파수 위치(STFT 기반, 5개), 힐베르트 포락선의 움직임 시작 위치와 전반부·후반부 에너지 비율(4개), 단시간 에너지의 뾰족함(2개), 3개 지연에 대한 자기상관(3개), 스펙트럼·진폭 히스토그램 엔트로피(2개), 그리고 전체 에너지·공간적 분산 집중도·전반부 대 후반부 분산 비율이라는 세 가지 전역 통계(3개)로 구성된다. 마지막 특징은 “급격한 순간적 변화 뒤 정지”라는 낙상 특유의 신호 패턴을 직접 겨냥해 설계했다. 모든 특징은 하나의 윈도우 내부에서만 계산되며 다른 샘플의 통계를 참조하지 않으므로, 훈련·검증·시험 분할 사이에 특징 계산 단계에서 정보가 새어나갈 여지가 없다.

분류기는 LightGBM이다. 표준화(StandardScaler)는 훈련 데이터에만 적합(fit)했고, 시드 42부터 46까지 5회 반복했다. 흥미로운 점은 5개 시드 사이에 표준편차가 정확히 0이었다는 것인데, 이는 우연이 아니라 LightGBM의 기본 설정(subsample=1.0, colsample_bytree=1.0)이 행/열의 확률적 샘플링을 켜지 않기 때문에 나온 필연적 결과다. 즉 이 반복은 성능의 실행 간 변동을 추정하기 위한 것이 아니라, 같은 데이터에서 같은 트리 구조가 재현되는지 확인하는 결정론성 검증이었다.

3.3 재실 판별 체인 (OPERAnet)

OPERAnet 실험에서는 활동 분류가 아니라 “빈 방인가, 아닌가”를 10초 윈도우 단위로 판별하는 데 집중했다. 컬레곱으로 위상잡음을 소거한 신호에 Hampel 필터를 적용해 임펄스 이상치를 제거한 뒤, 그 잔차의 제곱평균제곱근(RMS)을 하나의 모션 에너지 지표로 사용했다. 이 지표 하나로 조건 간 순위 기반 AUROC(rank-AUROC)를 계산했다. 학습된 분류기가 아니라 단일 통계량의 분리도를 본 것이므로, 이 실험은 “이 신호가 재실 판별에 쓸 수 있을 만큼 정보를 담고 있는가”라는 더 근본적인 질문에 답한다.

4 데이터와 설정

4.1 UT-HAR / SenseFi 벤치마크

UT-HAR는 Yousefi, Narui, Dayal, Ermon, Valaee가 2017년 IEEE Communications Magazine에 발표한 WiFi 행동 인식 데이터셋으로, Linux 802.11n CSI Tool을 얻은 Intel 5300 네트워크 카드로 수집되었다(3개 안테나 × 30개 부반송파 = 90개 진폭 채널). 이 논문은 원 raw 배포본이 아니라, SenseFi 벤치마크(Yang 등, Patterns/Cell Press, 2023)가 재배포한 학습/검증/시험 분할을 그대로 사용했다. 총 4,973개 윈도우(훈련 3,977 / 검증 496 / 시험 500), 윈도우 크기는 250개 시점 × 90개 채널, 7가지 활동(bed, fall, pickup, run, sitdown, standup, walk)으로 구성된다. 내려받은 데이터의 훈련/시험 개수는 SenseFi 논문 Table II에 보고된 수치(훈련 3,977, 시험 996)와 정확히 일치했고, 이는 손상되거나 대체된 파일이 아니라 진짜 벤치마크 릴리스임을 확인해 준다.

두 가지 정직한 한계를 밝힌다. 첫째, 재배포된 파일에는 레이블 인덱스가 어떤 활동에 대응하는지 알려주는 매핑 파일이 없다. 이 논문은 커뮤니티에서 널리 반복되는 알파벳 순서 관례(bed=0, fall=1, pickup=2, run=3, sitdown=4, standup=5, walk=6)를 채택했다. 이는 원저자가 .mat에서 .csv로 변환할 때 폴더를 알파벳 순으로 순회했을 것이라는 정황적 추론이며, 검증된 정답은 아니다. 모션 신호의 분산 패턴이나 에너지 시간 분포로 레이블을 역추정하는 대안도 시도했으나 7개 클래스가 그 방식으로서는 깨끗하게 갈라지지 않아, 불확실성을 감추기보다 관례를 그대로 밝히는 쪽을 택했다. 이 매핑이 틀렸다면 “낙상”이라는 이름이 붙은 구체적 수치가 다른 클래스 인덱스로 옮겨갈 수 있지만, 7종 전체의 다중클래스 정확도 자체는 어떤 이름이 어떤 인덱스에 붙는지와 무관하므로 영향받지 않는다.

둘째, 공식 분할이 레코딩 단위에서 완전히 누출이 없다고 보장하기 어렵다. SenseFi 논문 자신도 “데이터가 슬라이딩 윈도우로 분할되어 샘플 간 반복이 불가피하게 발생한다”고 명시한다. 인접한 윈도우가 크게 겹치고, 이 겹침이 공식 훈련/시험 파일 사이에도 걸쳐 있을 가능성이 있어, 진짜 독립적인 대상자·세션 분할보다 보고된 정확도가 다소 낙관적일 수 있다. 이 논문은 새로 만든 분할이 아니라 공개된 벤치마크 분할을 그대로 사용했고, 표준화와 LightGBM 학습을 훈련 데이터에만 적합시키고 낙상 판정 임계값을 검증 데이터에서 결정한 뒤 시험 데이터에는 고정된 값을 적용하는 식으로 추가적인 누출은 만들지 않았다. 그러나 벤치마크 분할 자체의 누출 여부는 이 논문도, 이 분할을 사용하는 다른 어떤 논문도 단언할 수 없다.

세 과제 중 (a) 재실 판별에는 합성 데이터가 하나 포함된다. UT-HAR에는 빈 방 레코딩이 전혀 없어서(활동 데이터셋이기 때문이다), 재실 판별의 “부재” 클래스로 실제 신호 전체 표준편차의 5% 크기를 갖는 작은 가우시안 노이즈를 실제 채널별 평균 기준선 주변에 합성했다. (b) 7종 활동 분류와 (c) 낙상 판별은 100% 실측 데이터이며, 어떤 합성도 섞이지 않았다.

4.2 OPERAnet (CC0, 실측)

OPERAnet은 Intel 5300 CSI Tool 기반 3×3 안테나 구성(1,600Hz)으로 실내 활동을 캡처한 공개 라디오 주파수 활동 인식 데이터셋으로, CC0(퍼블릭 도메인) 조건으로 배포된다. 이 논문은 그 중 Room 1에서 진행된 세 세션(exp001 빈 방, exp002 걷기, exp003 의자 앉기·서기)을 사용했다. 원본 데이터는 36.5GB에 달해 필요한 CSI 스트림 6개(tx1rx1/tx1rx2 × 부반송파 10/20/30)만 부분 추출해 실험당 약 30MB로 축소한 뒤 처리했다. 세션별 10초 윈도우 개수는 exp001 231개, exp002 114개, exp003 231개다.

5 결과

5.1 UT-HAR: 7종 활동 분류

7종 활동 분류의 전체 정확도는 95.2%, 매크로 F1은 92.7%였다. 클래스별 재현율과 정밀도는 다음과 같다(시드 42 혼동행렬 기준).

클래스	재현율	정밀도
bed	0.924	0.939
fall	0.911	0.976
pickup	0.993	0.973
run	0.940	0.855
sitdown	1.000	1.000
standup	0.850	0.895
walk	0.839	0.897

혼동은 대부분 standup과 walk 사이, 그리고 일부 bed와 run 사이에 집중된다. 이는 짧고 에너지 강도가 비슷한 자세 전환 동작과, 지속적이지만 짧게 끊긴 이동 동작이 서로 헷갈리기 쉽다는 상식과 정확히 일치하는 패턴이다.

5.2 UT-HAR: 낙상 대 비낙상

낙상 판별은 훈련 데이터에서 낙상 비율이 8.9%에 불과한 불균형 이진 분류다. 임계값 0.5에서 정확도 99.0%, F1 94.3%, 정밀도 97.6%, 재현율 91.1%, AUROC 0.990을 얻었다. 검증 데이터에서 목표 정밀도를 만족하는 임계값을 찾아 고정된 뒤 시험 데이터에 적용한 결과, 목표 정밀도 0.80에서는 재현율 95.6%(실제 시험 정밀도 82.7%), 목표 정밀도 0.90에서는 재현율 93.3%(실제 시험 정밀도 93.3%)를 기록했다. 두 경우 모두 검증에서 고른 임계값이 시험에서도 목표를 달성하거나 근접했다는 점은, 이 임계값 선택 절차가 누출 없이 잘 일반화된다는 신호다.

5.3 OPERAnet: 재실 판별

빈 방과 활동(걷기, 앉기서기) 사이의 10초 윈도우 모션 RMS는 자릿수 단위로 벌어졌다. 빈 방(exp001)의 모션 RMS 중앙값은 0.0041 rad로 이를 1배 기준선으로 두면, 앉기·서기(exp003)는 0.0524 rad로 약 13배, 걷기(exp002)는 0.2120 rad로 약 52배였다. 이 단일 지표만으로 빈 방 대 걷기, 빈 방 대 앉기서기의 순위 기반 AUROC은 각각 1.000이었다. Hampel 필터가 제거한 이상치 비율은 1.4~2.6% 수준으로, 실제 하드웨어 CSI에는 합성 신호에서는 나타나지 않는 임펄스성 아티팩트가 실제로 존재하며 이 필터가 이를 걸러낸다는 것을 보여준다.

세 번째 그림은 정밀도 하한을 높일수록 낙상 탐지가 더 보수적으로 동작하며 재현율이 어떻게 움직이는지를 보여준다. 정밀도 목표를 0.80에서 0.90으로 올려도 재현율이 91.1%에서 93.3%로 오히려 개선된 것은, 검증 데이터에서 고른 임계값이 시험 데이터의 실제 정밀도-재현율 곡면과 잘 맞아떨어졌기 때문이며, 이는 5절에서 다시 짚을 “단일 세션” 한계 안에서의 결과라는 점을 함께 읽어야 한다.

6 한계

이 연구가 보여주는 것과 보여주지 못하는 것을 구분하는 일이, 이 결과를 실제 배포 판단에 쓰려는 사람에게는 성능 수치 자체보다 더 중요하다.




그림 1: 과제별 성능




그림 2: OPERAnet 모션 RMS




그림 3: 낙상 판별 임계값별 재현율

호흡 수준의 정지 재실은 아직 공개 데이터로 검증되지 않았다. 지금까지의 결과는 모두 “움직이는 사람”과 “빈 방”을 가르는 문제였다. 실제로 어려운 문제는 사람이 방에 있지만 가만히 앉아 있거나 잠들어 있는 상태와 빈 방을 구분하는 것이다. 이 구분에는 걷기·서기 같은 큰 동작이 아니라 호흡으로 인한 흉곽의 밀리미터 단위 미세운동을 포착해야 한다. 지금 이 논문이 쓴 두 공개 데이터셋 중 어느 쪽도 이 과제에 맞는 “정지 재실 대 빈 방” 레이블을 정밀한 시간 정렬과 함께 제공하지 않는다. 이는 방법론의 결함이 아니라 공개 데이터의 공백이며, 이 문제를 풀려면 자체적으로 정밀한 타임스탬프와 정지 재실 레이블을 갖춘 캡처를 새로 수집해야 한다.

단일 방, 단일 세션 결과다. UT-HAR는 하나의 환경에서 수집되었고 OPERAnet도 이 논문에서는 Room 1의 한 캠페인만 사용했다. CSI의 통계적 특성은 가구 배치, 벽 재질, 송수신기 위치에 강하게 좌우된다는 것이 이 분야에서 반복적으로 보고된 사실이며, 이는 사전학습된 모델을 다른 방에 그대로 옮기는 제로샷 일반화가 우연 수준의 성능밖에 내지 못한다는 뜻이다. 실제 배포에서는 설치 현장마다 소량의 보정 데이터로 재학습하는 절차가 필요하며, 이 논문이 쓴 그라디언트 부스팅 접근은 딥러닝보다 훨씬 적은 레이블로 이 재보정을 감당할 수 있다는 점에서 실용적이지만, 재보정 자체를 없애주지는 않는다.

다인·다중 잡음원 환경은 다루지 않았다. UT-HAR의 모든 윈도우는 단일 거주자를 가정한다. 실제 가정에는 반려동물, 여러 명의 거주자, 선풍기나 커튼 같은 무관한 움직임이 함께 존재하며, 이 데이터셋은 그런 다중 잡음원 상황에 대해 아무것도 말해주지 않는다.

낙상 데이터는 노인 인구를 대표하지 않는다. UT-HAR의 낙상 이벤트는 (문헌상 관례로 보아) 건강한 성인 자원자가 각본에 따라 수행한 낙상이지, 실제 서비스가 목표로 하는 노인의 느리고 부분적이거나 부족된 낙상이 아니다. 이 논문의 91~96%대 재현율이 실제 노인 낙상에도 유지되는지는 검증되지 않았다.

슬라이딩 윈도우 겹침으로 인한 낙관 편향 가능성. 3.1절에서 밝힌 대로, 공식 분할의 인접 윈도우 간 중복이 보고된 정확도를 실제 독립 세션 성능보다 몇 퍼센트포인트 높게 보이게 할 가능성이 있다.

이 연구는 의료기기가 아니다. 이 논문은 연구 데모로서 기술적 타당성을 보여주는 것이 목적이며, 임상 인증이나 규제 승인을 받은 낙상 감지 제품이 아니다. 실제 요양 현장에 배포되는 제품에는 이 기술 검증과는 별도로 임상 검증과 인증 절차가 필요하다.

이 한계들 중 어느 것도 더 나은 분류기나 더 정교한 고전 특징으로 해결되지 않는다는 점을 분명히 밝힌다. 필요한 것은 다중 방, 다중 대상자, 실제 노인 낙상, 정밀 타임스탬프가 붙은 정지 재실 레이블을 갖춘 새로운 데이터 수집과, 현장별 보정을 전제로 하는 배포 설계다. 이것이 “연구로서 입증됨”과 “제품으로서 출하 가능함” 사이의 정직한 거리다.

7 데이터와 재현

이 논문에서 사용한 두 데이터셋은 모두 공개되어 있으며 이 논문이 인용한 통계는 각 데이터셋의 공개 배포본에서 직접 계산한 실측값이다.

- **UT-HAR (원본):** github.com/ermongroup/Wifi_Activity_Recognition (Yousefi et al., 2017). 재배포/재분할: SenseFi 벤치마크 github.com/xyanchen/WiFi-CSI-Sensing-Benchmark (Yang et al., 2023, 코드 MIT 라이선스, 데이터셋은 학술 연구 목적 재배포).
- **OPERAnet:** CC0(퍼블릭 도메인)로 배포된 라디오 주파수·비전 기반 다중모달 활동 인식 데이터셋 (Bocus et al., 2022). 이 논문은 Room 1의 wificsi1 exp001/002/003 세션만 사용했다.

7절 이하는 재현을 원하는 독자를 위한 절차 요약이다. UT-HAR 파이프라인은 SenseFi가 재배포한 학습/검증/시험 분할을 그대로 불러와 158개 특징을 계산하고, 표준화를 훈련 데이터에만 적합시킨 뒤 LightGBM으로 5개 시드(42~46)를 반복 학습한다. OPERAnet 파이프라인은 필요한 CSI 스트림만 원본에서 부분 추출해(전체 36.5GB 중 실험당 약 30MB), 두 안테나 신호의 컬레곱으로 하드웨어 위상잡음을 소거하고, Hampel 필터로 이상치를 제거한 뒤 10초 윈도우 단위 모션 RMS를 계산한다. 두 파이프라인 모두 CPU 한 대에서 몇 분 이내에 끝나는 가벼운 계산이며, 특별한 하드웨어나 GPU를 요구하지 않는다.

8 참고문헌

1. Yousefi, S., Narui, H., Dayal, S., Ermon, S., Valaee, S. “A Survey on Behavior Recognition Using WiFi Channel State Information.” IEEE Communications Magazine, 2017.
2. Yang, J., Chen, X., Zou, H., Lu, C. X., Wang, D., Sun, S., Xie, L. “SenseFi: A Library and Benchmark on Deep-Learning-Empowered WiFi Human Sensing.” Patterns (Cell Press), 2023.
3. Bocus, M. J., Li, W., Vishwakarma, S., et al. “OPERAnet: A Multimodal Activity Recognition Dataset Acquired from Radio Frequency and Vision-Based Sensors.” Scientific Data, 2022.
4. github.com/ermongroup/Wifi_Activity_Recognition - UT-HAR 원 데이터 배포처.

5. github.com/xyanchen/WiFi-CSI-Sensing-Benchmark - SenseFi 코드 및 재배포 데이터.