

드론 RF 탐지의 오픈셋 현실

낮은 융합 수에서 고전 기법이 딥러닝을 이기는 이유, DroneRF 실측

2i

2026-07-29

초록

안티드론 시스템의 실전 성패는 등록된 드론을 알아맞히는 정확도가 아니라, 라이브러리에 없는 미지 드론을 얼마나 빨리, 얼마나 적은 관측으로 걸러내는가에 달려 있다. 이는 오픈셋(open-set) 거부 문제이며, 야전에서는 관측 하나 또는 소수의 관측만으로 판단해야 하는 경우가 대부분이다. 본 논문은 공개 데이터셋 DroneRF(AI-Sa'd 등, 카타르대학교, CC BY 4.0)를 사용해 24차원 물리 특징(스펙트럼 형태, 고차 큐물런트, 순시 진폭·위상 통계) 기반 LightGBM 분류기와 마할라노비스 거부 규칙으로 구성된 고전 파이프라인을 실측했다. 드론 존재 탐지(배경 대 드론)에서는 AUROC 0.945를 얻었다. 오픈셋 미지 드론 거부에서는 단일 관측($K=1$, 융합 없음)일 때 고전 방법의 거부율이 0.424였고, 같은 과제 장르에서 딥러닝(ECAPA-TDNN 기반 임베딩, CardRF 데이터셋)의 $K=1$ 거부율은 0.074였다. 약 5.7배의 차이다. 관측을 5개, 10개로 늘려 융합해도 이 우위는 유지되었고($K=5$ 에서 0.581 대 0.129, $K=10$ 에서 0.725 대 0.408), $K=20$ 에서는 딥러닝이 근소하게 앞섰으며(0.917 대 0.875), $K=50$ 에서는 두 방법 모두 사실상 포화(1.0)에 도달했다. 이는 서로 다른 데이터셋 위에서 얻은 같은 과제 장르의 비교이므로 동일 데이터 위에서의 직접 대조는 아니지만, 결론은 뚜렷하다. 실제 야전 조건에 가까운 저융합(low- K) 구간에서는 손으로 설계한 물리 특징과 고전 분류기가 딥러닝 임베딩보다 오픈셋 거부에서 확실히 앞섰고, 둘의 성능이 비슷해지는 지점은 수십 개의 관측을 누적해야 하는 $K=20$ 이상의 고용합 구간뿐이었다.

목차

1	요약	3
2	배경	3
3	방법	3
3.1	고전 파이프라인 (본 실험)	3
3.2	딥러닝 비교점 (D1, 별도 실험)	4
4	데이터·설정	4
4.1	DroneRF (고전 실험)	4
4.2	CardRF (D1, 비교 대상)	4
5	결과	4
5.1	드론 존재 탐지 (배경 대 드론, 이진 분류)	4
5.2	드론/제조사 타입 분류 (3종 폐쇄셋: Bebop, AR-drone, Phantom)	5
5.3	오픈셋 미지 드론 거부 (Bebop과 AR-drone으로 훈련, Phantom 전량을 미지로 홀드아웃)	5
6	한계	6
7	재현	7
8	참고문헌	7

1 요약

안티드론 시스템의 실전 성패는 등록된 드론을 알아맞히는 정확도가 아니라, 라이브러리에 없는 미지 드론을 얼마나 빨리, 얼마나 적은 관측으로 걸러내는가에 달려 있다. 이는 오픈셋(open-set) 거부 문제이며, 야전에서는 관측 하나 또는 소수의 관측만으로 판단해야 하는 경우가 대부분이다. 본 논문은 공개 데이터셋 DroneRF(AI-Sa'd 등, 카타르대학교, CC BY 4.0)를 사용해 24차원 물리 특징(스펙트럼 형태, 고차 큐물런트, 순시 진폭·위상 통계) 기반 LightGBM 분류기와 마할라노비스 거부 규칙으로 구성된 고전 파이프라인을 실측했다. 드론 존재 탐지(배경 대 드론)에서는 AUROC 0.945를 얻었다. 오픈셋 미지 드론 거부에서는 단일 관측($K=1$, 융합 없음)일 때 고전 방법의 거부율이 0.424였고, 같은 과제 장르에서 딥러닝(ECAPA-TDNN 기반 임베딩, CardRF 데이터셋)의 $K=1$ 거부율은 0.074였다. 약 5.7배의 차이이다. 관측을 5개, 10개로 늘려 융합해도 이 우위는 유지되었고($K=5$ 에서 0.581 대 0.129, $K=10$ 에서 0.725 대 0.408), $K=20$ 에서는 딥러닝이 근소하게 앞섰으며(0.917 대 0.875), $K=50$ 에서는 두 방법 모두 사실상 포화(1.0)에 도달했다. 이는 서로 다른 데이터셋 위에서 얻은 같은 과제 장르의 비교이므로 동일 데이터 위의 직접 대조는 아니지만, 결론은 뚜렷하다. 실제 야전 조건에 가까운 저융합(low- K) 구간에서는 손으로 설계한 물리 특징과 고전 분류기가 딥러닝 임베딩보다 오픈셋 거부에서 확실히 앞섰고, 둘의 성능이 비슷해지는 지점은 수십 개의 관측을 누적해야 하는 $K=20$ 이상의 고융합 구간뿐이었다.

2 배경

안티드론(counter-drone) 시스템에 요구되는 능력은 두 층위로 나뉜다. 하나는 드론이 존재하는지, 즉 배경 잡음과 실제 드론 신호를 구분하는 탐지(detection)다. 다른 하나는 탐지된 신호가 어떤 드론인지, 그리고 더 중요하게는 등록된 목록에 없는 드론을 얼마나 정확히 걸러내는지를 다루는 식별(identification)과 오픈셋 거부(open-set rejection)다. 상용·군용 안티드론 레이더 시장은 드론 위협의 종류가 계속 늘어나면서 함께 커지고 있고, 그만큼 이 시스템이 마주치는 대부분의 신호는 사전에 학습되지 않은, 처음 보는 기종이다.

상업용 드론 보급이 늘면서 안티드론 시스템이 방어해야 하는 위협의 종류는 사전에 정의할 수 있는 목록보다 훨씬 빠르게 늘어난다. 취미용 쿼드콥터, 배달용 드론, 농업용 드론, 개조된 1인칭 시점(FPV) 드론이 모두 같은 주파수 대역을 오가며, 방어 시스템을 설치하는 시점에 존재하지 않았던 신형 기종이 운용 기간 중 새로 나타나는 것이 오히려 일반적인 상황이다. 이런 환경에서 시스템의 실전 가치는 “라이브러리에 있는 드론을 얼마나 정확히 맞히는가”가 아니라 “라이브러리에 없는 드론을 얼마나 신뢰성 있게 걸러내는가”로 결정된다. 라이브러리를 매번 갱신하는 것도 완전한 해법이 아니다. 신형 드론이 시장에 나온 뒤 그 RF 신호를 캡처하고 라벨링하고 재학습해 배포하는 데는 시간이 걸리고, 그 공백 기간 동안 시스템은 처음 보는 신호를 마주하게 된다.

여기서 흔히 놓치는 지점이 있다. 학계와 벤더 자료의 다수는 폐쇄셋(closed-set) 분류 정확도, 즉 “이 신호가 A 드론인지 B 드론인지”를 정해진 목록 안에서 맞히는 성능으로 결과를 보고한다. 그러나 실제 야전에서 방어 시스템이 마주하는 질문은 다르다. 라이브러리에 등록되지 않은 신형·개조·상업용 드론이 나타났을 때, 그것이 “알려진 것이 아니다”라는 판단을 얼마나 빠르고 신뢰성 있게 내릴 수 있는가다. 이것이 오픈셋 거부이며, 폐쇄셋 정확도가 높아도 오픈셋 거부가 약하면 안티드론 시스템은 미지의 위협을 아는 위협으로 오분류하거나, 반대로 아는 위협을 미지로 흘려버릴 수 있다.

오픈셋 거부에서 또 하나 간과되는 변수가 관측 수, 즉 얼마나 많은 패킷이나 신호 원도우를 모아서 하나의 판정을 내리는가(본 논문에서는 이를 융합 수 K 로 표기한다)다. 실험실 벤치마크는 흔히 K 를 크게 잡아(수십 개 관측을 평균해 하나의 결정을 내림) 인상적인 성능을 보이지만, 실제 야전에서 안티드론 시스템이 위협에 반응할 시간은 초 단위 이하로 제한되는 경우가 많고, 드론은 짧게 나타났다가 사라지거나 경로를 바꾼다. 즉 현실적인 운용 조건은 K 가 작은, 1에 가까운 구간이다. 본 논문의 핵심 질문은 이것이다. K 가 작을 때, 즉 야전에서 실제로 마주치는 조건에서, 고전 물리 특징 기반 방법과 딥러닝 임베딩 기반 방법 중 어느 쪽이 오픈셋 거부를 더 잘 하는가.

3 방법

3.1 고전 파이프라인 (본 실험)

원시 실수값 RF 파형(DroneRF는 IQ가 아니라 실측 ADC 진폭 신호)에 힐베르트 변환을 적용해 해석적 신호(analytic signal)를 구성한 뒤, 아래 네 그룹, 총 24차원의 물리 특징을 추출한다.

- RSSI(평균 전력, dB) 1개
- 엔벨로프 통계(평균, 표준편차, 비대칭도, 첨도, 변동계수) 5개와 PAPR 1개
- 순시주파수 기반 반송파 주파수 오프셋(CFO) 추정(평균, 표준편차, 첨도) 3개
- 고차 큐물런트(Swami와 Sadler, 2000년 방법: C20, C21, C40, C41, C42, C63, 정규화) 6개

- 스펙트럴 형태 특징(Welch PSD 기반 중심주파수 오프셋, 대역폭, 평탄도, 엔트로피와 4개 대역 에너지비) 8개

분류기는 LightGBM(300개 트리, num_leaves=31)이다. 오프셋 거부는 Ledoit-Wolf 축소 추정 공분산을 사용한 마할라노비스 거리 기반 거부 규칙으로 수행한다. 훈련에 쓰인 기지(known) 클래스들의 특징 벡터로 중심(centroid)과 공분산을 추정하고, 검증셋에서 임계값 τ 를 분위수($\gamma=0.9$)로 정한 뒤, 테스트 시 이 τ 보다 먼 벡터는 미지로 거부한다. 융합 수 K 는 K 개의 연속 관측에서 얻은 거리 벡터를 평균한 뒤 하나의 결정을 내리는 방식으로 정의한다.

3.2 딥러닝 비교점 (D1, 별도 실험)

딥러닝 비교점은 같은 과제 장르(드론 계열 RF 신호의 오프셋 미지 거부, 동일한 마할라노비스 거부 레시피)를 다루는 별도 실험(D1, 드론 컨트롤러 RF 지문 인식)에서 인용한다. D1은 ECAPA-TDNN 아키텍처에 MoCo 방식의 대조학습을 결합한 임베딩 모델을 사용하며, 코사인 유사도와 AS-norm 점수로 오프셋 검증을 수행하고, 같은 방식으로 K 개 관측을 평균하는 융합 스윙을 적용한다. D1은 CardRF 데이터셋(6종 드론 컨트롤러, 4종 기지 클래스, DJI Inspire · Phantom · Mavic Pro · M600, 2종 미지 클래스, Beebeerun과 3DR Iris)에서 실행되었다.

두 실험이 같은 과제 장르와 같은 거부 방법론(마할라노비스, K -평균 융합 스윙)을 공유하기 때문에 결과를 나란히 놓고 비교할 수 있지만, 데이터셋과 클래스 구성이 다르므로 이는 동일 데이터 위의 직접 A/B 테스트가 아니라 같은 장르 내 비교임을 명시한다. 4절과 5절에서 이 경계를 다시 짚는다.

4 데이터 · 설정

4.1 DroneRF (고전 실험)

DroneRF는 Al-Sa'd 등(카타르대학교)이 공개한 실측 드론 RF 데이터셋으로, Mendeley 저장소 (DOI 10.17632/f4c2b4n755)에서 로그인 없이 공개 API로 직접 확보했다. 라이선스는 데이터셋 메타데이터의 data_licence 필드로 직접 확인한 CC BY 4.0(출처 표시 조건 부착, 상업적 인용 가능)이며, 이는 D1이 사용한 CardRF(연구 목적 한정, 상업적 인용에는 별도 확인 필요)와 대조적이다.

데이터셋은 배경(00000) 1종과 드론 3종(Bebop, AR-drone, Phantom)의 비행모드별 신호로 구성된다. Bebop과 AR-drone은 각 4개 비행모드(정지, 호버링, 비행, 비디오 촬영)를 캡처했고, Phantom은 1개 모드(전원 켜짐)만 캡처되어 있다. 이는 데이터셋 자체의 구조(3개 드론, 227개 세그먼트)이며, 본 실험에서 임의로 만든 불균형이 아니다. 세그먼트당 1000만 개의 실수값 ADC 진폭 샘플을 4096샘플 크기의 비중첩 윈도우로 분할한 뒤, 결정론적 스트라이드로 세그먼트당 200개 윈도우를 서브샘플링했다. 배경은 9개 세그먼트, 드론은 각 비행모드당 4개 세그먼트를 사용해 총 9000개 윈도우(배경 1800개, 드론 9종 비행모드 각 800개, 합 7200개)를 구성했다. 이는 데이터셋 전체(각 부분 10~21개 세그먼트, 세그먼트당 1000만 샘플)의 일부만 사용한 것으로, 로컬 CPU 환경에서 완결 가능한 범위로 스코프를 의도적으로 좁힌 것이다.

4.2 CardRF (D1, 비교 대상)

D1이 사용한 CardRF는 Medaiyese 등(루이빌대학교/AERPAAW)이 공개한 드론 컨트롤러 RF 캡처 데이터셋으로, 원 목표였던 IEEE DataPort의 17개 컨트롤러 데이터셋이 로그인 게이트로 확보되지 않아 대체 데이터셋으로 사용되었다. 1024샘플로 리샘플링된 정상상태 신호 슬라이스 (Processed_CardRF)를 사용했으며, 실수값 RF 엔벨로프(단일 채널)로 DroneRF와 신호 형식이 유사하다. 라이선스는 원 IEEE DataPort 배포본이 구독 필요 상태이고, 실제로 확보한 공개 미러본의 라이선스는 명시적으로 검증되지 않아 연구 검증 용도로만 취급한다.

5 결과

5.1 드론 존재 탐지 (배경 대 드론, 이진 분류)

지표	값
Accuracy	0.8885
F1 (macro)	0.8245
F1 (drone)	0.9305
AUROC	0.945

테스트셋 2700개 윈도우(배경 540, 드론 2160, 원 데이터 비율 유지) 기준이다. D1에는 이와 직접 대응하는 탐지 과제가 없어, 이 결과는 고전 파이프라인 단독 결과다.

5.2 드론/제조사 타입 분류 (3종 폐쇄셋: Bebop, AR-drone, Phantom)

지표	값
Accuracy	0.5685
F1 (macro)	0.5534
우연 수준(chance)	0.333
다수클래스 기준선	0.444

우연 수준보다는 높지만 다수클래스 기준선을 크게 넘지 못한다. 세 제조사(Bebop, AR-drone, Phantom)를 구분하는 이 과제는 동일 제조사 내 기종 구분이 아니라 제조사 간 구분임에도 결과가 강하지 않다. 이는 4.3절과 5절에서 다시 논의한다.

5.3 오픈셋 미지 드론 거부 (Bebop과 AR-drone으로 훈련, Phantom 전량을 미지로 홀드아웃)

아래 표는 K(결정당 평균 관측 수)에 따른 미지거부율과 AUROC를 고전(DroneRF)과 딥러닝 (D1, CardRF)에서 나란히 보여준다.

K	고전 미지거부율	고전 AUROC	딥러닝 미지거부율	딥러닝 AUROC(코사인)
1	0.424	0.648	0.074	0.565
5	0.581	0.720	0.129	0.708
10	0.725	0.811	0.408	0.761
20	0.875	0.937	0.917	0.829
50	1.000	1.000	1.000	0.914




그림 1: 오픈셋 미지 드론 거부율

K=1, 즉 융합 없이 단일 관측으로 판단해야 하는, 야전 조건에 가장 가까운 지점에서 고전 방법의 미지거부율은 딥러닝의 약 5.7 배였다(0.424 대 0.074). D1 자체 문서가 정직하게 기록하듯, 딥러닝 임베딩은 단일 패킷에서 대조학습 손실이 거의 움직이지 않는 상태 (붕괴, collapse)였고, 이는 단일 관측에서 임베딩이 유의미한 지문을 뽑아내지 못했다는 뜻이다. 반면 24차원 물리 특징과 마할라노비스 거부는 단일 관측에서도 이미 우연 수준을 뚜렷이 넘는 신호를 확보하고 있었다. K=5, K=10 구간에서는




그림 2: K=1

격차가 오히려 더 벌어졌다 (0.581 대 0.129, 0.725 대 0.408). K=20에서 딥러닝이 근소하게 앞섰고 (0.917 대 0.875), K=50에서는 두 방법 모두 사실상 완전한 거부(1.0)에 도달했다.

두 번째 차트는 이 논문의 핵심 메시지를 한 장으로 보여준다. 저융합(K=1) 구간에서는 두 방법의 거부율 격차가 크지만, 고융합(K=50) 구간에서는 그 격차가 완전히 사라진다. K=20과 K=50 구간은 미지 표본 수가 각각 40개와 16개(고전), 40개와 48개(딥러닝, D1 표기 기준)로 작아, 이 구간의 “동률”은 방법의 우위를 나타내는 증거가 아니라 표본 크기의 한계로 읽어야 한다.

폐쇄셋 accK(기지 2종, Bebop 대 AR-drone)는 K에 따라 단조롭게 개선되지 않고 0.49에서 0.59 사이를 오갔다. 이는 24차원 특징 세트로는 Bebop과 AR-drone의 RF 특성 자체의 분리도가 낮다는 뜻이며, 융합이 잡음을 줄여도 분리 가능한 신호 자체가 약하면 개선이 제한된다는 것을 보여준다.

이 결과가 안티드론 배치에 갖는 함의는 K를 실제로 몇으로 잡을 수 있는가에 좌우된다. 드론이 짧게 노출되거나 빠르게 경로를 바꾸는 조건에서는 결정을 K=1에 가깝게 내려야 하고, 바로 이 구간에서 고전 방법의 우위가 가장 크다. 반대로 정찰 임무처럼 같은 드론이 오랜 시간 같은 공역에 머무는 조건에서는 K를 20 이상으로 키울 여유가 생기고, 이 구간에서는 두 방법의 차이가 좁아지거나 딥러닝이 근소하게 앞선다. 즉 어느 방법이 “더 낫다”는 질문에는 하나의 답이 없고, 답은 운용 시나리오가 허용하는 관측 시간에 달려 있다. 본 논문이 K별로 표를 나눠 보고하는 이유가 여기에 있다.

6 한계

동일 데이터셋 위의 직접 비교가 아니다. 고전 실험은 DroneRF(3종 드론, 2개 기지 클래스/1개 미지 클래스)에서, 딥러닝 비교값(D1)은 CardRF(6종 컨트롤러, 4개 기지/2개 미지, 동일 제조사 4종 포함)에서 얻었다. 과제 장르와 거부 방법론(마할라노비스, K-평균 융합)은 동일하지만 데이터와 클래스 구성이 다르므로, 본 논문의 “고전이 이겼다”는 서로 다른 데이터셋 위에서 같은 장르의 과제를 각각 측정한 결과의 비교로 읽어야 하며, 동일 데이터 위 A/B 테스트로 읽어서는 안 된다. DroneRF 위에서 딥러닝(ECAPA 계열) 대응 실험을 별도로 돌려야 완전한 동일 데이터 비교가 되며, 본 논문은 그 후속 실험을 수행하지 않았다.

고융합(K=50)에는 두 방법 모두 도달하는 비용이 든다. K=50은 관측 50개를 누적해야 하나의 판정이 나오는 것이며, 관측 대상이 짧게 노출되고 이동하는 실전 조건에서는 이 정도 누적 가능성이 가능하지 않을 수 있다. 두 방법 모두 K=20 이상에서 성능이 급격히 좋아지지만, 이 성능이 실제로 확보 가능한 관측 시간과 관측 안정성을 전제로 한다는 점은 별도로 검증되어야 한다.

소표본 경계. K=20, K=50 구간의 미지 표본 수는 고전 실험에서 각각 40개와 16개다. “1.0”이라는 완전 거부는 실측이지만, 이 표본 크기에서 나온 값을 국방 등급의 Pd(탐지율) 99% 이상, Pfa(오탐률) $1e-6$ 이하 같은 주장으로 확장해서는 안 된다. D1 문서 역시 자신의 K=50 “100%” 수치에 동일한 소표본 유효를 명시하고 있다.

타입 분류(제조사 구분)는 약점이다. 3종 분류(Bebop, AR-drone, Phantom) 정확도 0.5685는 다수클래스 기준선(0.444) 보다는 높지만 강하지 않다. 변조분류나 간섭분류 과제에서 고전 방법이 보인 압도적 우위와 달리, 드론의 제조사를 구분하는 과제는 이 24차원 손수 설계 특징으로는 쉽게 풀리지 않는다. 이는 스펙트럴·큐물런트 특징이 주로 “신호가 있는가”와 “신호가 안정적인가(오픈셋)”에는 강하지만, 세밀한 제조사 판별에는 호핑 패턴이나 버스트 타이밍 같은 추가 특징이 필요할 수 있음을

시사한다.

컨트롤러 지문 인식은 별도 결과다. D1(드론 컨트롤러 RF 지문 인식)은 본 논문의 비교점으로 인용했을 뿐, 본 논문의 실험이 아니다. D1 자체의 결론은 컨트롤러 지문 인식에서 미지 거부가 $K=20$ 이상에서 국방 설계 목표(90% 이상)를 달성하지만, 동일 제조사(DJI 4종) 내 컨트롤러 구분은 $K=50$ 에서도 70% 수준(우연 25%)에 그친다는 것이며, $P_d 99\% \cdot P_{fa} 1e-6$ 같은 국방 등급 운용점은 측정되지 않았다는 점을 정직하게 기록하고 있다. 본 논문은 이 결과를 오픈셋 거부의 K 에 따른 거동을 비교하는 근거로만 사용하며, 컨트롤러 식별 자체의 결론으로 재사용하지 않는다.

합성 아닌 실측이지만 규모는 제한적이다. 두 실험 모두 실측 RF 캡처를 사용했다는 점에서 합성 데이터 실험보다 신뢰도가 높지만, 캡처된 드론·컨트롤러 종류는 각각 3종과 6종으로 실전에 존재하는 드론 기종의 다양성에 비해 작다. 결론의 일반화는 이 규모 한계 안에서 읽어야 한다.

7 재현

1) 데이터 다운로드 (Mendeley public API, 로그인 필요)

```
curl -sL "https://data.mendeley.com/public-api/datasets/f4c2b4n755" -o dronerf_meta.json
# meta.json의 files[].content_details.download_url로 각 .rar 파일 다운로드 후 압축 해제
```

2) 특징 추출, 탐지, 타입 분류, 오픈셋 거부 실행

```
python3 classical_drone_rf.py --extracted-dir <추출된 디렉터리>
```

특징 추출은 윈도우당 약 0.457ms이며, 캐시된 윈도우 데이터가 있을 경우 특징 추출과 3개 과제 학습·평가를 포함한 총 실행 시간은 약 16초다(캐시 없이 윈도우 생성부터 시작하면 약 66초). 전 과정은 CPU 단독으로 실행되며 별도 GPU나 격리된 가상환경이 필요하지 않다.

8 참고문헌

1. M. Al-Sa'd, A. Al-Ali, A. Mohamed, T. Khattab, A. Erbad. "RF-based drone detection and identification using deep learning approaches." Future Generation Computer Systems, 2019. Dataset: DroneRF, Mendeley Data, DOI 10.17632/f4c2b4n755, CC BY 4.0, Qatar University.
2. O. Medaiyese, M. Ezuma, A. Lauf, A. Adeniran. "Cardinal RF (CardRF): An Outdoor UAV/UAS/Drone RF Signals with Bluetooth and WiFi Signals Dataset." AERPAAW, University of Louisville. 컨트롤러 지문 비교 실험 (D1)의 데이터 소스.
3. B. Desplanques, J. Thienpondt, K. Demuynck. "ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification." arXiv:2005.07143, 2020. D1이 사용한 임베딩 아키텍처.
4. A. Swami, B. M. Sadler. "Hierarchical digital modulation classification using cumulants." IEEE Transactions on Communications, 2000. 고전 파이프라인의 고차 큐물런트 특징의 근거.
5. D. R. Sturim, D. A. Reynolds. "Speaker adaptive cohort selection for Tnorm in text-independent speaker verification." ICASSP, 2005. D1이 사용한 AS-norm 점수 기법의 근거.
6. O. Ledoit, M. Wolf. "A well-conditioned estimator for large-dimensional covariance matrices." Journal of Multivariate Analysis, 2004. 고전 파이프라인의 마할라노비스 거부에 사용된 축소 추정 공분산 기법의 근거.