

팩터 수익 예측: 부스팅 vs 딥러닝

소데이터 금융 테이블러에서의 모델 선택

2i

2026-07-29

초록

퀀트 실무에서 반복되는 질문 하나는 단순하다. 표 형태(테이블러)의 금융 데이터, 그것도 관측치가 몇백에서 몇천 개에 불과한 소데이터 상황에서 그래디언트 부스팅(GBM)과 얇은 딥러닝(DL) 중 무엇을 기본값으로 삼아야 하는가. 이 논문은 그 질문을 실측으로 좁혔다. 공개 데이터인 Fama-French 3-팩터 일간 시계열(시장초과수익 Mkt-RF, 규모 SMB, 가치 HML)에서 시차 특징을 구성해 다음날 시장초과수익의 값(회귀)과 방향(분류)을 예측하는 과제를 만들고, 히스토그램 기반 그래디언트 부스팅과 은닉층 1개짜리 얇은 다층퍼셉트론(MLP)을 시간순 분할로 공정하게 맞세웠다. 훈련 데이터 크기를 60일에서 8,000일까지 여덟 단계로 바꿔가며 같은 500일짜리 최근 구간에서 평가한 결과, 극소데이터 구간(훈련 60일)에서 MLP의 표본 밖 결정계수(R^2)는 -2.60까지 붕괴한 반면 GBM은 -0.07로 상대적으로 완만하게 무너졌다. 즉 같은 조건에서 MLP가 GBM보다 훨씬 심하게 과적합했다. 훈련 데이터가 늘어날수록 이 격차는 좁혀졌고, 훈련 4,000~8,000일 구간에서는 오히려 MLP의 R^2 (-0.09~-0.08)가 GBM(-0.13~-0.10)을 소폭 앞섰다. 방향 예측 정확도는 훈련 크기와 무관하게 46.6~52.6% 사이에서 다수클래스 기준선(49.0%)을 크게 벗어나지 못했고, ROC-AUC 역시 대부분 0.46~0.55 구간에 머물렀다. 이 결과가 말하는 것은 두 가지다. 첫째, 일간 팩터 수익률의 방향 예측에서는 GBM이든 DL이든 시장 효율성을 뚫는 안정적인 신호를 찾지 못했다. 둘째, 그럼에도 불구하고 두 모델 계열이 실패하는 양상은 서로 다르다. 소데이터에서는 GBM이 훨씬 안전한 기본값이고, 데이터가 쌓일수록 그 우위는 줄어들거나 역전될 수 있다. 이 논문은 방법론 연구이며 투자자문이 아니다. 실거래 전략의 수익성을 주장하지 않는다.

목차

1 요약	3
2 배경: 왜 소데이터 테이블러 금융 문제에서 모델 선택이 갈리는가	3
3 방법: GBM 대 얇은 DL, 시간순 분할, 누수 차단	3
3.1 모델	3
3.2 시간순 분할과 누수 차단	4
3.3 평가 지표	4
4 데이터와 실험 설정	4
4.1 데이터 출처 (실측, 공개 데이터)	4
4.2 특징 구성 (시차 특징, 시간순 안전)	4
4.3 실험 설정 요약	4
5 결과	5
5.1 회귀: 소데이터에서 GBM이 훨씬 안전하다	5
5.2 분류: 방향 예측은 두 모델 다 동전 던지기에 가깝다	5
6 한계와 캐비엣	6
7 데이터와 재현	7
8 참고문헌	7

1 요약

퀀트 실무에서 반복되는 질문 하나는 단순하다. 표 형태(테이블러)의 금융 데이터, 그것도 관측치가 몇백에서 몇천 개에 불과한 소데이터 상황에서 그래디언트 부스팅(GBM)과 얇은 딥러닝(DL) 중 무엇을 기본값으로 삼아야 하는가. 이 논문은 그 질문을 실측으로 좁혔다. 공개 데이터인 Fama-French 3-팩터 일간 시계열(시장초과수익 Mkt-RF, 규모 SMB, 가치 HML)에서 시차 특징을 구성해 다음날 시장초과수익의 값(회귀)과 방향(분류)을 예측하는 과제를 만들고, 히스토그램 기반 그래디언트 부스팅과 은닉층 1개짜리 얇은 다층퍼셉트론(MLP)을 시간순 분할로 공정하게 맞세웠다. 훈련 데이터 크기를 60일에서 8,000일까지 여덟 단계로 바꿔가며 같은 500일짜리 최근 구간에서 평가한 결과, 극소데이터 구간(훈련 60일)에서 MLP의 표본 밖 결정계수(R^2)는 -2.60까지 붕괴한 반면 GBM은 -0.07로 상대적으로 완만하게 무너졌다. 즉 같은 조건에서 MLP가 GBM보다 훨씬 심하게 과적합했다. 훈련 데이터가 늘어날수록 이 격차는 좁혀졌고, 훈련 4,000~8,000일 구간에서는 오히려 MLP의 R^2 (-0.09~-0.08)가 GBM(-0.13~-0.10)을 소폭 앞섰다. 방향 예측 정확도는 훈련 크기와 무관하게 46.6~52.6% 사이에서 다수클래스 기준선(49.0%)을 크게 벗어나지 못했고, ROC-AUC 역시 대부분 0.46~0.55 구간에 머물렀다. 이 결과가 말하는 것은 두 가지다. 첫째, 일간 팩터 수익률의 방향 예측에서는 GBM이든 DL이든 시장 효율성을 뚫는 안정적인 신호를 찾지 못했다. 둘째, 그럼에도 불구하고 두 모델 계열이 실패하는 양상은 서로 다르다. 소데이터에서는 GBM이 훨씬 안전한 기본값이고, 데이터가 쌓일수록 그 우위는 줄어들거나 역전될 수 있다. 이 논문은 방법론 연구이며 투자자문이 아니다. 실거래 전략의 수익성을 주장하지 않는다.

2 배경: 왜 소데이터 테이블러 금융 문제에서 모델 선택이 갈리는가

표 형태 데이터에 관한 최근 머신러닝 문헌은 대체로 한 방향을 가리킨다. 행과 열로 구성된 정형 데이터에서는 딥러닝의 화려한 표현력보다 그래디언트 부스팅 계열의 트리 앙상블이 여전히 강력하거나, 적어도 경쟁력이 있다는 것이다. 이 경향은 관측치 수가 적을수록, 특징의 스케일이 이질적일수록, 특징 간 상호작용이 국소적이고 비매끄러울수록 더 뚜렷해진다고 보고된다. 금융 팩터 데이터는 이 조건에 상당 부분 들어맞는다. 일간 관측치는 많아 보여도 실제로 통계적 독립성을 가진 정보량은 훨씬 적고(변동성 군집, 자기상관, 레짐 전환 때문에), 개별 종목이나 전략 단위로 좁히면 훈련에 쓸 수 있는 표본이 수백 개 수준으로 줄어드는 경우가 흔하다. 신생 팩터, 신흥시장, 소형주 유니버스, 특정 섹터로 한정된 전략 등이 전형적인 예다.

문제는 이런 소데이터 상황에서 실무자가 마주치는 선택이 이론적 우아함이 아니라 실용적 판단이라는 점이다. 딥러닝 논문들이 대형 데이터셋에서 보고하는 인상적인 성능이 표본 수 200~2,000짜리 팩터 예측 문제에도 그대로 옮겨 오는지, 아니면 그 구간에서는 오히려 트리 기반 방법이 더 안전한 기본값인지는 각 실무자가 매번 직접 확인해야 하는 질문으로 남아 있다. 이 논문은 그 질문에 대한 하나의 정직한 답을 제공하려는 시도다. 유명한 표 형태 벤치마크(신용평가, 부동산 가격 등)가 아니라 실제 금융 팩터 시계열 위에서, 시간순 분할이라는 금융 데이터 고유의 제약을 지키면서, 훈련 데이터 크기를 체계적으로 바꿔가며 관찰한다.

같은 맥락에서 이 논문은 “어느 모델이 시장을 이기는가”라는 질문에는 답하지 않는다. 오히려 그 질문보다 한 단계 앞선, 더 좁고 더 재현 가능한 질문에 집중한다. 동일한 특징, 동일한 분할, 동일한 평가 지표 위에서 두 모델 계열의 표본 밖 성능이 훈련 데이터 크기에 따라 어떻게 움직이는가. 시장을 이기는 신호가 존재하지 않더라도, 이 질문 자체는 여전히 유효하고 실무적으로 유용하다. 두 모델이 실패하는 방식이 다르다면 그 실패 양상 자체가 모델 선택의 근거가 되기 때문이다.

3 방법: GBM 대 얇은 DL, 시간순 분할, 누수 차단

3.1 모델

이 논문은 두 모델 계열을 의도적으로 튜닝 없이, 널리 쓰이는 기본 설정에 가깝게 비교했다. 어느 한쪽에 유리하도록 하이퍼파라미터를 조정하지 않았다는 점을 분명히 밝힌다.

- **그래디언트 부스팅(GBM):** scikit-learn의 HistGradientBoostingRegressor/HistGradientBoostingClassifier. 히스토그램 기반 트리 분할을 쓰는 구현으로, LightGBM과 같은 계열의 알고리즘이다. 트리 개수(반복 횟수) 200, 최대 트리 깊이 4, 학습률 0.05로 고정했다.
- **얇은 딥러닝(DL):** scikit-learn의 MLPRegressor/MLPClassifier. 은닉층 1개, 은닉 유닛 32개, ReLU 활성화, 가중치 감쇠(L2) 계수 $1e-3$. 조기 종료(early stopping)를 검증 손실 기준으로 활성화해 과적합을 어느 정도 자동으로 억제하도록 했다. 최대 반복 2,000회.

두 모델 모두 입력 특징을 훈련 구간의 평균과 표준편차로 표준화(z-score)한 뒤 학습했고, 표준화 통계량은 훈련 구간에서만 추정해 테스트 구간에 그대로 적용했다(정보 누수 차단).

3.2 시간순 분할과 누수 차단

금융 시계열에서 가장 흔한 방법론적 실수는 무작위 교차검증이다. 시간 순서를 무시하고 데이터를 무작위로 섞어 훈련/검증에 나누면, 미래 정보가 과거를 예측하는 데 스며들어 표본 밖 성능이 체계적으로 부풀려진다. 이 논문은 모든 분할을 시간순으로 고정한다. 전체 기간의 가장 최근 500거래일을 고정된 평가 구간으로 떼어 두고, 그 직전 구간에서 훈련 데이터 크기(60, 125, 250, 500, 1,000, 2,000, 4,000, 8,000거래일)를 바꿔가며 반복 실험했다. 훈련 구간과 평가 구간은 어느 실험에서도 겹치지 않으며, 특징을 만들 때도 각 날짜의 특징은 그 날짜 이전의 값만 사용한다(시차 특징, 아래 3.2절).

이 설계는 흔히 쓰이는 워크포워드(walk-forward) 검증의 단순화 버전이다. 여러 개의 겹치는 평가 구간을 평균 내는 대신 하나의 고정된 최근 평가 구간만 사용했다. 이는 계산량을 줄여 실험을 재현 가능하게 유지하기 위한 의도적 단순화이며, 5절 한계에서 그 대가를 명시한다.

3.3 평가 지표

회귀 과제는 표본 밖 결정계수(R^2)로, 분류 과제는 정확도와 ROC-AUC로 평가했다. 두 과제 모두 훈련 구간의 통계량만으로 만든 자명한 기준선(회귀는 훈련 구간 평균으로 예측, 분류는 훈련 구간 다수 클래스로 예측)을 함께 계산해, 모델이 이 기준선보다 실제로 나은지를 같은 표에서 확인할 수 있게 했다.

4 데이터와 실험 설정

4.1 데이터 출처 (실측, 공개 데이터)

이 논문에서 사용한 데이터는 **실측(real) 공개 데이터**이며 합성 데이터가 아니다. 원 데이터는 Kenneth R. French 교수의 데이터 라이브러리가 제공하는 Fama-French 3-팩터 일간 시계열(시장초과수익 Mkt-RF, 규모 프리미엄 SMB, 가치 프리미엄 HML, 무위험수익률 RF)이다. 이 실험을 실행한 네트워크 환경에서는 French 교수의 원 서버에 직접 접근할 수 없었기 때문에, GitHub에 공개적으로 미러링된 동일 CSV 파일(vicmart11/Fama-French-3-Factor 저장소)을 대신 사용했다. 파일 자체의 헤더 주석에 "CMPT_ME_BEME_RETS_DAILY, 2023년 7월 CRSP 데이터베이스 사용"이라고 명시되어 있어, 원 데이터의 출처와 생성 방법이 파일 안에 자체 기록되어 있음을 확인했다. 내려받은 원본 파일은 1926년 7월 1일부터 2023년 7월 31일까지 25,543개 거래일 관측치를 담고 있다.

4.2 특징 구성 (시차 특징, 시간순 안전)

원 데이터는 팩터 3개뿐이므로, 이를 그대로 특징으로 쓰는 대신 과거 시차와 이동통계량으로 특징 공간을 넓혔다. 구체적으로 Mkt-RF, SMB, HML 각각에 대해 1, 2, 3, 5, 10, 20거래일 전 값(시차 특징 18개)을, 그리고 5, 10, 20거래일 창에서 Mkt-RF의 이동평균·이동 변동성과 SMB·HML의 이동평균(창당 4개, 3개 창이므로 12개)을 추가해 총 30개 특징을 구성했다. 이동통계량도 모두 "그 날짜 하루 전까지"의 값만 사용하도록 이동(shift)한 뒤 계산해, 당일 정보가 특징에 섞여 들어가는 것을 막았다. 예측 대상은 같은 날짜의 Mkt-RF 값(회귀)과 그 부호(분류, 상승=1)이며, 특징은 전부 그 날짜 이전 정보로만 구성되므로 이는 사실상 "어제까지의 정보로 오늘을 예측"하는 다음날 예측 문제와 동일한 구조다. 시차·이동통계량 계산으로 발생하는 결측 구간(가장 이른 20거래일)은 제거했고, 최종 특징 표본 수는 25,523행이다.

4.3 실험 설정 요약

항목	값
데이터 출처	실측(real), Fama-French 3-팩터 일간, GitHub 미러
관측 기간	1926-07-27 ~ 2023-07-31 (특징 생성 후)
특징 수	30 (시차 18 + 이동통계량 12)
평가 구간	최근 500거래일 (고정)
훈련 구간 크기	60 / 125 / 250 / 500 / 1,000 / 2,000 / 4,000 / 8,000 거래일
GBM	HistGradientBoosting, 트리 200개, 깊이 4, 학습률 0.05
DL	MLP, 은닉 32유닛 1층, ReLU, L2=1e-3, 조기종료
시드	42 (고정)

5 결과

5.1 회귀: 소데이터에서 GBM이 훨씬 안전하다

아래 표는 훈련 데이터 크기별 표본 밖 R^2 를 GBM, MLP, 그리고 훈련 구간 평균으로 예측하는 자명한 기준선과 함께 정리한 것이다. 세 값 모두 실측치다.

훈련 일수	R^2 (GBM)	R^2 (MLP)	R^2 (평균 기준선)
60	-0.074	-2.600	-0.003
125	-0.295	-0.347	-0.005
250	-0.120	-0.205	-0.009
500	-0.156	-0.208	-0.006
1,000	-0.168	-0.219	-0.003
2,000	-0.167	-0.228	-0.002
4,000	-0.131	-0.089	-0.001
8,000	-0.096	-0.076	-0.001

가장 눈에 띄는 결과는 훈련 60일 지점이다. MLP의 표본 밖 R^2 는 -2.60으로, 이는 모델이 평균으로만 예측하는 것보다 훨씬 나쁜 예측을 만들어냈다는 뜻이다. 반면 같은 조건에서 GBM은 -0.07로 상대적으로 완만하게 무너졌다. 두 모델의 격차는 이 지점에서 35배에 가깝다. 이는 극소데이터 구간에서 은닉층을 가진 신경망이 소수의 훈련 표본에 극단적으로 과적합하는 반면, 트리 앙상블은 분할 조건이 자연스럽게 보수적으로 제한되어 상대적으로 덜 무너진다는 통념과 일치한다.




그림 1: 훈련 데이터 크기에 따른 표본 밖 R^2

훈련 데이터가 늘어나면서 이 격차는 급격히 좁혀진다. 훈련 125일 지점에서는 이미 GBM(-0.295)과 MLP(-0.347)의 차이가 한 자릿수 범위로 줄었고, 흥미롭게도 훈련 4,000일과 8,000일 지점에서는 MLP(-0.089, -0.076)가 GBM(-0.131, -0.096)을 소폭 앞선다. 다만 두 모델 모두 이 구간에서도 평균 기준선(-0.001 근처)보다는 뚜렷하게 나쁘다는 점을 놓치면 안 된다. 즉 “MLP가 GBM을 이겼다”는 말은 정확히 “두 모델 다 평균으로 예측하는 것보다 못한 상태에서, 그나마 덜 나쁜 쪽이 MLP로 바뀌었다”는 뜻이지, 어느 모델이든 경제적으로 의미 있는 예측력을 얻었다는 뜻이 아니다.

5.2 분류: 방향 예측은 두 모델 다 동전 던지기에 가깝다

훈련 일수	정확도 (GBM)	정확도 (MLP)	다수클래스 기준선	AUC (GBM)	AUC (MLP)
60	0.470	0.496	0.490	0.480	0.483

훈련 일수	정확도 (GBM)	정확도 (MLP)	다수클래스 기준선	AUC (GBM)	AUC (MLP)
125	0.502	0.490	0.490	0.507	0.483
250	0.526	0.490	0.490	0.546	0.475
500	0.516	0.492	0.490	0.531	0.485
1,000	0.500	0.488	0.490	0.504	0.485
2,000	0.468	0.502	0.490	0.468	0.504
4,000	0.466	0.524	0.490	0.462	0.521
8,000	0.484	0.500	0.490	0.511	0.518

방향(상승/하락) 예측 정확도는 모든 훈련 크기, 모든 모델에서 46.6%~52.6% 범위에 머물렀고, 이는 다수클래스 기준선(항상 상승을 예측, 49.0%)과 통계적으로 구분하기 어려운 수준이다. ROC-AUC도 대부분 0.46~0.55 사이로, 0.5(무작위)에서 크게 벗어나지 않는다. 가장 높은 AUC는 훈련 250일 구간의 GBM(0.546)이었지만, 이 값 하나만으로 안정적인 예측력이 있다고 결론짓기는 이르다. 단일 평가 구간에서 얻은 값이기 때문이다(5절 한계 참고).




그림 2: 훈련 데이터 크기에 따른 방향 예측 ROC-AUC

그럼에도 회귀 결과와 같은 방향의 패턴이 분류에서도 관찰된다. 훈련 250~1,000일 구간에서는 GBM의 AUC(0.50~0.55)가 MLP(0.48~0.49)를 꾸준히 앞섰고, 훈련 2,000일을 넘어서면서 MLP의 AUC(0.50~0.52)가 GBM(0.46~0.51)을 따라잡거나 앞선다. 회귀와 분류 두 과제에서 같은 교차 패턴이 훈련 2,000~4,000일 사이에서 독립적으로 나타났다는 점은, 이 패턴이 우연한 잡음이라기보다 실제로 두 모델 계열이 데이터 규모에 반응하는 방식이 다르다는 신호일 가능성을 시사한다. 다만 이는 하나의 데이터셋, 하나의 평가 구간에서 나온 관찰이므로 일반화에는 신중해야 한다.

6 한계와 캐비엣

- 단일 평가 구간:** 위크포워드 검증에서 흔히 쓰는 여러 개의 겹치는 평가 구간 대신, 가장 최근 500거래일이라는 하나의 고정된 구간만 사용했다. 이는 계산량을 줄이고 실험을 단순하게 유지하기 위한 선택이지만, 그 대가로 결과가 이 특정 시기(2021년 중반~2023년 7월)의 시장 특성에 좌우될 수 있다. 여러 평가 구간에 걸친 평균과 분산은 이 논문에서 확인하지 않았다.
- 모델을 튜닝하지 않았다:** GBM과 MLP 모두 널리 쓰이는 기본값에 가까운 하이퍼파라미터로 고정했다. 각 모델을 정성껏 튜닝하면 (특히 MLP의 은닉층 구조, 정규화 강도, 학습률 스케줄) 결과가 달라질 수 있다. 이 논문의 목적은 “최선으로 튜닝된 두 모델의 대결”이 아니라 “합리적인 기본 설정에서 두 모델 계열이 보이는 경향성”을 관찰하는 것이었다.
- 특징이 단순하다:** 시차와 이동통계량만으로 구성된 30개 특징은 실무에서 쓰이는 정교한 팩터 모델(모멘텀, 밸류에이션, 품질, 거시경제 지표 결합 등)에 비해 소박하다. 더 풍부한 특징 집합에서는 두 모델의 상대적 우위가 달라질 수 있다.
- 회귀 결과의 절대 수준:** 모든 구간에서 R^2 가 음수이고 대체로 평균 기준선보다도 나쁘다는 사실은, 이 문제 설정(일단 팩터 시차 특징으로 다음날 시장초과수익 예측)에서 유의미한 선형 이상의 예측력을 찾지 못했다는 뜻이다. 이는 시장

효율성과 일치하는 결과이지 두 모델의 구현 결함이 아니다. 그러나 “GBM이 더 낫다/MLP가 더 낫다”는 이 논문의 비교는 어디까지나 “둘 다 거의 실패한 상태에서 어느 쪽이 덜 실패하는가”에 대한 비교임을 다시 한번 명시한다.

5. **투자자문 아님**: 본 연구는 방법론 연구이며 투자자문이 아니다. 특정 팩터, 특정 전략, 특정 모델의 실거래 수익성을 주장하지 않는다. 이 논문에서 사용한 데이터, 코드, 결과는 모두 연구·재현 목적이며 실제 자금 운용에 그대로 적용해서는 안 된다.

7 데이터와 재현

- **데이터**: Fama-French 3-팩터 일간 시계열(Mkt-RF, SMB, HML, RF). 원 출처는 Kenneth R. French 교수의 데이터 라이브러리(다트머스대 Tuck 경영대학원)이며, 이 데이터는 학술 연구 목적으로 널리 공개되어 있다. 이 실험에서는 원 서버 대신 GitHub 공개 저장소 vicmarti1/Fama-French-3-Factor에 미러링된 동일 CSV (F-F_Research_Data_Factors_daily.CSV)를 raw.githubusercontent.com을 통해 내려받았다. **주의**: 이 미러 저장소 자체에는 명시적 라이선스 파일이 없다. 데이터 내용 자체는 French 교수 라이브러리의 공개 학술 데이터이므로 연구 인용에는 문제가 없으나, 재현 시 가능하면 원 출처(Kenneth R. French Data Library)에서 직접 내려받는 것을 권장한다. 이 논문에서 미러를 사용한 것은 실험을 실행한 네트워크 환경이 French 교수의 원 서버(dartmouth.edu)에 직접 접근할 수 없었기 때문이며, 이는 결과의 신뢰성이 아니라 접근성의 문제였음을 명시한다.
- **데이터 성격**: 전부 **실측(real)**. 합성 데이터는 사용하지 않았다.
- **시드**: 42로 고정. 표준화, GBM, MLP 모두 동일 시드를 사용했다.
- **코드 재현 절차**: (1) 위 CSV를 내려받아 헤더 주석을 제거하고 날짜를 파싱한다. (2) Mkt-RF, SMB, HML 각각에 시차 1·2·3·5·10·20과 이동평균·이동변동성(창 5·10·20)을 계산해 특징을 만든다. (3) 가장 최근 500거래일을 평가 구간으로 고정하고, 그 직전 60~8,000일 구간을 훈련 데이터로 사용한다. (4) HistGradientBoostingRegressor/Classifier와 MLPRegressor/Classifier(scikit-learn)를 훈련 구간에서 학습하고 평가 구간에서 R^2 , 정확도, ROC-AUC를 계산한다. scikit-learn 버전 1.9, 시드 42.

8 참고문헌

1. Fama, E. F., French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3-56.
2. Fama, E. F., French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1-22.
3. Kenneth R. French Data Library, Tuck School of Business, Dartmouth College (Fama-French 팩터 데이터 원 출처).
4. Grinsztajn, L., Oyallon, E., Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems (NeurIPS)* 35.
5. Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5), 2223-2273.
6. Ke, G. et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems (NeurIPS)* 30.
7. Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
8. vicmarti1/Fama-French-3-Factor (GitHub 공개 저장소, Fama-French 3-팩터 일간 CSV 미러, 실험 실행 시점 접근).