

# 측정 가능한 신호·AI 지능

측정 규율로 본 2i 논문 라이브러리 (백서 v4)

2i

2026-07-29

## 초록

이 백서는 2i가 축적한 20편의 기술 논문을 하나의 논지로 묶는다. 미디어, 센싱, 보안, 산업, 엣지·AI 인프라, 금융이라는 여섯 산업군에 걸친 이 논문들은 겉모습이 전혀 다르다. 방송사가 궁금한 것은 짧은 오디오 조각이 카탈로그의 어느 곡인지이고, 요양 시설이 궁금한 것은 방 안에 사람이 있는지·넘어졌는지이며, 공장이 궁금한 것은 베어링의 진동이 정상 범위를 벗어났는지이고, 매장이나 순찰 현장이 궁금한 것은 데이터센터 GPU 없이도 비전-언어모델을 온프레미에서 빠르게 돌릴 수 있는지이며, 에이전트 플랫폼이 궁금한 것은 도구가 1000개를 넘을 때 검색이 정답을 상위에 올리는지, 쿼트 운용사가 궁금한 것은 백테스트 성과가 실전에서 재현되는지다. 그러나 이 여섯 질문은 모두 같은 밑단 구조로 환원된다. 신호(음파, 무선 전자기파, 진동, 이미지 토큰, 텍스트 질의, 시계열 수익률)에서 특징을 뽑고, 그 특징이 정상·등록·기지 상태에서 벗어났는지, 또는 그 처리 경로가 실제로 약속한 예산(정확도·오탐률·지연·메모리) 안에 있는지를 판단하는 하나의 로직이다. 산업마다 얼굴이 다를 뿐 몸은 같다.

# 목차

|                                |   |
|--------------------------------|---|
| 1 요약                           | 3 |
| 2 왜 측정 규율인가: 하나의 로직, 여섯 산업의 얼굴 | 3 |
| 3 게이지 방식: 측정에서 이관까지            | 4 |
| 4 논문 라이브러리: 20편, 여섯 산업군        | 4 |
| 4.1 미디어·콘텐츠ID                  | 4 |
| 4.2 센싱·WiFi-CSI                | 5 |
| 4.3 보안·RF지문                    | 5 |
| 4.4 산업·설비                      | 5 |
| 4.5 엣지·AI 인프라                  | 6 |
| 4.6 금융                         | 7 |
| 5 활용 지도와 성숙도 사다리               | 7 |
| 6 정직한 경계                       | 8 |
| 7 참고문헌                         | 9 |

## 1 요약

이 백서는 2i가 축적한 20편의 기술 논문을 하나의 논지로 묶는다. 미디어, 센싱, 보안, 산업, 엣지·AI 인프라, 금융이라는 여섯 산업군에 걸친 이 논문들은 겉모습이 전혀 다르다. 방송사가 궁금한 것은 짧은 오디오 조각이 카탈로그의 어느 곡인지이고, 요양 시설이 궁금한 것은 방 안에 사람이 있는지·넘어졌는지이며, 공장이 궁금한 것은 베어링의 진동이 정상 범위를 벗어났는지이고, 매장이나 순찰 현장이 궁금한 것은 데이터센터 GPU 없이도 비전-언어모델을 온프레임에서 빠르게 돌릴 수 있는지의, 에이전트 플랫폼이 궁금한 것은 도구가 1000개를 넘을 때 검색이 정답을 상위에 올리는지, 쿼트 운용사가 궁금한 것은 백테스트 성과가 실전에서 재현되는지다. 그러나 이 여섯 질문은 모두 같은 밑단 구조로 환원된다. 신호(음파, 무선 전자기파, 진동, 이미지 토큰, 텍스트 질의, 시계열 수익률)에서 특징을 뽑고, 그 특징이 정상·등록·기지 상태에서 벗어났는지, 또는 그 처리 경로가 실제로 약속한 예산(정확도·오탐률·지연·메모리) 안에 있는지를 판단하는 하나의 로직이다. 산업마다 얼굴이 다를 뿐 몸은 같다.

이 백서를 관통하는 진짜 논지는 산업 확장 그 자체가 아니라, 그 확장을 가능하게 하는 측정 규율이다. 사전선언, 셔플·대조 실험, 고정 오탐률 비교, 데이터 누수 차단, 음성 결과 공개라는 다섯 원칙이 도메인이 바뀌어도 형태만 바뀌 반복된다. 레이더가 반세기 전에 정립한 고정 오탐률(CFAR) 규율을 산업 무선 간섭 탐지와 금융 시장 국면 경보에 그대로 옮겼을 때 똑같이 0.1 퍼센트포인트 안팎의 정밀도로 목표를 맞춘다는 사실이, 하이브리드 검색이 늘 이긴다는 통념을 실측이 뒤집었다는 사실이, 그리고 이번 갱신에서 가장 선명하게 확인된 사실, 즉 같은 4비트 정밀도라도 계산 커널이 그 정밀도를 어떻게 다루느냐에 따라 디코드 속도가 190배까지 갈린다는 사실이 이 규율이 말뿐이 아니라는 증거다.

이번 v4 갱신의 핵심은 엣지 비전-언어모델(VLM) 양자화 논문이 닫힌 결론을 얻었다는 점이다. Apache-2.0 라이선스로 공개된 4B급 스트리밍 VLM microsoft/Mage-VL을 소비자용 Apple 실리콘(M4 Pro, 통합 메모리 48GB) 위에서 실측한 이 연구는, 지난 판에서 “양자화는 메모리를 줄이지만 오히려 속도를 늦춘다”는 반직관적 결과를 남겨두고 그 원인을 런타임 탓으로 추정만 했었다. 이번 갱신은 그 추정을 실측으로 닫았다. 같은 언어 백본을 융합 커널 런타임으로 옮기자 디코드 속도가 0.47 tok/s에서 89.67 tok/s로, 약 190배 뛰었다. 메모리와 속도는 서로 다른 축이며, 그 축을 실제로 함께 얻으려면 저비트 정밀도뿐 아니라 그 정밀도를 직접 계산하는 커널을 가진 런타임이 필요하다는 것이, 이 백서 전체가 반복해서 확인하는 측정 규율을 엣지 배치라는 새로운 무대에서 보여주는 가장 구체적인 사례다.

20편의 성숙도는 균일하지 않고, 이 백서는 그 불균일함을 감추지 않는다. 14편은 공개 실측 데이터 또는 실측 하드웨어 벤치마크에서 결과를 확인했고, 나머지는 합성 데이터, 혼합(실측+합성을 명시적으로 구분), 또는 방법론 실험 단계에 머물러 있다. 부정 결과, 즉 통념이 깨진 지점도 그대로 공개한다. 하이브리드 검색이 단일 검색기를 이기지 못한 결과, 오픈셋 RF 지문 인증이 실사용 오탐률에서 무너지는 결과, 딥러닝이 소데이터에서 부스팅에 크게 뒤지는 결과, 그리고 naive 양자화가 엣지 실리콘에서 오히려 느려지는 결과가 그렇다. 금융 세 편은 방법론 연구이며 투자자문이 아니다.

## 2 왜 측정 규율인가: 하나의 로직, 여섯 산업의 얼굴

AI 전환을 파는 회사는 대개 산업별로 다른 이야기를 만든다. 제조에는 비전 검사, 미디어에는 콘텐츠 인식을, 금융에는 예측 모델을, 엣지 배치에는 “더 작은 모델”을 판다. 이 접근은 틀리지 않지만 한 가지를 놓친다. 서로 다른 산업의 문제 중 상당수가 표면의 형태만 다를 뿐 수학적으로 같은 질문을 던진다는 사실이다. “이 소리가 우리가 아는 그 곡인가”(오디오 지문), “이 방에 지금 사람이 있는가, 넘어졌는가”(WiFi 감지), “이 신호를 보낸 것이 등록된 기기인가, 처음 보는 기기인가”(RF 지문), “이 베어링의 진동이 정상 범위를 벗어났는가”(예지보전), “이 모델을 4비트로 줄이면 정말 더 빨라지는가, 아니면 메모리만 줄고 느려지는가”(엣지 양자화), “이 사용자 요청에 맞는 도구가 검색 결과 상위에 있는가”(에이전트 검색), “이 백테스트 수익률이 우연보다 나은가”(금융)라는 서로 다른 문장이 전부 같은 수학 문제, 즉 신호에서 뽑은 특징이나 자원 사용 프로파일이 정상·등록·기지·약속 상태에서 벗어났는지를 판단하는 이상탐지·개체식별·오픈셋 분류·자원 예산 검증 문제다.

2i가 20편에 걸쳐 반복해서 확인한 것은 이 판단 로직 자체가 아니라, 이 로직이 정직하게 작동하는지를 재는 방법이다. 다섯 원칙으로 요약된다. 첫째, 무엇을 재고 무엇이 성공인지를 실험 전에 사전선언한다. 둘째, 실제 신호와 무작위로 섞은 대조군을 나란히 돌려 우연과 실력을 구분한다. 셋째, 정확도 하나만 보지 않고 목표 오탐률이나 목표 처리율을 고정한 채 그 지점에서의 성능을 비교한다. 넷째, 훈련·검증·평가 데이터가 시간이나 파티션 경계를 넘어 새는 경로를 차단한다. 다섯째, 통념과 다르거나 불리한 결과라도 그대로 공개한다. 이 다섯 원칙이 왜 필요한지는 이 백서에 실린 논문들이 직접 증명한다. WiFi-CSI 벤치마크의 공식 데이터 분할 자체가 데이터 누수였다는 사실이, 같은 RF 지문 모델의 AUROC가 평가 방식만 바뀌도 0.9994에서 0.2235까지 갈린다는 사실이, 룩어헤드 편향 하나가 백테스트 성과를 21배 부풀린다는 사실이, 그리고 같은 4비트 정밀도가 런타임에 따라 190배의 속도 차이를 낸다는 사실이 각각 넷째와 셋째, 첫째, 그리고 새로 이번 판에서 확인된 다섯째 원칙(불리해 보이는 결과도 먼저 공개하고 원인을 끝까지 추적한다)이 왜 있어야 하는지를 보여준다.

### 3 게이지 방식: 측정에서 이관까지

2i는 모든 프로젝트를 세 관문으로 나눈다. 측정 게이트는 공개 데이터나 합성 데이터, 또는 실제 소비자용 하드웨어로 방법이 통계적으로 유의한 신호를 잡거나 약속한 자원 예산을 지키는지 가장 저비용으로 확인하는 단계다. 실증 게이트는 그 방법을 고객사의 실제 데이터, 실제 오탐률 목표, 실제 하드웨어 예산으로 재검증하는 단계다. 이관 게이트는 실증을 통과한 방법을 운영 파이프라인에 넣고 성능을 지속적으로 감시하는 단계다. 각 관문은 다음 관문의 비용을 벌어야만 넘어간다. 측정 게이트에서 실패한 방법을 실증으로 밀어붙이지 않는다는 뜻이다.

엣지 VLM 양자화 논문은 이 게이지 방식이 어떻게 스스로 다음 단계를 만들어내는지 보여주는 좋은 예다. 지난 측정(양자화가 메모리는 줄이지만 속도는 늦춘다는 절반의 반박)은 측정 게이트 단계에서 나온 정직한 부정 결과였다. 그 결과를 숨기지 않고 공개하자, 다음 측정 게이트의 질문이 자연스럽게 정해졌다. “정밀도가 아니라 런타임이 원인이라면, 같은 정밀도를 융합 커널로 계산했을 때 정말 빨라지는가.” 이번 갱신은 바로 그 질문에 답한 두 번째 측정 게이트다. 결과가 190배 개선으로 나오면서, 다음 단계(커스텀 아키텍처 `mage_v1`을 MLX 비전-언어 프레임워크에 포팅하는 실증 게이트 작업)의 사업적 근거가 구체적인 숫자로 확보됐다. 측정 게이트가 실증 게이트의 비용을 벌여준 사례다.

이 백서에 실린 20편은 이 세 관문 중 대부분 측정 게이트를 통과했고, 일부는 이미 실증 데이터로 재검증됐다. 오디오 콘텐츠 지문식별과 장비 없는 WiFi 감지, 설비 진동 예지보전, RadioML 기반 엣지 최적화, 그리고 이번에 실측으로 닫힌 엣지 VLM 양자화까지는 공개 실측 데이터나 실제 소비자용 하드웨어에서 이미 실증 단계에 근접했다. 반대로 백테스트 규율, 레짐 탐지 CFAR, 에이전트 검색, RF 지문 프로브포인트 절제 실험은 아직 측정 게이트 단계, 즉 합성 데이터로 방법론이 유의미하다는 것만 확인한 단계다. 이 구분을 감추면 고객에게 실증된 것과 아이디어를 같은 확신으로 팔게 된다. 2i는 그렇게 팔지 않는다.

세 관문을 나누는 이유는 비용이다. 측정 게이트는 공개 데이터셋이나 로컬에서 생성한 합성 데이터, 또는 개발자의 노트북 한 대로 하루에서 며칠 안에 끝난다. 실증 게이트는 고객사의 실제 신호나 실제 배치 하드웨어를 받아 재측정해야 하므로 며칠에서 몇 주가 걸리고, 이관 게이트는 운영 환경에 상시 모니터링을 붙이는 지속 비용이다. 측정 게이트에서 통계적으로 우연과 구별되지 않는 방법을, 즉 셔플 대조군과 실제 신호의 성능 차이가 없거나 약속한 자원 예산을 지키지 못하는 방법을 실증으로 넘기면 고객의 시간과 비용을 낭비한다. 그래서 2i의 게이지 방식은 관문마다 “다음 단계로 넘어갈 근거가 있는가”를 먼저 묻고, 근거가 없으면 그 자리에서 멈춘다.

### 4 논문 라이브러리: 20편, 여섯 산업군

20편 중 19편은 아래 여섯 산업군으로 뚜렷하게 나뉜다. 나머지 한 편, 고전 신호처리 및 부스팅과 딥러닝을 여섯 개 신호 과제에 걸쳐 맞춘 결정 지도 논문은 이 산업군을 가로질러 “언제 고전 방법이, 언제 딥러닝이 이기는가”라는 4절의 활용 지도 질문에 직접 답하는 종합 논문이라 별도로 다룬다.




그림 1: 산업군별 실증 단계 논문 비율

미디어와 센싱은 두 편 모두 공개 실측 데이터로 결과를 확인했다. 보안은 네 편 중 세 편이 실측이고 한 편(프로브포인트 절제)만 합성 장비군을 썼다. 엣지·AI 인프라는 여섯 편 중 다섯 편이 실측이며, 이번에 새로 실측으로 닫힌 엣지 VLM 양자화 논문이 그 비율을 끌어올렸다. 금융은 세 편 중 한 편(팩터 수익 예측)만 실측이고, 나머지 두 편(백테스트 규율, 레짐 탐지)은 방법론 실험이라는 사실을 이 비율이 그대로 드러낸다.

#### 4.1 미디어·콘텐츠ID

두 편은 오디오 지문식별을 실측으로 확장했다. 첫 논문은 GTZAN 999개 트랙에서 클린 10초 클립 top-1 정확도 95.0%, 강한 잡음(SNR -5dB)에서도 72.5%를 유지하고, MP3 128~32kbps 압축에서는 96.7%까지 버틴다는 것을 확인했다. 시간

정렬을 하지 않는 나이트 매칭은 같은 조건에서 SNR 0dB 기준 87.5%에서 2.0%로 무너진다. FMA-small로 카탈로그를 500곡에서 7,996곡까지 16배 늘려도 클린 정확도는 99.5%에서 99.0%로 거의 그대로였고, 나이트 베이스라인은 37.5%에서 17.0%로 붕괴했다. 이 실측이 드러낸 진짜 병목은 정확도가 아니라 메모리였다. 곡당 약 0.889MB, 100만곡 규모 단일 디렉터리로 환산하면 약 868GB에 이른다.

두 번째 논문은 이 메모리 병목을 정면으로 다룬다. 해시 키 기준 정확한 파티션으로 인덱스를 샤딩하면 1개에서 32개 샤드로 늘려도 정확도가 정확히 보존된다(150개 질의 중 140개, 32배 전 구간에서 동일). 그러나 이 논문은 샤딩이 문제를 완전히 풀지 않는다는 사실도 숨기지 않는다. 샤드당 고정 프로세스 오버헤드(약 180MB)가 샤드 수만큼 중복되기 때문에, 100만곡 규모에서 샤드 용량을 6,000곡으로 잡으면 전체 합계 메모리는 모놀리식 추정치의 1.18배, 용량을 1,000곡으로 더 잘게 자르면 2.17배까지 늘어난다. 게다가 32-샤드 상태에서도 한 번의 질의는 여전히 샤드의 99.98%를 건드린다. 라우팅은 샤드당 데이터량을 줄일 뿐 질의가 접촉하는 샤드 수는 줄이지 못한다.

## 4.2 센싱·WiFi-CSI

장비 없는 WiFi-CSI는 UT-HAR·OPERAnet 실측 데이터에서 7종 활동 분류 정확도 95.2%(매크로 F1 92.7%), 낙상 탐지 AUROC 0.990(임계 0.5 기준 정밀도 97.6%, 재현율 91.1%), 재실 판별 AUROC 1.000을 기록했다. 다만 이 연구는 기술적 타당성을 보여주는 연구 데모이며 임상 인증을 받은 의료기기가 아니라는 점을 스스로 명시한다.

크로스 환경 보정 논문은 이 성과의 이면을 드러낸다. UT-HAR의 공식 train/val/test 분할로 측정하면 정확도가 94.7~94.9%로 거의 떨어지지 않는데, 이는 슬라이딩 윈도우가 겹치는 데이터 누수 때문이라는 것을 밝히고, 비지도로 유도한 검증 가능한 도메인 분할을 새로 구성해 정확도가 55.08%까지, 즉 같은 도메인 상한(92.37%) 대비 37.29퍼센트포인트까지 무너지는 진짜 도메인 이동을 재측정했다. 클래스당 50개, 총 350개(원본 학습셋의 9.7%)의 라벨만 추가하면 정확도가 84.92%까지 올라 이 격차의 80%를 되찾는다. 공식 분할로 측정했던 팀은 같은 보정 기법을 적용해도 회복률이 -4.4%에서 +0.6%에 그쳤는데, 애초에 꽤 만한 진짜 격차가 없었기 때문이다.

## 4.3 보안·RF지문

네 편은 이 백서에서 가장 정직한 경계를 보여준다. 오픈셋 RF 지문 검증은 분리성이 실재한다는 것을 확인했다. K=1 AUROC는 데이터셋에 따라 0.52(WIDEFT, 거의 우연 수준)에서 0.87(INRIA)까지 갈리고, 접근제어가 실제로 요구하는 낮은 오탐률에서는 인증률이 무너진다. INRIA 기준 TAR@FAR=1%는 20.8%지만 TAR@FAR=0.1%에서는 2.9%로 떨어지고, WiSig 크로스-수신기 조건에서는 TAR@FAR=0.1%가 0.5%까지 내려간다. 패킷 10개를 융합하면(K=10) INRIA TAR@FAR=1%가 91.4%까지 오르지만, 같은 조건에서도 FAR=0.1%로 기준을 좁히면 61.6%로 다시 떨어진다.

재현 가능한 평가 프로토콜 논문은 이 숫자들이 왜 이렇게 흩어지는지를 설명한다. 같은 임베딩, 같은 모델이라도 평가 프로토콜에 따라 AUROC가 최적 조합 0.9994에서 완전 분리된 등록·평가 기기와 미등록 신원 공격자를 가정한 엄격한 프로토콜에서는 0.2235까지 갈린다. 닫힌 집합 분류 정확도가 82.0%로 인상적으로 보이는 실험이 같은 데이터에서 TAR@FAR=0.1%는 2.9%에 불과하다는 사실도 확인했다. 저자들은 이를 “모델의 능력이 아니라 프로토콜의 관대함을 재고 있는 것”이라고 직접 표현한다. 프로브포인트 절제 연구는 이 지문이 수신 체인의 어디서 살고 죽는지를 파고들었다. 등가 오류율(EER, 낮을수록 좋음)은 원시 IQ 단계에서 0.307로 가장 낮았지만, 통신 성능을 높이는 표준 처리(주파수 오차 보정, 매칭 필터, 동기화)를 지날수록 0.489, 0.499로 우연 수준까지 지워졌다. 드론 오픈셋 탐지는 낮은 패킷 융합 조건(K=1)에서 고전 방법이 딥러닝보다 5.7배 높은 미지 거부율(0.424 대 0.074)을 보였지만, K=20을 넘으면 딥러닝이 근소하게 앞선다(0.875 대 0.917). 2i는 이 네 편의 결론을 합쳐 RF 지문 인증을 단일 판정 게이트가 아니라 리스크 스코어 계층으로 재정의한다. 다만 이 네 편이 쓴 공개 데이터의 라이선스는 균일하지 않다. WiSig는 CC-BY-NC-SA(비상업·연구 목적 한정)이고 INRIA는 CC-BY 4.0(상업 이용 가능)이라, 상업적 제품화를 위한 재검증은 후자 계열 데이터로 다시 해야 한다.

## 4.4 산업·설비

설비 진동·음향 예지보전 논문은 진동 데이터(CWRU 표준 베어링 결함 데이터셋)를 실측으로, 음향 데이터를 절차적 합성으로 명시해 각 결과를 실측·합성으로 구분해 표기했다. 진동 측은 클린 조건에서 물리 특징 기반 분류와 단순 베이스라인이 모두 1.000으로 동률이었지만, SNR -5dB의 강한 잡음에서는 물리 특징이 0.636, 단순 베이스라인이 0.186으로 3.4배 차이가 났다. 음향 측은 클린 0.903 대 0.312, SNR -5dB에서 0.492 대 0.302로 같은 패턴을 보였지만, 이 논문은 “가장 크고 가리기 어려운 한계는 음향 결과가 전부 합성이라는 점”이라고 스스로 명시하고, 다음 단계로 실제 산업 소음 데이터셋(MIMI, CC-BY-4.0)으로의 검증을 예고한다.

산업 무선 간섭 탐지 논문은 레이더의 CFAR 규율을 그대로 옮겨, 목표 오탐률 5%에 대해 CA-CFAR 방식이 실현 오탐률 5.29%를 냈고, 전체 탐지율(Pd) 98.0%, 슬라이스 위치 추정 정확도는 무작위 기준선 16.7% 대비 98.2%를 기록했다. 다만 이 논문도

정직한 한계를 그대로 남긴다. 전체 송신 전력이 가장 높은 재밍 신호가 오히려 마스킹 때문에 탐지율이 92.9%로 가장 낮았고, 공간 위치추정 오차는 그늘 효과가 없는 조건에서 기준선(18.49m) 대비 3.7배 개선된 4.98m였지만, 그늘 효과가 커지면 (12dB) 18.47m까지 나빠져 기준선과 거의 같아지는 비단조적인 결과를 있는 그대로 보고했다. 이 논문의 모든 수치는 실제 무선 하드웨어가 아니라 물리 법칙 기반 합성 시뮬레이션에서 나왔다는 점도 명시한다.

## 4.5 엣지·AI 인프라

여섯 편은 운영 질문에 실측으로 답한다. 이 군집에서 가장 최근에 달린, 그리고 이번 v4 갱신의 대표 사례는 엣지 실리콘에서의 스트리밍 VLM 양자화 연구다. 대상은 Apache-2.0 라이선스로 공개된 4B급 스트리밍 비전-언어모델 microsoft/Mage-VL(Mage-ViT 비전 인코더 + Qwen3-4B 언어 백본, 총 47.42억 파라미터)이며, 측정은 데이터센터 GPU가 아니라 소비자용 Apple M4 Pro(통합 메모리 48GB) 한 대에서 이뤄졌다. 지난 측정에서는 transformers + Metal(MPS) 스택으로 bf16(9.49GB, 13.01 tok/s), INT8(5.86GB, 2.31 tok/s), INT4(4.15GB, 0.47 tok/s) 세 정밀도를 실측했는데, 메모리는 정확히 기대대로 줄었지만(bf16 대비 INT8 -38%, INT4 -56%) 디코드 속도는 정밀도가 낮아질수록 오히려 느려지는 반직관적 결과가 나왔다. 원인으로 지목된 것은 하드웨어가 아니라 커널이었다. optimum-quant의 weight-only 양자화는 가중치를 저비트로 저장하지만 행렬곱을 할 때는 그 값을 다시 bf16으로 역양자화해서 계산하고, Apple Metal에는 이 저비트 표현을 직접 계산하는 융합 커널이 없어 역양자화 비용이 토큰마다 반복 청구된다는 가설이었다.

이번 갱신은 그 가설을 실측으로 달았다. 같은 Apple M4 Pro에서 같은 언어 백본(Qwen3-4B-Instruct-2507, Mage-VL의 디코드 속도를 지배하는 부분)을 mlx-lm의 융합 커널 INT4 경로로 돌리자 디코드 89.67 tok/s, 프롬프트 처리 71.06 tok/s, 피크 메모리 2.46GB가 나왔다. 같은 4비트 정밀도인 quanto INT4의 0.47 tok/s와 나란히 놓으면 비율은 약 190.8배다. 메모리도 절대값 기준으로 더 작았다. 이는 축이 어긋난 것이 아니라, 잘못된 런타임이 한 축의 이득(메모리 절감)을 다른 축의 빗(디코드 지연)으로 전환시키고 있었을 뿐이며, 저비트 표현을 직접 계산하는 올바른 런타임을 고르면 그 전환 자체가 일어나지 않는다는 것을 이번 데이터가 보여준다. “정밀도를 낮추면 항상 빠르다”는 가정도, “정밀도를 낮추면 늦어질 수 있다”는 반박도 둘 다 불완전했다. 실제 결론은 메모리와 속도가 서로 다른 축이고, 그 축을 함께 얻으려면 정밀도 선택과 런타임 선택을 별도로 검증해야 한다는 것이다.




그림 2: 엣지 VLM 디코드 속도: 같은 INT4

정직하게 밝혀야 할 경계가 세 가지 있다. 첫째, 89.67 tok/s는 Mage-VL 전체가 아니라 언어 백본만 MLX로 격리해 측정된 값이다. 디코드 루프는 언어모델 레이어만 반복 통과하므로(비전 인코더는 프리필 단계에서 한 번만 관여) 이 격리 측정이 전체 VLM의 디코드 속도를 지배하는 요인을 정확히 짚어내지만, Mage-ViT 비전 인코더와 StreamMind 이벤트 게이트를 포함한 Mage-VL 전체가 MLX에서 이 속도로 엔드투엔드로 도는 것은 아직 아니다. 커스텀 아키텍처 mage\_vl이 mlx-vlm 메인라인에 등록되어 있지 않아, 커뮤니티 제작 Mage-VL INT4 체크포인트를 mlx-vlm으로 직접 로드하는 시도는 이번에도 실패했다 (“Model type mage\_vl not supported”). 둘째, 메모리 비교도 완전한 동급은 아니다. quanto INT4의 4.15GB는 비전 인코더까지 포함한 전체 모델이고, MLX의 2.46GB는 언어 백본 단독이다. 셋째, 스트리밍 비디오의 빠른 경로(DCVC-RT 신경 코덱)는 여전히 CUDA에 묶여 있어 이번 측정의 스코프 밖이다. 이 경계들을 건너내면 남는 것은 구체적이고 검증 가능한 다음 작업, 즉 mage\_vl을 mlx-vlm(또는 동급의 MLX 비전-언어 프레임워크)에 포팅해 비전 인코더까지 포함한 전체 파이프라인을 같은 런타임으로 재측정하는 실증 게이트다.

나머지 다섯 편은 이 교훈, 즉 자원 예산은 정밀도·크기·지연이라는 서로 다른 축으로 나뉘어 있고 그 축을 함께 재야 한다는 원칙을 각기 다른 각도에서 반복해서 확인한다. INT8 양자화 논문은 RadioML 변조분류 모델에서 FP32 정확도 93.18%가 정적 PTQ(보정만 적용) 양자화에서는 61.91%(-31.27퍼센트포인트) 까지 떨어지지만, QAT(15에폭 미세조정)는 91.45%(-1.73퍼센트포인트)로 PTQ 손실의 94.5%를 되찾는다는 것을 확인했다. 두 방식 모두 모델 크기는 70.3% 줄었고, QAT가 지연시간에서도 근소하게 더 빠르다(0.155ms 대 0.158ms, p50). 엣지 예산 귀속 논문은 Apple M3 Pro 단일 코어에서 40 MSPS를 약속하는 스펙이 조용한 환경에서도 실측 0.19배(7.59 MSPS)에 그치고, 부하가 걸리면 0.09배(3.5 MSPS)까지

떨어진다는 것을 스테이지별로 증명했다. 상위 3개 스테이지가 예산의 85.28%를 차지하며, 코드 최적화만으로는 목표 스펙의 최대 33.1%(4코어 동시 사용 가정)에 그친다.

표형 부스팅 대 딥러닝 논문은 539개 표본에서 LightGBM이 원시 IQ 딥러닝을 17.4퍼센트포인트 차(85.5% 대 68.1%)로 이긴다는 것을 재확인했다. 표본을 2,000개로 늘리면 격차는 36.0퍼센트포인트에서 21.3퍼센트포인트로 줄어들고, 이 논문은 두 지점만으로 5,000·9,900 표본에서 곡선이 실제로 교차할지 단정할 수 없다는 것도 솔직히 밝힌다. 캘리브레이션 논문은 판정 점수의 신뢰도 오차(ECE)를 등분위 회귀로 0.0446에서 0.0188(-57.9%)까지 낮추면서도 판별력(AUROC 0.9374→0.93633)은 거의 그대로 지킬 수 있다는 것을 보였다. 보정 전 신뢰도 0.80~0.87 구간의 실제 정확도는 0.6441에 불과했지만, 등분위 보정 후 같은 구간의 정확도는 0.8986으로 올라갔다.

여섯 번째 논문, 대규모 스킵 코퍼스 라우팅은 통념을 정면으로 뒤집는다. 도구 2,000개짜리 완전히 공개된 합성 코퍼스에서 순수 어휘 매칭(BM25), 형태 유사 검색(문자 n-gram TF-IDF), 돌을 상호순위융합(RRF)한 하이브리드를 실측으로 맞세운 결과, Recall@1에서 하이브리드(0.508)는 BM25(0.508)와 동률이었으나 TF-IDF(0.517)보다 근소하게 낮았다. Recall@5에서는 BM25 0.742, TF-IDF 0.700에 비해 하이브리드가 오히려 가장 낮은 0.683을 기록했다. 더 중요한 결과는 정답이 없는 질의에 대한 기권 성능이다. 정답이 있는 질의의 약 90%가 통과하도록 보정한 점수 게이트를 하드 네거티브 41개에 적용했을 때, 올바르게 기권한 비율은 BM25 26.8%, TF-IDF 31.7%였지만 하이브리드는 12.2%에 그쳤다. 이 논문은 “하이브리드가 최고 성능 단일 검색기를 압도적으로 앞선 경우는 한 번도 없었다”는 결과를 그대로 공개한다.

## 4.6 금융

금융 세 편은 방법론 연구이며 투자자문이 아니다. 백테스트 규율 논문은 성과를 부풀리는 세 가지 함정을 합성 시계열로 실측했다. 록어헤드 편향은 같은 전략을 하루만 늦춰도 사라지는 평균 샤프 21.1(오류)에서 0.069(정상)로 무너뜨렸고, 생존편향은 5년간 약 20.3%가 상장폐지되는 유니버스에서 전체 대비 생존자만 남긴 유니버스의 연간복리성장률(CAGR)을 3.8퍼센트포인트 부풀렸다(10.1% 대 13.9%). 다중검정 보정 없이는 시도 횟수(N)가 5에서 2,000으로 늘어날 때 인샘플 최고 샤프가 0.34에서 0.90으로 오르는 동안 아웃오브샘플 샤프는 여전히 잡음 범위(-0.07~0.17)에 머물렀고, 나이브 유의성 검정의 거짓 양성률은 6.7%에서 46.7%까지 치솟았다. 반면 본페로니 보정과 축소 샤프 비율은 시도 횟수와 무관하게 거짓 양성률 0%를 유지했다.

팩터 수익 예측 논문은 이 백서에서 처음으로 실측 시장 데이터(Fama-French 3-팩터 일간, 1926~2023년 25,543거래일)를 썼다. 훈련 표본이 60일뿐일 때 얇은 신경망의 표본 밖 결정계수( $R^2$ )는 -2.60까지 붕괴했지만, 그래디언트 부스팅은 -0.07로 약 35배 완만하게 무너졌다. 훈련 표본이 4,000~8,000일로 늘어나면 신경망( $R^2$  -0.09~-0.08)이 부스팅(-0.13~-0.10)을 근소하게 앞섰지만, 두 모델 모두 훈련 구간 평균으로만 예측하는 자명한 기준선(약 -0.001)보다는 여전히 뚜렷하게 나뉘었다. 방향 예측 정확도는 훈련 크기와 무관하게 46.6~52.6%에 머물러 다수클래스 기준선(49.0%)과 사실상 구분되지 않았다. 이 논문의 결론은 시장을 이기는 모델을 찾았다는 것이 아니라, 일간 팩터 시차 특징만으로는 어느 모델도 시장 효율성을 뚫는 안정적인 신호를 찾지 못했다는 것이다. 다만 극소데이터에서는 부스팅이 훨씬 안전한 기본값이라는 실무적 결론은 남는다.

레짐 탐지 논문은 이 백서의 산업 무선 CFAR와 정확히 같은 규율을 시장 국면 경보로 옮겼다. 합성 마르코프 전환 변동성 과정에서, 위기 구간이 섞인 표본의 90분위수로 정한 나이브 임계값은 목표 오탐률 10%를 노렸지만 실현 오탐률은 4.53%에 그쳐 5.47퍼센트포인트(약 54.7%) 빚나갔다. 반면 평균 구간만의 통계량으로 임계값을 계산하는 CFAR 방식은 목표 1%, 5%, 10% 세 수준 모두에서 1.02%, 5.02%, 10.02%로 오차 0.02퍼센트포인트 안팎의 정밀도를 냈다. 목표 오탐률을 1%에서 10%로 높이면 평균 탐지 지연이 18.46스텝에서 4.86스텝으로 짧아지고 미탐지율은 40.9%에서 0%로 떨어지는 트레이드오프도 함께 측정했다. 이 실험은 CFAR 임계값 계산에 참 레짐 레이블을 그대로 썼다는 상한선 실험이라는 것과, 실제 시장 데이터를 전혀 쓰지 않았다는 것을 스스로 명시한다.

## 5 활용 지도와 성숙도 사다리

여섯 산업군을 가로지르는 결정 지도 논문은 이 백서의 나머지 19편이 따로따로 보여준 패턴, 즉 “언제 고전 방법이 이기고 언제 딥러닝이 이기는가”를 정면으로 다룬다. 변조분류(RadioML, SNR 6dB)에서는 고전 방법이 딥러닝을 85.5% 대 68.1%로 이겼고, 고정 오탐률 간섭 탐지에서는 고전 방법이 조건이 변해도 오탐률을 지켰지만 딥러닝의 오탐률은 1.0까지 치솟았다. 반대로 신호 분리에서는 딥러닝(Conv-TasNet 계열) 신호대잡음 개선치가 +3.01dB였던 반면 고전 방법(ICA)은 -14.25dB로 아무것도 하지 않는 것보다 더 나빴고, RF 지문 융합(K=50)에서는 딥러닝이 AUROC 0.9994로 고전 방법(0.945)을 앞섰다. 승자는 과제마다 다르고, 이 논문은 그 사실을 하나의 알고리즘을 파는 대신 과제별 결정 지도로 공개한다. 옛지 VLM 양자화 논문이 보여준 “정밀도와 런타임을 분리해서 재라”는 교훈도 이 결정 지도의 확장판으로 읽을 수 있다. 승자는 알고리즘 계열뿐 아니라 계산 스택의 어느 층에서도 갈릴 수 있다.

이 지도를 근거로 2는 여섯 산업군의 판단 로직이 스마트빌딩, 에너지, 물류, 통신·스펙트럼, 온프레임 엣지 AI 패키징까지 어떻게 확장되는지를 실증(이미 측정), 확장(자연스러운 확장, 재검증 필요), 연구(방법은 있으나 검증 전), 개념(아이디어 단계) 네

단계로 정직하게 구분한다. 합성 데이터에만 의존하는 방법은 연구 또는 개념 단계로만 표기하며, 실측 데이터로 검증되기 전에는 확장이나 실증으로 올리지 않는다.

이 네 단계 사다리는 낙관을 위한 장식이 아니라 영업 대화에서 실제로 쓰는 경계선이다. 실증 단계의 방법은 지금 유료 파일럿이나 고객사 데이터 재검증 PoC를 시작할 수 있다는 뜻이고, 확장 단계는 같은 판단 로직이 다른 신호 종류로 옮겨갈 개연성은 높지만 그 도메인의 실측 데이터로 다시 재보기 전까지는 숫자를 약속하지 않는다는 뜻이며, 연구와 개념 단계는 방법론이나 아이디어는 있으나 아직 팔 수 있는 성능 수치가 없다는 뜻이다. 합성 데이터에서만 검증된 방법을 확장이나 실증으로 올리지 않는 것이 이 사다리의 가장 중요한 규칙이다. 옛지 VLM 양자화 논문은 이번 갱신으로 언어 백본 디코드 부분만 실증 단계에 올라섰고, 비전 인코더를 포함한 전체 파이프라인은 여전히 확장 단계(포팅이 끝나야 재검증 가능)에 머문다는 것을 이 사다리가 정확히 표시한다.

같은 CFAR 규율이 산업 무선과 시장 국면이라는 서로 다른 얼굴에 각각 적용된 결과를 나란히 놓으면, 측정 규율이 도메인을 가로질러 얼마나 일관되게 작동하는지가 드러난다.

| 확장 영역               | 근거 논문                     | 성숙도                    |
|---------------------|---------------------------|------------------------|
| 방송·음원 콘텐츠ID 운영 확장   | 오디오 지문식별, 샤딩 인덱스          | 실증                     |
| 재실·낙상 감지 상업화        | 장비 없는 WiFi-CSI, 크로스 환경 보정 | 실증(라벨 예산 필요)           |
| 접근제어용 RF 지문 인증      | 오픈셋 검증 4편                 | 연구(리스크 스코어 단계)         |
| 설비 예지보전 확장(음향 포함)   | 진동·음향 PdM                 | 실증(진동)·연구(음향)          |
| 매장·순찰용 오픈프레임 옛지 VLM | 옛지 VLM 양자화(신규)            | 실증(언어 백본)·확장(전체 파이프라인) |
| 에이전트 플랫폼 도구 검색      | 스킬 검색 라우팅                 | 연구                     |
| 스마트빌딩 재실·에너지 최적화    | WiFi-CSI + 산업 CFAR        | 확장                     |
| 통신·스펙트럼 간섭 관리       | 산업 CFAR, RF 지문 결정 지도      | 확장                     |
| 물류·설비 다중센서 이상탐지     | 캘리브레이션, PdM               | 확장                     |
| 시장 리스크 경보 체계        | 백테스트 규율, 레짐 CFAR, 팩터 GBM  | 연구(투자자문 아님)            |
|                     | 대DL                       |                        |

## 6 정직한 경계

20편 중 14편은 공개 실측 데이터 또는 실제 하드웨어 벤치마크(GTZAN, FMA-small, UT-HAR, OPERAnet, WiSig, INRIA, WIDEFT, DroneRF, CardRF, CWRU, RadioML2016.10a, Fama-French 3-팩터 데이터, 그리고 Apple M4 Pro·M3 Pro 실측)에서 결과를 확인했다. 나머지 6편, 즉 백테스트 규율, 레짐 탐지 CFAR, 대규모 스킬 검색, RF 지문 프로브포인트 절제, 산업 간섭 탐지는 합성 데이터나 방법론 실험이고, 설비 예지보전과 결정 지도 논문은 실측과 합성이 섞인 혼합 결과이며, 이 백서는 이 구분을 각 절에서 명시했다. 합성 데이터를 쓴 이유도 숨기지 않는다. 참 레짐 레이블이나 참 값을 알아야만 방법의 상한선을 짤 수 있는 경우, 사전학습 임베딩 모델을 내려받을 수 없는 네트워크 환경에서 대리 지표를 정직하게 표기해야 하는 경우, 실제 마이크 녹음을 아직 확보하지 못한 경우가 그 이유다.

데이터·모델 라이선스도 균일하지 않다. WiSig는 CC-BY-NC-SA로 비상업·연구 목적에 한정되고, INRIA·DroneRF·OPERAnet·FMA-small은 CC-BY 계열로 상업 이용이 가능하다. GTZAN은 원저작자의 정식 라이선스가 확인되지 않아 이 백서의 근거 논문들은 GTZAN을 재배포 없이 로컬 검증에만 사용했다. 이번에 새로 추가된 옛지 VLM 양자화 논문의 대상 모델 microsoft/Mage-VL은 Apache-2.0으로, 연구 데모가 아니라 상업적으로 패키징해 배치할 수 있는 라이선스라는 점을 이 논문이 스스로 강조한다. 상업적 제품화 논의에는 이 구분이 그대로 적용된다.

금융 세 편(백테스트 규율, 팩터 수익 예측, 레짐 탐지)은 방법론 연구이며 투자자문이 아니다. 특정 전략이나 자산배분의 실거래 수익성을 주장하지 않으며, 신호처리 백서 전체가 강조하는 측정 규율이 다른 도메인에 이식된 사례로만 읽어주시기 바란다. 센싱 두 편도 기술적 타당성을 보여주는 연구 데모이며 임상 인증을 받은 의료기기가 아니라는 점을 다시 밝힌다. 보안 네 편은 분리성이 실재한다는 것과 접근제어에 필요한 인증률이 아직 부족하다는 것을 동시에 말한다. 옛지 VLM 양자화 논문은 상업적으로 배치 가능한 모델을 다루지만, 89.67 tok/s라는 대표 수치는 언어 백본 단독 측정이며 비전 인코더를 포함한 전체 파이프라인의 실측치가 아니라는 경계를 반드시 함께 인용해야 한다. 2가 판매하는 것은 산업별 완제품 알고리즘이 아니라, 이 경계를 스스로 긋고 그 경계 안에서 정직하게 측정하는 방법이다.

이 경계 감각은 앞으로 추가될 논문에도 그대로 적용된다. 새 논문이 실증 데이터를 확보하면 해당 절의 성숙도 표기를 올리고, 반대로 재현 과정에서 문제가 발견되면 성숙도를 내리거나 결과를 철회한다. 백서 자체도 논문 라이브러리가 바뀔 때마다 이 다섯 절의 틀 위에서 다시 쓰인다.



전문은 아래 PDF 버튼에서 국문·영문으로 내려받을 수 있다. 20편의 원본 논문은 각각 독립된 페이지에도 게시되어 있으며, 이 백서의 3장 각 절에서 전문 PDF로 바로 연결된다.

## 7 참고문헌

- 오디오 콘텐츠ID at scale (GTZAN, FMA-small)
- 100만곡 규모 샤딩 인덱스 (GTZAN + 합성 용량 확장)
- 장비 없는 WiFi-CSI 재실·낙상 감지 (UT-HAR, OPERAnet)
- WiFi-CSI 환경 이동과 소량 보정 (UT-HAR)
- 오픈셋 RF 지문 검증 (WiSig, INRIA, WIDEFT)
- 재현 가능한 오픈셋 평가 프로토콜
- RF 지문 프로브포인트 절제 연구 (합성 장비군)
- 드론 RF 탐지의 오픈셋 현실 (DroneRF, CardRF)
- 고전 특징 기반 설비 예지보전 (CWRU 실측, 음향 합성)
- 고정 오탐률 산업 이상·간섭 탐지 (합성 시뮬레이션)
- 고전 DSP+GBM 대 딥러닝: 신호 과제 결정 지도 (RadioML, DroneRF/CardRF 등 혼합)
- 신호 특징 위에서 테이블러 부스팅이 딥러닝을 이기는 조건 (RadioML)
- 신호 모델 엣지 배치: INT8 QAT 대 PTQ (RadioML)
- 엣지 신호처리 예산 귀속 (실측 하드웨어 벤치마크)
- 신호 판단의 캘리브레이션된 리스크-스코어 (DroneRF)
- 대규모 스킵 코퍼스 라우팅: BM25 대 하이브리드 검색 (합성 도구 코퍼스)
- 엣지 실리콘에서 스트리밍 VLM 양자화 (microsoft/Mage-VL, Apple M4 Pro 실측)
- 백테스트 규율: 성과를 부풀리는 세 가지 함정 (합성 시계열)
- 팩터 수익 예측: 부스팅 vs 딥러닝 (Fama-French 실측)
- 고정 오탐률 레짐 탐지 (합성 마르코프 전환 과정)