

오픈셋 RF 지문 검증: 분리성과 동작점 격차

지문 분리성은 실재하나 하드 인증 동작점은 아직 멀다, 실측 경계 연구

2i

2026-07-29

초록

RF 지문(무선기기 하드웨어 임퍼펙션 기반 개체 식별)은 동일 모델의 기기라도 아날로그 송신 체인의 제조 공차가 파형에 남기는 미세한 흔적으로 개체를 구분한다. 이 흔적을 오픈셋 검증 문제로 다루면 - 등록된 정당 기기와, 학습·보정 어디에도 등장하지 않은 미등록 기기를 구분하는 문제 - 분리성 자체는 실재한다. 공개 데이터셋 세 종(WiSig, INRIA PLA, WIDEFT)에 걸쳐 우리가 실측한 단일 패킷($K=1$) AUROC는 0.70~0.87 구간으로, 우연(0.5)을 뚜렷이 상회한다. 그러나 하드 인증(접근제어 게이트가 실제로 판정을 내려야 하는 낮은 오탐률 지점, $TAR@FAR$)으로 넘어가면 이 신호는 붕괴한다. INRIA(CC BY 4.0, 상업 이용 가능)에서 $FAR=0.1\%$ 일 때 TAR 는 2.9%에 불과했고, WiSig 교차수신기 조건에서는 0.5%까지 떨어졌다. 라이선스가 갈리는 두 데이터셋(WiSig는 비상업 전용 CC BY-NC-SA, INRIA는 상업 이용 가능 CC BY)에 걸쳐 같은 격차가 재현됐다는 사실은, 이 결과가 특정 데이터셋의 특이성이 아니라 과제 자체의 성질임을 시사한다. 10패킷 융합($K=10$)은 이 격차를 크게 줄이지만 완전히 닫지는 못했고($FAR=0.1\%$ 에서 TAR 61.6%), SSL 사전학습은 저라벨 조건에서 AUROC를 소폭 끌어올렸으나 그와 동시에 가장 엄격한 동작점의 TAR 는 오히려 낮아졌다. 결론적으로 오늘의 공개 데이터·공개 방법으로는 RF 지문을 하드 액세스 게이트로 세우는 것은 근거가 부족하다. 정직하게 팔 수 있는 형태는 단일 판정 게이트가 아니라, 다른 신호와 함께 융합되는 연속값 리스크 스코어 계층이다.

목차

1 요약	3
2 배경	3
3 평가 방법론	3
4 데이터와 설정	4
5 결과	5
6 합의	6
7 데이터와 재현	7
8 참고문헌	7

1 요약

RF 지문(무선기기 하드웨어 임퍼펙션 기반 개체 식별)은 동일 모델의 기기라도 아날로그 송신 체인의 제조 공차가 파형에 남기는 미세한 흔적으로 개체를 구분한다. 이 흔적을 오픈셋 검증 문제로 다루면 - 등록된 정당 기기와, 학습·보정 어디에도 등장하지 않은 미등록 기기를 구분하는 문제 - 분리성 자체는 실재한다. 공개 데이터셋 세 종(WiSig, INRIA PLA, WIDEFT)에 걸쳐 우리가 실측한 단일 패킷($K=1$) AUROC는 0.70~0.87 구간으로, 우연(0.5)을 뚜렷이 상회한다. 그러나 하드 인증(접근제어 게이트가 실제로 판정을 내려야 하는 낮은 오탐률 지점, TAR@FAR)으로 넘어가면 이 신호는 붕괴한다. INRIA(CC BY 4.0, 상업 이용 가능)에서 FAR=0.1%일 때 TAR는 2.9%에 불과했고, WiSig 교차수신기 조건에서는 0.5%까지 떨어졌다. 라이선스가 갈리는 두 데이터셋(WiSig는 비상업 전용 CC BY-NC-SA, INRIA는 상업 이용 가능 CC BY)에 걸쳐 같은 격차가 재현됐다는 사실은, 이 결과가 특정 데이터셋의 특이성이 아니라 과제 자체의 성질임을 시사한다. 10패킷 융합($K=10$)은 이 격차를 크게 줄이지만 완전히 닫지는 못했다(FAR=0.1%에서 TAR 61.6%), SSL 사전학습은 저라벨 조건에서 AUROC를 소폭 끌어올렸으나 그와 동시에 가장 엄격한 동작점의 TAR는 오히려 낮아졌다. 결론적으로 오늘의 공개 데이터·공개 방법으로는 RF 지문을 하드 액세스 게이트로 세우는 것은 근거가 부족하다. 정직하게 팔 수 있는 형태는 단일 판정 게이트가 아니라, 다른 신호와 함께 융합되는 연속값 리스크 스코어 계층이다.

2 배경

무선기기는 동일한 설계·동일한 부품 목록으로 제조돼도 완전히 동일하게 동작하지 않는다. 발진기 위상잡음, ADC/DAC 비선형성, IQ 불균형, 전력증폭기 응답 곡선 같은 아날로그 단의 제조 공차가 개체마다 조금씩 다르고, 이 차이는 방사되는 파형에 재현 가능한 흔적으로 남는다. 이 흔적을 특징으로 뽑아 “이 신호를 보낸 것이 어느 기기인가”를 판정하는 것이 RF 지문(RF fingerprinting, 종종 RFFI로 축약)이다.

이 기술이 매력적인 이유는 명확하다. 암호 키나 인증서를 추가로 심을 필요 없이, 물리계층 신호 자체에서 신원 신호를 뽑아낸다. 크리덴셜은 훔치거나 복제할 수 있지만 아날로그 하드웨어의 제조 공차는 그렇게 하기 훨씬 어렵다는 직관이 있다. 그래서 공장 무선망의 미등록 기기 탐지, 산업 IoT 게이트웨이 인증, 심지어 의료기기 네트워크의 접근제어까지 다양한 제안이 나온다. 문제는 이 제안들이 거의 예외 없이 “닫힌 목록 안에서 누가 보냈는가를 맞히는 정확도”(closed-set 분류)를 근거로 인용된다는 점이다. 그러나 접근제어가 실제로 마주하는 질문은 다르다. 등록된 목록에 전혀 없는 기기가 등록된 신원을 사칭하려 할 때, 그 시도를 낮은 오탐률로 걸러낼 수 있는가라는 오픈셋 검증 질문이다. 닫힌 목록 정확도가 높다는 사실은 이 질문에 대해 아무것도 보장하지 않는다. 이 논문은 그 간극을 정면으로, 그리고 정직하게 측정한다.

우리가 이 문제를 다시 여는 이유는 문헌에 보고되는 헤드라인 수치들이 대체로 사후 선택의 산물이기 때문이다. 여러 패킷을 융합하고, 여러 스코어링 방식 중 최고를 고르고, 사전에 등록하지 않은 조합을 결과가 나온 뒤에 선택하는 방식으로 얻어진 AUROC 0.999 같은 수치는 실제 배포 조건(패킷 하나가 도착하는 순간 판정해야 하는 단일 결정, 사전에 고정된 임계값)과는 다른 것을 재고 있다. 이 논문은 그 사후 선택을 걷어내고, 사전에 고정된 단일 패킷($K=1$) 조건과 사전등록한 다중 패킷($K=10$) 조건만으로 무엇이 실제로 남는지를 보인다.

3 평가 방법론

오픈셋 검증(open-set verification)은 두 단계로 구성된다. 먼저 알려진 기기 집합(known)의 일부로 등록·학습·임계값 보정을 하고, 나머지는 완전히 미등록 상태로 남긴다(unknown). 그 다음 테스트 시점에 모델이 한 번도 보지 못한 미등록 기기의 신호를 등록된 신원 중 하나로 잘못 받아들이는지, 반대로 정당한 등록 기기의 신호를 올바르게 받아들이는지를 함께 측정한다. 이 설계에서 핵심은 미등록 기기가 임계값 보정에도, 모델 학습에도 전혀 등장하지 않아야 한다는 점이다. 미등록 기기의 데이터가 조금이라도 보정 과정에 스며들면 성능이 낙관적으로 부풀려진다. 우리가 측정한 모든 실험은 임계값을 등록된 기기의 검증(validation) 분할에서만 보정했고, 미등록 기기는 테스트 시점에만 처음 노출시켰다.

이 설계에서 쓰는 지표는 세 가지다. EER(Equal Error Rate)은 오인가율과 오거부율이 같아지는 지점의 오류율로, 전체 분리성을 한 숫자로 요약한다. AUROC는 모든 임계값에 걸친 판별력을 적분한 값으로, 임계값을 아직 정하지 않은 상태에서의 분리성을 나타낸다. 그러나 이 두 지표는 접근제어가 실제로 운용하는 지점을 직접 말해주지 않는다. 실제 배포는 하나의 고정된 오탐률 목표(FAR, false accept rate)를 정하고, 그 지점에서 정당한 기기를 얼마나 통과시키는지(TAR, true accept rate)를 봐야 한다. AUROC가 높아도 TAR@FAR가 낮을 수 있고, 이 논문의 핵심 발견이 정확히 이 지점에 있다. 그래서 우리는 모든 결과를 AUROC/EER과 함께 TAR@FAR=10%, 1%, 0.1%의 세 지점으로 병기한다. FAR=0.1%는 통상적인 하드 접근제어가

요구하는 수준에 가깝고, 여기서의 TAR가 사실상 “이 시스템을 게이트로 켜면 정당한 사용자가 몇 퍼센트나 거부당하는가”를 뜻한다.

작은 기기 수(known 8~24대)에서 나오는 점추정치는 표본 변동성이 크다. 우리는 기기 단위 부트스트랩(기기를 리샘플링 단위로 삼는 신뢰구간 추정)으로 이 불확실성을 명시했다. 예를 들어 INRIA K=1의 AUROC 점추정치 0.868은 95% 신뢰구간이 [0.810, 0.932]로 상당히 넓다. 이는 계산 오류가 아니라 8대라는 소규모 표본이 갖는 진짜 불확실성이며, 이 논문의 결론(하드 인증 미달)은 이 신뢰구간 안에서 성립한다는 점을 함께 밝힌다.

패킷 수(K)도 방법론적으로 중요하다. K=1은 패킷 하나가 도착한 순간 즉시 판정해야 하는, 지연이 허용되지 않는 실제 접근제어 시나리오에 해당한다. K를 10, 50으로 올리면 여러 패킷의 점수를 평균해 분리성이 크게 개선되지만, 그만큼 여러 전송을 누적할 시간이 필요해지고 공격자 관점에서도 판정 기준이 예측 가능해진다. 우리는 K=1을 주 결과로, 사전에 K값을 고정한 K=10을 참고 결과로 함께 보고한다. K=50 이상의 다중 스코어러 최적 조합 같은 사후 선택 수치는 이 논문의 결과가 아니며, 오직 문헌상의 참고 맥락으로만 인용한다.

이 사후 선택 문제는 추상적인 우려가 아니다. 같은 계열의 공개 문헌 결과에 대한 별도의 누수(leakage) 점검에서, K=50 융합이 6가지 K값과 3종 스코어러의 조합 18개 중 held-out 분할에서 사후에 가장 좋은 것을 고른 결과였다는 사실이 드러났다. 즉 “사전에 이 조합을 쓰겠다”고 선언한 뒤 측정한 수치가 아니라, 결과를 본 뒤 가장 그림이 좋은 조합을 역으로 선택한 수치다. 이런 수치는 실제 배포에서 재현되지 않을 가능성이 크다. 배포 시점에는 결과를 미리 알 수 없으므로 최적 조합을 사후에 고를 방법이 없기 때문이다. 이 논문이 K=1과 사전등록 K=10만을 헤드라인으로 삼는 이유가 여기에 있다.

4 데이터와 설정

이 연구는 공개 데이터셋 세 종을 쓴다. 데이터셋을 하나로 좁히지 않은 이유는 라이선스와 캡처 조건이 다른 두 데이터셋에서 같은 결과가 재현되는지를 직접 확인하기 위해서다.

데이터셋	라이선스	기기 구성	캡처 조건
WiSig (Hanna, Karunaratne, Cabric, 2022)	CC BY-NC-SA 4.0 (비상업 전용)	알려진 기기 20대, 실측 무선 캡처	다중 수신기·다중 일자, 교차수신기 분할
INRIA PLA (Zenodo 레코드 18268648)	CC BY 4.0 (상업 이용 가능)	알려진 기기 8대 + 미등록 4대, 상용 IoT 송신기 12대	단일 BladeRF 수신기, 단일 세션, 2.4GHz ISM
WIDEFT (Zenodo 레코드 4116383)	CC BY 4.0 (상업 이용 가능)	알려진 소비자 기기 모델 24종 + 미등록 14종	단일 USRP B210 수신기, 실측 WiFi 캡처

WiSig는 이 분야에서 가장 널리 쓰이는 벤치마크지만 라이선스가 CC BY-NC-SA로 비상업 연구 검증에만 쓸 수 있다. 상업적으로 판매 가능한 결론을 내리려면 상업 이용이 허용된 데이터에서 같은 실험을 다시 해야 한다. 그래서 우리는 INRIA PLA(CC BY 4.0)에서 같은 오픈셋 검증 프로토콜을 독립적으로 재현했다. 이 재측정은 단순한 라이선스 문제 회피가 아니라, “격차가 WiSig라는 특정 데이터셋의 소음이나 기기 구성 때문이었는가”를 검증하는 실험이기도 했다. 결과는 아래에서 보듯 격차가 달하지 않았다 - INRIA가 WiSig보다 오히려 K=1 AUROC가 더 높았음에도(0.868 대 0.729), TAR@FAR=0.1%는 여전히 3% 미만이었다.

WIDEFT는 소비자 전자기기(휴대폰·노트북·라우터·스트리밍박스)의 WiFi RF 지문 데이터셋이다. 동일 PHY 계층(WiFi 2.4GHz)을 쓰는 기기 모집단에서 등록 기기를 식별하고 미등록 기기를 거부하는 과제의 프록시로는 타당하지만, 의료기기 자체의 RF 방사 특성이나 규제 준수를 증명하지 않는다는 점을 분명히 해둔다. 여기서는 딥러닝 임베딩이 아니라 28차원 고전 DSP 특징(IQ 불균형, CFO, 순시 주파수/위상/진폭 통계, 고차 큐물런트, 스펙트럴 밴드)과 LightGBM/Mahalanobis 분류기를 썼다 - 학습형 임베딩이 없어도 같은 실패 양상이 나타나는지 보기 위한, 방법론 자체를 바꾼 대조 실험이다.

학습형 파이프라인의 백본은 화자 검증에서 널리 쓰이는 ECAPA-TDNN을 원시 IQ 신호에 맞게 적용했고, ArcFace 스타일의 각도 마진 손실과 모멘텀 대조 학습(MoCo)을 결합해 임베딩을 학습시켰다. 검증 시점에는 등록된 기기의 임베딩 갤러리와 질의 신호 임베딩 사이의 거리를 점수로 써서 AUROC·EER·TAR@FAR를 계산했다. 별도로, 저라벨 조건에서 자기지도학습(SSL) 사전학습이 도움이 되는지도 확인했다. 마스킹된 IQ 구간을 복원하도록 사전학습한 뒤 같은 검증 과제로 미세조정하는 방식으로, 무작위 초기화 대비 3개 시드에서 비교했다.

5 결과

아래 표는 이 연구에서 사전에 고정한 조건들의 실측치다. 모든 수치는 등록 기기 검증 분할에서만 보정한 임계값을 썼고, 미등록 기기 데이터는 테스트 시점에만 노출됐다.

조건	K	AUROC	EER	TAR@FAR=10%	TAR@FAR=1%	TAR@FAR=0.1%
WiSig, 교차수신기, 무작위 초기화 (3시드 평균)	1	0.729	0.334	-	12.1%	4.2%
WiSig, 교차수신기, masked-IQ SSL 사전학습 (3시드 평균)	1	0.752	0.314	-	10.9%	2.6%
WiSig, 교차수신기, 무작위 초기화, 사전등록 융합	10	0.953	0.116	-	33.9%*	14.5%*
INRIA PLA, 동일수신기 · 동일세션	1	0.868	0.215	63.0%	20.8%	2.9%
INRIA PLA, 동일수신기 · 동일세션, 사전등록 융합	10	0.997	0.024	99.95%	91.4%	61.6%
WiSig, 교차수신기, 별도 도메인적응 실험	1	0.695	0.344	-	-	0.5%
WIDEFT 소비자기기 proxy, 고전 DSP+ 거리기반	1	0.519	0.480	-	0.7%	0.1%

* K=10 WiSig 열은 3시드 중 대표 시드 값. INRIA와 달리 사전등록 K=10 계열의 seed 평균 집계는 별도 진행하지 않았다.

세 가지가 눈에 띈다. 첫째, K=1 AUROC는 세 데이터셋 · 두 방법론(학습형 임베딩, 고전 DSP)에 걸쳐 0.52(WIDEFT, 거의 우연)에서 0.87(INRIA)까지 흩어지지만, 어느 조건에서도 TAR@FAR=0.1%가 5%를 넘지 못했다. AUROC가 가장 높았던 INRIA조차 이 지점에서 TAR 2.9%다. 이는 “AUROC가 높다”와 “접근제어로 쓸 수 있다”가 별개의 명제라는 뜻이다.




그림 1: 분리성 대 동작점 격차

둘째, 다중 패킷 융합($K=10$)은 이 격차를 크게 줄이지만 완전히 닫지는 못한다. INRIA에서 $K=10$ 은 $FAR=1\%$ 일 때 TAR 91.4% 까지 올라 접근제어 문턱에 가까워지지만, FAR 를 0.1%로 더 조이면 TAR 가 61.6%로 다시 떨어진다. 즉 열 개의 패킷을 누적해도 가장 엄격한 오탐률 목표에서는 여전히 정당한 사용자 3명 중 1명 이상을 거부하게 된다. FAR 을 조일수록 TAR 가 얼마나 빠르게 무너지는지를 보면 이 비선형성이 뚜렷하다.




그림 2: FAR가 엄격해질수록 TAR가 붕괴한다

셋째, SSL 사전학습의 효과는 지표에 따라 방향이 갈렸다. masked-IQ 재구성으로 사전학습한 임베딩은 무작위 초기화 대비 $K=1$ AUROC를 0.729에서 0.752로, +0.0235만큼 끌어올렸다(3시드 평균, 개선폭이 3시드 모두에서 일관됨). 그러나 같은 조건에서 $TAR@FAR=1\%$ 는 12.1%에서 10.9%로, $TAR@FAR=0.1\%$ 는 4.2%에서 2.6%로 오히려 낮아졌다. 세 시드 모두에서 두 FAR 지점 모두 같은 방향(SSL이 더 낮음)으로 움직였다는 점에서 이는 우연한 노이즈로 보기 어렵다. AUROC는 전체 임계값 구간의 판별력을 적분하기 때문에, 완화된 임계값 구간에서의 개선이 가장 엄격한 임계값 구간에서의 악화를 가릴 수 있다. 이 결과는 “AUROC가 올랐다”를 “인증 성능이 좋아졌다”로 곧바로 치환하는 것이 위험하다는 이 논문의 핵심 주장을 SSL이라는 구체적 개입에서도 재확인한다.




그림 3: SSL 사전학습: AUROC는 오르나 엄격한 동작점의 TAR는 오히려 낮아짐

넷째, 우리가 시도한 두 가지 표준 완화책도 격차를 닫지 못했다. 그래디언트 반전(GRL) 기반 도메인적응은 끄는 쪽이 켜는 쪽보다 오히려 AUROC가 근소하게 낮았고(0.737 대 0.727), 소스-프리 대조 적응 역시 $K=1$ AUROC를 0.030 낮췄다. 즉 이 격차는 손실 함수나 스코어링 방식의 사소한 개선으로 메워지는 종류가 아니라, 특징 공간 자체에 걸린 병목으로 보인다.

6 합의

가장 직접적인 합의는 명확하다. 오늘의 공개 데이터와 공개 방법(학습형 메트릭 임베딩, 고전 DSP+거리기반 분류, SSL 사전 학습, 도메인적응)으로 단일 결정 하드 인증 게이트($K=1$, FAR 목표 1% 이하)를 세우는 것은 근거가 부족하다. 이 결론은 하나의 데이터셋이나 하나의 백본에 국한되지 않는다. 비상업 라이선스 데이터(WiSig)와 상업 이용 가능 데이터(INRIA) 양쪽에서, 동일 수신기 조건과 교차수신기 조건 양쪽에서, 학습형 파이프라인과 고전 DSP 파이프라인 양쪽에서 같은 실패 양상이 재현됐다.

다중 패킷 융합은 유용한 완화책이지만 만능은 아니다. $K=10$ 사전등록 융합은 완화된 오탐률 목표($FAR=1\%$)에서는 실용적인 수준에 근접하지만, 여러 패킷을 누적할 시간이 필요해 즉시 판정이 필요한 시나리오에는 맞지 않고, 가장 엄격한 목표($FAR=0.1\%$)에서는 여전히 미달이다. 문헌에서 종종 인용되는 $K=50$, 다중 스코어러 최적 조합의 AUROC 0.999에 가까운 수치는 이 논문이 재현한 결과가 아니며, 사전등록 없이 사후에 최적 조합을 고른 것으로 알려져 있어 실제 배포 조건과 다른 것을 재는 수치로 취급해야 한다.

이 결과가 함의하는 정직한 제품 형태는 하드 게이트가 아니라 리스크 스코어 계층이다. RF 지문 판정을 연속값 확신도(confidence)로 출력하고, 이를 네트워크 계층 신원, 행동 기반선, 지오펜싱 같은 다른 신호와 함께 융합 플랫폼에 입력해 최종 판정을 내리게 하는 구조다. 이 구조에서는 중간 정도의 오탐률이 허용된다. 다른 신호나 사람이 경계 사례를 추가로 판단하기 때문이다. 이는 단일 판정 게이트보다 덜 극적이지만, 지금 측정된 근거로 정직하게 팔 수 있는 유일한 형태다.

이 결론이 뒤집힐 수 있는 조건도 명시해둔다. 등록 기기군을 좁고 동질적으로(예: 동일 제조사·동일 조달 배치) 구성하면 벤더 간 이질성이 줄어 분리성이 개선될 가능성이 있다. 실제 IoT 캡처처럼 지금과 다른 PHY·환경에서 재측정하면 결과가 달라질 수 있다. 우리가 측정한 것은 오늘의 공개 데이터·공개 방법이 보이는 결과이며, 이 결론이 모든 RF 지문 응용을 영구히 배제한다고 주장하지 않는다. 다만 지금 시점에서 하드 인증을 판매하려는 제안은 이 논문이 보인 수준의 실측 근거를 함께 제시해야 한다고 본다.

리스크 스코어 계층으로 제품을 구성할 때 실무적으로 따라오는 결정도 짚어둔다. 첫째, 확신도의 소비자는 최종 사용자가 아니라 융합 플랫폼이어야 한다. RF 지문 점수 하나만으로 접근을 거부하면 이 논문이 측정한 오탐·오거부율이 그대로 사용자 경험에 노출된다. 둘째, 운영 중 재보정이 필요하다. 수신기·환경·기기 모집단이 바뀌면 임계값도 다시 등록 검증 분할로 보정해야 하며, 배포 후 실제 미등록 시도 데이터로 몰래 재보정하면 이 논문이 경고한 누수가 그대로 재현된다. 셋째, 이 스코어는 단독 방어선이 아니라 심층방어(defense in depth)의 한 겹으로 설계해야 한다. 낮은 확신도를 받은 시도는 차단이 아니라 추가 검증(예: 2차 인증 요청, 관리자 알림)으로 이어지는 것이 지금 근거 수준에 맞는 설계다.

마지막으로 이 결과가 측정하지 않은 것을 분명히 한다. 교차 일자·교차 환경에 걸친 드리프트, 능동적 스푸핑 공격 하에서의 강건성, 그리고 지금보다 훨씬 큰 등록 기기군(50대 이상)에서의 성능은 이 논문의 범위 밖이다. 등록 기기군이 커지면 어떤 고정 임계값에서든 우연히 충돌하는 미등록 기기가 늘어날 가능성이 높으므로, 여기 보고된 수치는 오히려 실제 대규모 배치보다 낙관적인 쪽에 가깝다고 보는 것이 안전하다.

7 데이터와 재현

이 연구가 쓴 세 데이터셋은 모두 공개돼 있다. WiSig(Hanna, Karunaratne, Cabric, 2022)는 CC BY-NC-SA 4.0으로, 비상업 연구 검증에만 쓸 수 있다. INRIA PLA(Zenodo 레코드 18268648)와 WIDEFT(Zenodo 레코드 4116383)는 모두 CC BY 4.0으로 상업적 이용이 가능하다. 평가 프로토콜은 다음을 고정했다. 임계값은 등록 기기의 검증 분할에서만 보정하고 미등록 기기 데이터는 테스트 시점에만 노출한다. 알려진 기기와 미등록 기기의 분할은 기기 단위로 완전히 분리한다. AUROC·EER과 함께 항상 $TAR@FAR=10\%/1\%/0.1\%$ 의 세 지점을 병기한다. K값은 $K=1$ 을 주 결과로, 사전에 고정한 K값을 참고 결과로만 함께 보고하며, 결과를 본 뒤 K나 스코어러를 바꿔 최적 조합을 다시 고르지 않는다. 작은 기기 수에서 나오는 점추정치에는 기기 단위 부트스트랩 신뢰구간을 함께 표기한다. 평가 스크립트와 정확한 하이퍼파라미터는 요청 시 제공한다.

8 참고문헌

1. Hanna, S., Karunaratne, S., & Cabric, D. (2022). WiSig: A Large-Scale WiFi Signal Dataset for Receiver and Channel Agnostic RF Fingerprinting. Dataset. License: CC BY-NC-SA 4.0.
2. INRIA PLA Physical-Layer Authentication Dataset. Zenodo record 18268648. License: CC BY 4.0.
3. WIDEFT Dataset. Zenodo record 4116383. License: CC BY 4.0.
4. Desplanques, B., Thienpondt, J., & Demuynck, K. (2020). ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification. Interspeech 2020.
5. He, K., Fan, H., Wu, Y., Xie, S., & Girshick, R. (2020). Momentum Contrast for Unsupervised Visual Representation Learning. CVPR 2020.
6. Deng, J., Guo, J., Xue, N., & Zafeiriou, S. (2019). ArcFace: Additive Angular Margin Loss for Deep Face Recognition. CVPR 2019.