

재현 가능한 오픈셋 평가 프로토콜

왜 closed-set 정확도로 인증을 주장하면 안 되는가

2i

2026-07-29

초록

무선기기 RF 지문(RFFI)처럼 물리계층 신호로 개체를 식별하는 과제는 최근 몇 년 사이 ‘딥러닝이 고전 신호처리를 이겼다’는 인상적인 수치들과 함께 소개되는 일이 많아졌다. 이 논문은 그 수치들을 그대로 받아들이기 전에 반드시 확인해야 할 질문 하나를 다룬다. 그 수치가 답하는 질문이 실제로 우리가 물으려는 질문과 같은가라는 것이다. 우리는 공개 데이터셋 계보에서 실측한 하나의 구체적 사례로 이 질문의 무게를 보인다. 같은 모델 계보가 사후에 가장 좋은 조합을 골라 보고한 조건에서는 AUROC 0.9994라는, 거의 완벽에 가까운 수치를 낸다. 그러나 인증이 실제로 판정을 내려야 하는 지표, 즉 낮은 오탐률 지점에서의 정당 사용자 통과율(TAR@FAR)로 같은 계보의 같은 패킷 융합 조건을 다시 보면 0.8765로 내려가고, 등록되지 않은 임의의 신원으로 통과를 시도하는 최악조건 공격자와 보정용 장치·평가용 장치를 완전히 분리한 엄격한 프로토콜로 재측정하면 0.2235까지 떨어진다. 세 숫자는 모두 실측치이며 날조되지 않았다. 그런데도 서로 다른 결론을 가리킨다. 이 격차를 만드는 것은 모델의 성능이 아니라 평가 프로토콜의 엄격도다.

목차

1 요약	3
2 왜 평가 프로토콜이 결과를 좌우하나	3
3 검증과 분류는 다른 문제다	3
4 순환성과 누수의 함정: 같은 신호, 다른 진실	4
5 권장 프로토콜: A/B/C	5
6 한계	8
7 재현	8
8 참고문헌	8

1 요약

무선기기 RF 지문(RFFI)처럼 물리계층 신호로 개체를 식별하는 과제는 최근 몇 년 사이 “딥러닝이 고전 신호처리를 이겼다”는 인상적인 수치들과 함께 소개되는 일이 많아졌다. 이 논문은 그 수치들을 그대로 받아들이기 전에 반드시 확인해야 할 질문 하나를 다룬다. 그 수치가 답하는 질문이 실제로 우리가 물으려는 질문과 같은가라는 것이다. 우리는 공개 데이터셋 계보에서 실측한 하나의 구체적 사례로 이 질문의 무게를 보인다. 같은 모델 계보가 사후에 가장 좋은 조합을 골라 보고한 조건에서는 AUROC 0.9994라는, 거의 완벽에 가까운 수치를 낸다. 그러나 인증이 실제로 판정을 내려야 하는 지표, 즉 낮은 오탐률 지점에서의 정당 사용자 통과율(TAR@FAR)로 같은 계보의 같은 패킷 융합 조건을 다시 보면 0.8765로 내려가고, 등록되지 않은 임의의 신원으로 통과를 시도하는 최악조건 공격자와 보정용 장치·평가용 장치를 완전히 분리한 엄격한 프로토콜로 재측정하면 0.2235까지 떨어진다. 세 숫자는 모두 실측치이며 날조되지 않았다. 그런데도 서로 다른 결론을 가리킨다. 이 격차를 만드는 것은 모델의 성능이 아니라 평가 프로토콜의 엄격도다.

이 논문은 세 가지를 한다. 먼저 검증(verification)과 분류(classification)가 왜 다른 문제이고 서로 다른 지표를 요구하는지 정의한다. 둘째, closed-set 정확도가 인증 능력의 증거로 오독되는 구체적 실패 양상을 순환성(circularity)과 정보 누수(leakage)라는 두 경로로 나눠 실측 사례와 함께 보인다. 셋째, 세 단계 난이도(A/B/C)로 구성된 재현 가능한 평가 프로토콜을 제시한다. 이 프로토콜은 물리적 송신기·수신기·캡처일자·환경·패킷군이라는 독립된 분리 축을 명시적으로 관리하고, 등록 목록에 없는 임의 신원으로 접근을 시도하는 최악조건 1:N 공격자 시나리오를 표준 평가 대상으로 삼으며, 신뢰구간을 패킷이 아니라 물리적 장치·세션 단위로 재추정할 것을 요구한다. 결론은 단순하다. 모델의 등급이나 아키텍처의 우열이 아니라 그 모델을 어떤 프로토콜로 평가했는가가, 보고된 숫자를 믿어도 되는지를 결정한다.

2 왜 평가 프로토콜이 결과를 좌우하나

RF 지문(RF fingerprinting, RFFI)은 발진기 위상잡음, ADC/DAC 비선형성, 전력증폭기 응답 곡선처럼 아날로그 송신 체인의 제조 공차가 방사되는 파형에 남기는 재현 가능한 흔적으로 개체를 구분하는 기술이다. 크리덴셜을 추가로 심지 않고 물리계층 신호만으로 신원 신호를 얻을 수 있다는 매력 때문에 공장 무선망의 미등록 기기 탐지부터 산업 IoT 게이트웨이 인증까지 다양한 곳에 제안된다. 문제는 이 제안 대부분이 근거로 인용하는 수치가 “단한 목록 안에서 어느 기기가 보냈는가를 맞히는 정확도”라는 점이다. 그러나 접근제어가 실제로 마주하는 질문은 다르다. 등록 목록에 전혀 없는 기기가 등록된 신원을 사칭하려 할 때, 그 시도를 낮은 오탐률로 걸러낼 수 있는가라는 오픈셋 검증 질문이다. 단한 목록에서의 정확도가 높다는 사실은 이 질문에 대해 아무것도 보장하지 않는다.

이 간극이 추상적인 우려가 아님을 보이는 것이 이 논문의 출발점이다. 같은 학습형 임베딩 계보를 세 번, 서로 다른 프로토콜로 측정하면 서로 다른 결론에 도달한다. 첫 번째 측정은 50개 패킷을 융합하고 여섯 가지 패킷 수와 세 가지 스코어링 방식의 조합 18가지 가운데 평가셋에서 사후에 가장 좋은 결과를 고른 것으로, AUROC 0.9994를 낸다. 이 조합이 사전에 선언된 것이 아니라 결과를 본 뒤 역으로 선택됐다는 점, 그리고 캡처일자가 등록·평가 양쪽에 모두 섞여 있었다는 점을 감안하면, 이 수치가 재는 것은 “50개의 독립된 인증 결정”이 아니라 “신호대잡음비가 높아진 단일 캡처 세션 내부 매칭”일 가능성이 크다. 두 번째 측정은 같은 조합에서 인증이 실제로 요구하는 지표인 TAR@FAR=1e-3을 계산한 것으로, 사후선택은 유지한 채 0.8765가 나온다. 세 번째 측정은 등록되지 않은 임의 신원으로 접근을 시도하는 공격자를 가정하고, 임계값 보정에 쓰는 장치와 평가에 쓰는 장치를 완전히 분리한 뒤 같은 패킷 융합 조건(K=50)에서 다시 TAR@FAR=1e-3을 계산한 것으로, 0.2235로 떨어진다. 첫 번째 수치가 보고된 그대로 인용되면 이 시스템은 거의 완벽한 인증기처럼 보인다. 세 번째 수치가 말해주는 진실은 같은 오탐률 목표에서 정당한 사용자 5명 중 4명 가까이가 거부된다는 것이다.

이 세 수치는 서로 다른 지표(AUROC와 TAR@FAR)를 재고 있으므로 하나의 직선으로 이어 “모델이 이만큼 나빠졌다”고 말하는 것은 정확하지 않다. 이 논문이 강조하려는 지점은 그것과 다르다. 첫 번째 수치가 두 번째, 세 번째와 같은 좌표계에 있지 않다는 것을 모르고 그대로 인증 능력의 증거로 인용하는 것 자체가 오독이라는 점이다. 뒤에서 이 세 수치를 다시 다루면서, 왜 서로 다른 좌표계인지, 그리고 어떤 프로토콜이 실제 배포 조건에 대응하는지를 구체적으로 짚는다.

3 검증과 분류는 다른 문제다

분류(classification)는 “이 신호를 보낸 것이 등록된 N개 기기 중 어느 것인가”를 맞히는 과제다. 정답 후보가 이미 유한하고 알려져 있다는 것이 이 과제의 핵심 전제다. 검증(verification)은 다른 질문을 던진다. “이 신호가 주장하는 신원 X가 실제로 X인가, 아니면 등록되지 않은 다른 무엇인가”라는 이진 판정이며, 후보 목록에 전혀 없는 입력이 항상 함께 들어온다는 것이 전제다.

접근제어·인증·불법기기 탐지는 모두 검증 문제다. 분류 정확도가 아무리 높아도, 등록되지 않은 입력을 등록된 신원으로 잘못 받아들이는 비율을 재지 않으면 접근제어에 쓸 수 있는지 알 수 없다.

이 차이는 지표 선택에 그대로 반영돼야 한다. closed-set 정확도(acck)는 등록된 후보들 사이에서만 맞았는지를 보는 지표로, 우연 수준(1/등록기기수)과 함께 보고해야 의미가 있다. 이 지표는 미등록 입력을 아예 다루지 않으므로 검증 성능에 대해 아무것도 말해주지 않는다. 검증 성능을 재려면 아래 다섯 계열의 지표가 필요하다.

동일오류율(EER)은 정당한 시도를 잘못 거부하는 비율과 미등록 시도를 잘못 받아들이는 비율이 같아지는 지점의 오류율이다. 임계값을 아직 정하지 않은 상태에서 전체 분리성을 한 숫자로 요약한다.

$$EER = FAR(\tau^*) = FRR(\tau^*), \quad \text{where } \tau^* \text{ satisfies } FAR(\tau) = FRR(\tau)$$

AUROC(area under the ROC curve)는 모든 임계값에 걸쳐 정당 시도의 점수가 미등록 시도의 점수보다 높을 확률을 적분한 값이다. 임계값을 정하기 전 단계의 전반적 판별력을 나타낸다.

$$AUROC = P(s(x_{\text{genuine}}) > s(x_{\text{unknown}}))$$

TAR@FAR(τ)는 실제 배포가 요구하는 지점이다. 하나의 오탐률 목표(FAR, false accept rate)를 먼저 정하고, 그 임계값에서 정당한 시도를 얼마나 통과시키는지(TAR, true accept rate)를 본다. AUROC가 아무리 높아도 특정 FAR 지점의 TAR는 낮을 수 있으며, 이 논문의 핵심 경고가 바로 이 지점에 있다.

$$TAR@FAR = \gamma : \quad TAR(\tau_\gamma), \quad \text{where } \tau_\gamma \text{ satisfies } FAR(\tau_\gamma) = \gamma$$

OSCR(open-set classification rate)은 분류와 검증을 한 곡선에 결합한다. 각 오탐률 수준에서, 미등록으로 거부되지 않고 통과된 정당 시도 가운데 올바른 등록 신원으로까지 정확히 분류된 비율을 그린다. 검증만 잘 되고 분류가 틀리는 경우와, 분류는 맞지만 미등록 거부 실패하는 경우를 동시에 별점 처리한다.

마지막으로 신뢰도 보정(calibration) 지표인 ECE(expected calibration error)와 Brier score가 필요하다. 검증 시스템은 대부분 이진 판정이 아니라 연속값 확신도 점수를 출력하고 그 점수가 다른 신호와 융합되는 리스크 계층으로 쓰인다. 이때 모델이 "90% 확신"이라고 말하는 예측이 실제로 90% 확률로 맞는지를 확인해야 그 점수를 다른 신호와 안전하게 섞을 수 있다.

$$ECE = \sum_{b=1}^B \frac{|n_b|}{N} |\text{acc}(b) - \text{conf}(b)| \quad (\text{균등 구간 } B \text{개, 기본 } B = 15)$$

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2$$

신뢰구간을 계산하는 방식도 지표 선택만큼 중요하다. RFFI류 실험은 흔히 물리적 장치 수십 개에서 나온 신호를 수천에서 수만 개의 패킷 단위로 잘라 평가한다. 여기서 실제 독립 단위는 물리적 장치(또는 캡처 세션)이지 패킷이 아니다. 같은 장치, 같은 세션에서 나온 패킷들은 서로 상관돼 있다. 패킷 수만 개를 리샘플링 단위로 부트스트랩 신뢰구간을 계산하면 신뢰구간이 인위적으로 좁아진다. 실제 독립 표본 수는 장치 수(보통 8~24대)이며, 신뢰구간은 반드시 그 단위로, 즉 매 리샘플에서 장치(또는 세션) 전체를 통째로 뽑는 방식으로 재추정해야 한다. 이 구분을 지키지 않으면, 표본 변동성이 실제보다 훨씬 작아 보이는 착시가 생긴다.

4 순환성과 누수의 함정: 같은 신호, 다른 진실

closed-set 정확도가 인증 능력으로 오독되는 경로는 크게 두 가지다. 첫째는 지표 자체를 바꿔치기하는 경우, 즉 분류 정확도를 재고 이를 검증 성능처럼 인용하는 경우다. 둘째는 지표는 올바르게 검증 지표를 썼지만 데이터 분할이 새어(leak) 있어 그 수치가 실제 배포 조건보다 훨씬 쉬운 과제를 재는 경우다. 둘 다 실측 사례로 구체적으로 보인다.

첫째 함정: 이상적인 closed-set 정확도, 초라한 인증 동작점. 공개 데이터셋 계보에서 같은 실험의 결과표를 그대로 놓고 보면 이 함정이 선명하게 드러난다. 등록 기기 여럿대, 동일 수신기·동일 캡처 세션이라는 상대적으로 쉬운 조건에서, closed-set

정확도(accK)는 82.0%다. 우연 수준($1/8 = 12.5\%$)을 크게 상회하는 인상적인 숫자다. 그런데 같은 실험, 같은 임베딩에서 인증이 실제로 요구하는 지표를 보면 사정이 다르다. AUROC는 0.881로 여전히 높지만, TAR@FAR=1%는 20.8%, TAR@FAR=0.1%는 2.9%에 그친다. closed-set 정확도 82.0%만 인용하면 이 시스템이 인증에 쓸 수 있을 것처럼 들리지만, 실제로 FAR을 0.1%로 고정하면 정당한 사용자 100명 중 97명이 거부된다. 같은 계보를 더 어려운 조건(수신기를 교체한 실제 교차수신기 분할)에서 재면 closed-set 정확도 자체도 50.4%로 떨어지고, TAR@FAR=0.1%는 2.7%에 그친다. 두 조건에서 closed-set 정확도(82.0% 대 50.4%)가 크게 차이 나는데도 어느 쪽에서도 하드 인증 동작점은 살아나지 않는다. closed-set 정확도는 그 자체로 프로토콜 난이도에 따라 크게 흔들리는 지표이며, 어느 값이든 검증 성능을 대신 말해주지 않는다.

둘째 함정: 순환성, 지문이 장치기 아니라 수신기를 외운 것. 같은 특징 집합으로 “이 신호를 받은 것이 어느 수신기인가”를 맞히는 과제를 별도로 돌리면, 우연 수준이 12분의 1 (8.3%)인 조건에서 정확도가 96.4%까지 올라간다. 같은 특징 집합의 장치 식별 정확도는 92.1%로, 수신기 식별 정확도보다 오히려 낮았다. 즉 이 특징 집합은 장치 지문보다 수신기 지문을 더 잘 외우고 있다. 수신기를 교체하면 성능이 무너지는 이유가 여기서 기계적으로 설명된다. 특징을 바꿔(수신기 의존성이 낮다고 알려진 다른 특징 집합) 다시 측정하면 수신기 식별 정확도가 83.1%, 장치 식별 정확도가 83.5%로 누수가 13.3퍼센트포인트 줄어들지만, 83%라는 수신기 정보는 여전히 압도적으로 남아 있다. 이 실험이 보여주는 것은 “장치를 정확히 식별했다”는 결과의 상당 부분이 실제로는 “그 신호를 받은 수신기를 식별했다”는 것일 수 있다는 점이다. 같은 수신기로 등록하고 같은 수신기로 평가하는 분할에서는 이 순환성이 성능으로 위장돼 드러나지 않는다.

이제 도입부에서 예고한 세 숫자로 돌아온다. 사후에 가장 좋은 스코어러·패킷 수 조합을 평가셋에서 골라 보고한 AUROC 0.9994는, 같은 조합에서 인증이 실제로 요구하는 지표 (TAR@FAR=1e-3)로도 이미 0.8765로 내려간다. 그리고 등록되지 않은 임의 신원으로 접근을 시도하는 공격자를 가정하고, 임계값 보정용 장치와 평가용 장치를 완전히 분리한 엄격한 프로토콜로 같은 패킷 융합 조건(K=50)을 다시 측정하면 0.2235까지 떨어진다. 낙관적 스왑의 TAR@FAR=1e-3(0.8765)과 최악조건 프로토콜의 같은 지표(0.2235)는 정확히 같은 지표, 같은 패킷 수를 비교한 것이다. 그런데도 네 배 가까운 차이가 난다. 이 차이를 만드는 유일한 변수는 모델이 아니라 평가 프로토콜이다.




그림 1: 낙관적 대 엄격 프로토콜의 격차

이 격차가 특정 데이터셋 하나의 우연이 아니라는 점도 확인할 필요가 있다. 문헌에 보고된 전용 오픈셋 검증 방법(같은 공개 데이터셋 계보에서 구조적 앵커와 거부지향 정렬을 쓴 비교 대상 연구)은 단일 결정 조건에서 OSCR 0.958, FPR@TPR90 0.047을 보고한다. 우리가 같은 조건에서 측정한 OSCR은 0.326에서 0.622 사이, 미등록 거부율은 10.8%에서 29.4% 사이다. 우리 자신의 단일 패킷 조건과 비교 대상 SOTA 사이의 이 격차는, 오픈셋 검증이 정말로 어려운 문제이며 인상적인 헤드라인 수치 하나로 이 난이도를 뛰어넘을 수 없다는 사실을 다시 한번 보여준다.

5 권장 프로토콜: A/B/C

앞의 사례들이 공유하는 원인은 하나다. RFFI/수신기 검증에서 새는 정보는 거의 항상 학습과 평가에 걸쳐 공유되는 축 하나에서 생긴다. 재현 가능한 평가를 하려면 다음 여섯 개 축을 각각 명시적으로 관리하고, 어떤 실험이든 이 목록을 채워 문서화해야 한다.

분리 축	무엇	관리하지 않으면 왜 새는가
송신기/장치 개체	지문의 대상 그 자체	같은 기기의 패킷이 학습·평가에 나뉘면 암기가 일반화로 위장
장치 모델/제조사 수신기(수신 체인)	칩셋군 특유의 스푸리어스 안테나·RF 프런트엔드·ADC	모델 특유의 신호가 지문과 혼입 수신기 특성이 지문에 섞여 “수신기를 외웠다”가 됨

분리 축	무엇	관리하지 않으면 왜 새는가
캡처 일자/세션 환경/위치 패킷/burst 군	온도 · 클럭 드리프트 · 환경 변동 실내외, 거리, 다중경로 한 캡처에서 나온 연속 패킷들	같은 날 캡처는 상관된 잡음을 공유 환경별 채널 특성이 지문과 얽힘 인접 패킷은 채널 · 타이밍이 상관돼 있어 무작위 분할이 사실상 같은 캡처를 나누는 것에 그침

이 가운데 절대 규칙 하나는 예외를 두지 않는다. 같은 연속 캡처(burst)를 학습과 평가에 걸쳐 나누지 않는다는 것이다. 패킷 단위 무작위 분할은 인접 패킷이 채널 · 타이밍 상관을 공유하므로 성능을 인위적으로 부풀린다. 최소한 실험이 검증하려는 축(장치, 수신기, 일자 가운데 해당하는 것)은 반드시 명시적 hold-out이어야 한다.

이 여섯 축을 관리하는 정도에 따라 같은 실험을 세 난이도로 나눠 보고하면 “실험실 수치”와 “배치 수치”의 간극이 드러난다. 각 실험은 최소 하나, 가능하면 A와 B를 함께, 제품화 직전에는 C까지 명시적으로 라벨링해 보고한다.

프로토콜 A(연구 기준선). 같은 수신기, 같은 또는 인접한 캡처일자를 쓰고 미등록 장치 hold-out만 건다. 등록된 장치는 등록 절차에 포함되지만 미등록 장치는 학습 · 등록 어디에도 등장하지 않는다. 이 프로토콜은 백본이나 스코어링 방식의 상한(ceiling)을 확인하는 목적으로만 쓰고, 제품 성능 주장의 근거로 인용하지 않는다. “이 조건에서만 성립한다”는 캐비엣을 항상 함께 명시한다.

프로토콜 B(현실적 오픈셋). 등록된 장치와 미등록 장치를 오픈셋 정의 그대로 분리하고, 같은 수신기를 유지하되 평가 시점의 캡처일자 · 환경은 학습 시점과 분리한다. 미등록 데이터는 임계값 결정이나 모델 선택에 절대 쓰지 않는다. 미등록 정보가 하이퍼 파라미터나 임계값 튜닝에 스며들면 오픈셋 성능이 낙관적으로 부풀려진다. 임계값은 등록된 장치의 검증(validation) 분할에서만 고른다.

프로토콜 C(제품 등급). 배치될 실제 수신기를 완전히 hold-out한다. 그 수신기의 데이터는 등록된 장치의 등록(enrollment) 절차에만 쓰고, 모델 학습 · 하이퍼파라미터 튜닝 · 임계값 보정에는 전혀 쓰지 않는다. 배치 시점의 캡처일자 · 환경도 hold-out해, 학습 시점과 환경이 다르다는 실제 배치 조건을 시뮬레이션한다. 등록된 장치는 새 수신기에서 등록 절차만 허용되며, 이는 실제 제품에서 “새 수신기에 기존 기기를 등록”하는 절차와 동형이다. 그리고 평가는 임의의 등록된 신원으로 통과를 시도하는 최악조건 1:N 공격자 시나리오를 기본으로 삼는다. 등록되지 않은 임의의 장치가 등록된 신원 중 자신과 가장 가까운 것을 찾아 사칭을 시도한다고 가정하고, 그 최선의 사칭 시도가 통과하는 비율을 잰다. 이 시나리오가 제품/방산 브리프에 인용할 수 있는 유일하게 정직한 수치를 낸다.

프로토콜 C의 최악조건 조건에서 측정하면, 패킷을 융합해 판정 지연을 늘리는 것이 어느 정도 도움이 되지만 완전한 해법은 아니라는 것도 드러난다. 아래 표는 같은 시스템을 패킷 융합 개수(K)를 늘려가며 재측정한 결과다.

K(융합 패킷 수)	TAR@FAR=1e-3	TAR@FAR=1e-4
1	0.16%	0.01%
20	6.79%	1.60%
50	22.35%	13.11%
100	43.33%	22.00%

K=100까지 패킷을 쌓아도 가장 엄격한 목표(FAR=1e-4)에서는 정당한 사용자의 5명 중 4명이 여전히 거부된다. 그리고 이 조건에서 AUROC를 함께 보면, K=20에서 AUROC는 0.863으로 여전히 높지만 같은 K에서 TAR@FAR=1e-3은 6.8%에 그친다. 높은 AUROC와 쓸 수 있는 인증 동작점은 같은 것을 말하지 않는다는 이 논문의 핵심 경고가 여기서도 그대로 재확인된다.

프로토콜 C는 또한 캡처일자 분리가 수신기 분리보다 더 가혹한 조건임을 드러낸다. 같은 1:N 최악조건 설계 위에서, 학습 · 평가가 동일 시점일 때 AUROC는 0.9515이고 closed-set 식별 정확도는 88%다. 평가를 미래의 2~3일 뒤 캡처로 옮기면 AUROC는 0.7981로, closed-set 식별 정확도는 47%로 떨어진다. 같은 설계에서 수신기만 교체했을 때의 AUROC 하락폭은 0.605에서 0.722 사이로 관측돼, 캡처일자 열화보다 오히려 작았다. 즉 실제 배치에서는 온도 드리프트나 클럭 편이 같은 시간 경과 요인이 하드웨어 교체보다 더 큰 위협일 수 있으며, 재등록 주기를 제품 설계의 핵심 변수로 삼아야 한다.

이 절을 마치기 전에, 새 실험 보고서를 쓸 때 확인할 체크리스트를 명시한다. 여섯 개 분리 축을 각각 어떻게 관리했는지 한 줄씩 밝힌다(해당 없으면 이유와 함께 “해당 없음”으로 명시). 어떤 프로토콜(A/B/C)로 측정했는지 표에 라벨을 단다. closed-set 정확도, AUROC, AUPRC, OSCR, EER, TAR@FAR(FAR 10%/1%/0.1%), FPR@TPR(TPR 90%/95%), ECE, Brier score




그림 2: 패킷 융합




그림 3: 캡처일자 분리가 수신기 교체보다 가혹하다

를 전부 보고한다(일부만 골라 보고하는 cherry-picking을 막기 위해서다). 신뢰구간이 패킷 단위가 아니라 장치·세션 단위 부트스트랩인지 밝힌다. 그리고 미등록 데이터가 임계값 결정이나 모델 선택에 전혀 들어가지 않았는지 확인한다.

6 한계

이 논문이 측정하지 않은 것을 분명히 해둔다. 능동적 스푸핑·재생(replay) 공격에 대한 강건성은 다루지 않았다. 높은 충실도의 재생 신호가 baseline과 구분되지 않을 가능성은 별도로 검증돼야 하는 열린 문제로 남는다. 등록 기기군의 규모가 지금 실험(수십 대 수준)보다 훨씬 커졌을 때(수만~수십만 대)의 성능도 범위 밖이다. 등록 기기군이 커질수록 임의의 미등록 장치가 어떤 등록 신원과 우연히 가까워질 확률이 늘어나므로, 이 논문이 보고한 최악조건 수치조차 실제 대규모 배치보다 오히려 낙관적인 쪽에 가깝다고 보는 것이 안전하다. 소규모 표본(known 장치 8~24대)에서 나온 점추정치에는 표본 변동성이 있으며, 이는 계산 오류가 아니라 소규모 표본이 갖는 진짜 불확실성이다. 마지막으로, 이 논문이 제시한 6축 분리 규칙과 A/B/C 프로토콜은 RFFI/수신기 검증이라는 구체적인 과제 계열에서 추출됐다. 다른 생체인증·행동인증 과제에 그대로 옮기려면 각 과제에 맞는 분리 축을 다시 식별하는 과정이 필요하다.

7 재현

이 논문의 핵심 기여는 특정 모델이 아니라 프로토콜과 지표 정의 그 자체이며, 그래서 재현 가능성의 단위도 모델이 아니라 프로토콜이다. 재현을 원하는 연구자는 다음 절차를 그대로 따를 수 있다. 첫째, 사용하는 데이터셋에서 6축(송신기, 장치모델, 수신기, 캡처일자/세션, 환경, 패킷/burst 군) 각각의 메타데이터를 먼저 확인하고, 최소한 실험이 검증하려는 축을 명시적으로 hold-out한다. 둘째, 같은 캡처(burst) 안의 패킷을 학습과 평가에 걸쳐 나누지 않도록 분할 스크립트에 burst-id 단위의 그룹 분할을 강제한다. 셋째, 임계값은 등록된 장치의 검증 분할에서만 고정하고, 미등록 데이터는 오직 최종 평가 단계에만 노출한다. 넷째, closed-set 정확도·AUROC·AUPRC·OSCR·EER·TAR@FAR·FPR@TPR·ECE·Brier score를 전부 계산해 보고하고, 신뢰구간은 장치(또는 세션) 단위 부트스트랩으로 재추정한다. 다섯째, 프로토콜 C를 보고할 때는 등록되지 않은 모든 장치가 등록된 각 신원에 대해 가장 가까운 사칭 시도를 만든다고 가정하고, 그 최선의 시도가 통과하는 비율로 TAR@FAR을 계산한다. 이 다섯 단계는 특정 벤더나 특정 백본에 묶여 있지 않으며, 공개된 오픈셋 RF 지문 데이터셋 위에서 그대로 재현할 수 있다. 이 논문이 인용한 세 단계 격차(AUROC 0.9994에서 TAR@FAR=1e-3 0.8765를 거쳐 0.2235까지)는 바로 이 절차를 그대로 밟았을 때 재현되는 수치다.

8 참고문헌

1. Hanna, S., Karunaratne, S., Cabric, D. (2022). WiSig: A Large-Scale WiFi Signal Dataset for Receiver and Channel Agnostic RF Fingerprinting. 실측 무선 캡처, 150 송신기 x 18 수신기 x 4일. 라이선스: CC BY-NC-SA 4.0(비상업 전용).
2. INRIA PLA I/Q RF Fingerprinting Dataset. Zenodo record 18268648. 라이선스: CC BY 4.0(상업 이용 가능).
3. WIDEFT Dataset (Physical Science Laboratories / NMSU). Zenodo record 4116383. 라이선스: CC BY 4.0(상업 이용 가능).
4. CRODA-ST: structural-anchor and rejection-oriented alignment for open-set RF fingerprint identification. arXiv:2607.02567. 참조 SOTA(WiSig strict cross-receiver open-set): OSCR 0.958, FPR@TPR90 0.047, AUROC 0.9692(단일 결정 기준).
5. Open-set 검증 지표(EER, AUROC, TAR@FAR, OSCR, ECE, Brier score)의 정의와 장치/ 세션 단위 부트스트랩 신뢰구간 산정 절차는 본 연구가 채택한 고정 평가 프로토콜 문서(내부 평가 스펙, 비공개)에 기반하며, 위 1-4의 공개 데이터셋에 적용해 실측했다.