

분할 프로토콜이 만드는 성능 착시

무카메라 센싱 타당성은 정확도가 아니라 도메인 이전 성능으로 판정한다

2i

2026-07-29

초록

WiFi 신호(CSI) 기반 센싱에서 같은 데이터, 같은 모델, 같은 학습 비율을 두고 **데이터 분할 방식만** 바꿔 성능을 실측했습니다. 결과는 0.931에서 0.088까지 벌어졌습니다. 16개 클래스 문제이므로 우연 수준은 0.0625입니다. 즉 한쪽 프로토콜에서는 93%로 보이는 모델이, 다른 프로토콜에서는 아무것도 맞히지 못합니다.

목차

1	요약	3
2	배경	3
3	방법	3
4	데이터와 설정	3
5	결과	4
5.1	분할 방식만 바꿨을 때	4
5.2	격차의 분해	4
5.3	라벨 번호 불일치 가설의 기각	5
5.4	회복에 필요한 라벨의 양	5
6	한계	6
7	데이터와 재현	6
8	참고문헌	6

1 요약

WiFi 신호(CSI) 기반 센싱에서 같은 데이터, 같은 모델, 같은 학습 비율을 두고 **데이터 분할 방식만** 바꿔 성능을 실측했습니다. 결과는 0.931에서 0.088까지 벌어졌습니다. 16개 클래스 문제이므로 우연 수준은 0.0625입니다. 즉 한쪽 프로토콜에서는 93%로 보이는 모델이, 다른 프로토콜에서는 아무것도 맞히지 못합니다.

더 중요한 것은 격차의 구성입니다. 흔히 지적되는 인접 윈도우 누수는 1.7~5.8%p에 불과했고, 피험자 및 설치 조건이 바뀌는 도메인 이동이 77.7~81.6%p를 차지했습니다. 누수를 고쳐도 문제의 93% 이상이 남습니다. 따라서 무카메라 센싱 도입 타당성은 보고된 정확도가 아니라 **도메인 이전 성능**으로 판정해야 합니다.

붕괴가 영구적인 것은 아닙니다. 대상 도메인에서 클래스당 1개 시행만 라벨링해도 0.090에서 0.454로 올라가고, 20개면 0.873으로 회복됩니다. 도입 비용을 계산할 수 있는 형태의 숫자입니다.

2 배경

전파 기반 실내 센싱은 카메라 없이 사람의 존재와 움직임을 읽습니다. 영상정보를 수집하지 않아 설치 제약이 적고, 학술 문헌에는 90%대 후반의 정확도가 반복해서 보고됩니다. 도입을 검토하는 쪽에서 보면 근거가 충분해 보입니다.

문제는 그 수치를 만든 평가 절차가 대부분 공개되지 않는다는 점입니다. 시계열 신호를 겹치는 창으로 잘라 무작위로 섞어 나누면, 같은 시행에서 나온 인접한 창이 학습셋과 평가셋 양쪽에 들어갑니다. 평가셋의 표본이 학습셋의 표본과 사실상 같은 순간을 담고 있으므로, 모델은 일반화가 아니라 기억으로 문제를 푼다.

이 문서는 그 영향을 추정이 아니라 실측으로 분해합니다. 그리고 실무적으로 더 중요한 질문, “환경이나 사람이 바뀌면 얼마나 떨어지는가”와 “얼마를 라벨링하면 회복되는가”에 숫자로 답합니다.

3 방법

세 가지 분할 프로토콜을 정의했습니다. 데이터, 모델, 하이퍼파라미터, 학습 비율은 전부 동일하게 고정하고 분할 방식만 바꿉니다.

P1 윈도우 무작위. 모든 창을 한데 모아 섞고 나눕니다. 한 시행에서 나온 창들이 학습셋과 평가셋에 함께 들어갑니다. 문헌에서 가장 흔히 쓰이는 절차입니다.

P2 시행 단위. 시행을 단위로 나눕니다. 한 시행의 창은 전부 같은 쪽에 들어갑니다. 창 누수가 사라지지만 사람과 설치 조건은 양쪽에 함께 존재합니다.

P3 피험자 단위. 한 사람을 통째로 빼고 학습한 뒤 그 사람으로 평가합니다. 창 누수도 없고 사람도 겹치지 않습니다.

P1과 P2의 차이가 인접 윈도우 누수의 크기이고, P2와 P3의 차이가 도메인 이동의 크기입니다. 학습 비율은 세 프로토콜 모두 6/7로 맞췄습니다. P3가 7명 중 1명을 빼는 구조이므로, P1과 P2도 같은 비율로 잘라 비교 가능성을 확보했습니다.

모델은 세 가지입니다. 진폭 통계 특징에 랜덤포레스트를 얹은 고전 기준선, 서브캐리어와 시간축을 2차원으로 보는 CNN, 그리고 BiLSTM입니다. 정규화 통계는 항상 학습셋에서만 계산했습니다.

4 데이터와 설정

공개 데이터셋 WiAR을 사용했습니다. Intel 5300 무선랜카드로 수집한 원시 CSI 로그이며, 안테나 3개와 서브캐리어 30개, 표본율 30Hz입니다. 16개 동작을 10명이 각각 30회 수행했습니다.

이 실험에서는 16개 동작을 모두 30회씩 보유한 7명분을 사용했습니다. 시행 3,361개를 파싱해 길이 96 표본, 보폭 32의 창으로 자르면 17,356개 창이 나옵니다. 클래스는 16개이므로 우연 수준 정확도는 0.0625입니다.

원시 로그는 8비트 실수부와 허수부가 비트 단위로 채워져 있어 직접 언패킹했습니다. 위상은 반송파와 표본 클록의 오프셋으로 손상되어 있어 사용하지 않고 진폭만 썼습니다. 전 과정이 노트북 한 대에서 수행되며 추가 장비가 필요하지 않습니다.

5 결과

5.1 분할 방식만 바꿨을 때

7회 반복의 평균과 표준편차입니다. P3는 7명을 한 번씩 제외하는 7개 폴드이고, P1과 P2는 같은 비율로 7회 반복했습니다.

모델	P1 윈도우 무작위	P2 시행 단위	P3 피험자 단위	P3 학습 정확도
통계특징 + 랜덤포레스트	0.931 ± 0.005	0.873 ± 0.009	0.088 ± 0.024	1.000
CNN	0.866 ± 0.006	0.849 ± 0.020	0.072 ± 0.021	0.910
BiLSTM	0.917 ± 0.006	0.876 ± 0.009	0.061 ± 0.032	0.959




그림 1:

세 모델 모두 P3에서 우연 수준 0.0625 부근으로 내려앉았습니다. 같은 시점의 학습 정확도는 0.910에서 1.000 사이입니다. 모델은 학습 데이터를 완벽하게 외웠지만 새 사람에게는 아무것도 전달하지 못했습니다.

5.2 격차의 분해

모델	인접 윈도우 누수 (P1 - P2)	도메인 이동 (P2 - P3)	합계
통계특징 + 랜덤포레스트	5.8%p	78.5%p	84.3%p
CNN	1.7%p	77.7%p	79.4%p
BiLSTM	4.0%p	81.6%p	85.6%p




그림 2:

도메인 이동이 인접 윈도우 누수보다 13배에서 46배 큼니다. 무작위 분할을 시행 단위로 고치는 것은 올바른 조치이지만, 그것만으로는 문제의 93% 이상이 그대로 남습니다. 평가 절차를 고쳤다는 설명이 곧 일반화를 확인했다는 뜻은 아닙니다.

한 가지 더 눈에 띄는 점이 있습니다. CNN은 P1에서 세 모델 중 가장 낮은 0.866이지만 총 격차도 가장 작습니다. 무작위 분할 성적으로 모델을 고르면 이전성이 가장 좋은 후보를 탈락시키게 됩니다.

5.3 라벨 번호 불일치 가설의 기각

P3의 결과가 우연 수준이라는 것은 데이터셋 자체의 결함일 수도 있습니다. 피험자마다 동작 번호가 다르게 매겨졌다면 교차 평가는 자동으로 우연 수준이 됩니다.

이를 직접 검사했습니다. 제외된 피험자의 혼동행렬에 헝가리안 할당을 적용해 정확도를 최대화하는 라벨 순열을 찾았습니다. 번호만 뒤섞인 것이라면 이 조작으로 원래 성능이 회복되어야 합니다.

제외 피험자	원본 라벨	최적 순열 적용
10	0.064	0.294
7	0.069	0.197
8	0.074	0.294

최적 순열을 적용해도 0.197에서 0.294에 머물렀습니다. 같은 파이프라인의 피험자 내부 성능이 0.951인 것과 비교하면 회복이라 부를 수 없습니다. 붕괴는 번호 표기의 문제가 아니라 실제 도메인 이동입니다. 데이터셋 문서의 동작 목록도 16개 동작이 고정된 순서로 정의되어 있음을 확인했습니다.

5.4 회복에 필요한 라벨의 양

대상 도메인에서 클래스당 k개 시행을 라벨링해 학습에 추가하고, 그 도메인의 나머지 시행으로 평가했습니다. 창이 아니라 **시행 단위로** 추가했습니다. 창 단위로 뽑으면 같은 시행의 인접 창이 학습에 들어가 이 문서가 비판하는 부풀림을 그대로 재현하게 됩니다.

클래스당 라벨 시행	0	1	2	3	5	10	20
정확도	0.090	0.454	0.599	0.665	0.753	0.822	0.873




그림 3:

클래스당 한 개만 라벨링해도 0.090에서 0.454로 올라갑니다. 20개면 0.873으로, 피험자가 섞여 있던 P2의 0.873과 같은 수준을 회복합니다. 도메인 이동은 넘을 수 없는 벽이 아니라 라벨링 비용으로 환산되는 항목입니다.

이 곡선이 실무에서 갖는 의미는 분명합니다. 현장마다 얼마를 라벨링해야 하는지가 곧 도입 단가이고, 그 단가는 벤더가 보고한 정확도가 아니라 이 형태의 곡선에서만 읽힙니다.

같은 게시판의 별도 실험(「WiFi-CSI 환경 이동과 소량 보정」)은 다른 데이터셋과 다른 과제에서 환경 이동에 따른 하락과 소량 라벨의 회복 효과를 보고했습니다. 데이터도 과제도 다르지만 방향은 같습니다. 이 문서의 기여는 회복 곡선 자체가 아니라, 그 앞 단계에서 **격차를 누수와 도메인 이동으로 분해해 어느 쪽이 지배적인지 보인 것**입니다.

6 한계

피험자와 설치 조건이 분리되지 않습니다. WiAR은 피험자별 촬영 환경 메타데이터를 공개하지 않습니다. 따라서 P3의 격차에서 사람의 차이와 장비 배치의 차이가 각각 얼마인지 나눌 수 없습니다. 다만 실제 도입 현장에서는 두 가지가 함께 바뀌므로, 이 조건이 오히려 배포 상황에 가깝습니다.

의도적으로 소박한 특징을 썼습니다. 진폭 통계와 표준 신경망만 사용했고 도메인 불변 특징 설계나 도메인 적응 기법을 적용하지 않았습니다. 이 문서의 주장은 전파 센싱이 불가능하다는 것이 아니라, 무작위 분할에서 93%로 보이는 소박한 파이프라인이 사람이 바뀌면 아무것도 하지 못하며 그 사실은 분할 방식을 바꿔야만 드러난다는 것입니다. 도메인 불변 설계가 존재하는 이유가 바로 이 격차입니다.

동작 인식 데이터셋입니다. WiAR은 16개 동작 분류이고 매장의 혼잡도나 체류 측정과 과제가 다릅니다. 절대 수치를 다른 과제로 옮길 수 없습니다. 옮겨지는 것은 절차입니다. 즉 어떤 과제든 도메인 단위로 분할해 보고해야 한다는 점입니다.

한 데이터셋의 결과입니다. 7명, 16개 동작, 단일 수집 장비입니다. 격차의 방향과 규모가 다른 데이터셋에서 같으리라는 보장은 없습니다.

7 데이터와 재현

- 데이터셋: WiAR (WiFi-based Activity Recognition), <https://github.com/linteresa/WiAR>
- 원본 형식: Intel 5300 CSI 원시 로그, 안테나 3개, 서브캐리어 30개, 30Hz
- 사용 범위: 16개 동작을 30회씩 모두 보유한 피험자 7명, 시행 3,361개, 창 17,356개
- 라이선스: 저장소에 별도 라이선스 파일이 없습니다. 본 문서는 연구 인용 목적의 재측정이며, 상업 제품의 성능 근거로 사용하지 않습니다. 상업적 활용이 필요하면 명시적 허용 라이선스를 가진 데이터셋으로 재측정해야 합니다.
- 실측 여부: 모든 수치는 공개 데이터에 대한 실제 측정값입니다. 시뮬레이션이나 추정이 아닙니다.
- 계산 환경: 노트북 1대. 별도 수집 장비를 사용하지 않았습니다.
- 난수 시드 고정, 반복 7회, 학습 비율 6/7로 세 프로토콜 동일.

부정적 결과를 그대로 씁니다. 이 실험에서 우리 파이프라인의 교차 피험자 성능은 우연 수준이며, 그 사실이 이 문서의 핵심 근거입니다.

8 참고문헌

1. Guo, L., Wang, L., Liu, J., Zhou, W. "A Survey on Motion Detection Using WiFi Signals." Proc. IEEE MSN. (WiAR 데이터셋 출처)
2. Halperin, D., Hu, W., Sheth, A., Wetherall, D. "Tool Release: Gathering 802.11n Traces with Channel State Information." ACM SIGCOMM CCR. (Intel 5300 CSI 수집 도구 및 로그 형식)
3. Yang, J., Chen, X., Zou, H., Wang, D., Xu, Q., Xie, L. "SenseFi: A Library and Benchmark on Deep Learning for WiFi Human Sensing." Patterns, 2023. (표준 벤치마크에서 아키텍처별 전이 성능 편차 보고)
4. Zheng, Y., Zhang, Y., Qian, K., Zhang, G., Liu, Y., Wu, C., Yang, Z. "Zero-Effort Cross-Domain Gesture Recognition with Wi-Fi." MobiSys (Widar3.0). (도메인 불변 특징 설계로 교차 도메인 하락을 억제한 사례)