

신호 특징 위에서 테이블러 부스팅이 딥러닝을 이기는 조건

GBM·TabPFN·딥러닝의 데이터 규모별 교차점, 실측

2i

2026-07-29

초록

무선 신호 분류처럼 물리 원리로부터 특징을 뽑아낼 수 있는 과제에서, 딥러닝이 결국 고전적인 테이블러 모델을 이긴다는 통념이 있다. 이 논문은 그 통념을 하나의 좁고 검증 가능한 질문으로 바꿔 실측했다. 공개 데이터셋 RadioML2016.10a의 6dB 부분집합에서 11종 변조를 분류하는 과제에 28차원의 큐물런트·스펙트럴 물리 특징을 얹고, LightGBM·XGBoost·CatBoost·랜덤포레스트 같은 GBM 계열과 TabPFN v2·RealMLP·TabM·AutoGluon 같은 최신 테이블러 학습기, 그리고 원시 IQ 샘플을 그대로 입력받는 딥러닝(믹스처-오브-엑스퍼트 트랜스포머 재현체)을 같은 학습·검증 분할 위에서 비교했다. 학습 표본이 539개뿐인 소규모 체제에서 LightGBM은 정확도 0.855로 모든 경쟁자를 앞섰고, 원시 IQ 딥러닝은 0.681에 머물렀다. 학습 표본을 539개에서 2,000개로 늘리자 딥러닝의 정확도는 0.368에서 0.581로 뛰었고 GBM과의 격차는 36.0 퍼센트포인트에서 21.3퍼센트포인트로 좁혀졌다. 이 격차 축소 추세는 실재하지만, 5,000개와 9,900개 지점에서의 딥러닝 재측정은 완료하지 못해 교차점이 실제로 존재하는지, 존재한다면 어느 지점인지는 이 실험 범위 안에서 확인하지 못했다. 결론은 양방향으로 정직하다. 소규모에서 중간 규모의 물리 특징 데이터셋에서는 테이블러 부스팅이 실용적인 승자이고, 그 우위는 해석성과 학습 비용에서 더 벌어진다. 그러나 그 우위가 데이터가 아무리 늘어나도 무한히 유지된다는 근거는 이 실험에 없다.

목차

1 요약	3
2 왜 테이블러 부스팅인가: 해석성, 소데이터, 엣지	3
3 방법: 특징과 모델군	3
4 데이터와 실험 설정	4
5 결과	4
5.1 표 1 - 모델별 정확도 (학습 539개, 28차원 물리 특징 위, 검증 1,100개)	4
5.2 표 2 - 데이터 규모별 GBM과 원시 IQ 딥러닝의 격차	5
6 한계: 교차점은 대규모에서 재검토해야 한다	6
7 재현	6
8 참고문헌	6

1 요약

무선 신호 분류처럼 물리 원리로부터 특징을 뽑아낼 수 있는 과제에서, 딥러닝이 결국 고전적인 테이블러 모델을 이긴다는 통념이 있다. 이 논문은 그 통념을 하나의 좁고 검증 가능한 질문으로 바꿔 실측했다. 공개 데이터셋 RadioML2016.10a의 6dB 부분집합에서 11종 변조를 분류하는 과제에 28차원의 큐물런트·스펙트럴 물리 특징을 얹고, LightGBM·XGBoost·CatBoost·랜덤포레스트 같은 GBM 계열과 TabPFN v2·RealMLP·TabM·AutoGluon 같은 최신 테이블러 학습기, 그리고 원시 IQ 샘플을 그대로 입력받는 딥러닝(믹스처-오브-엑스퍼트 트랜스포머 재현체)을 같은 학습·검증 분할 위에서 비교했다. 학습 표본이 539개뿐인 소규모 체제에서 LightGBM은 정확도 0.855로 모든 경쟁자를 앞섰고, 원시 IQ 딥러닝은 0.681에 머물렀다. 학습 표본을 539개에서 2,000개로 늘리자 딥러닝의 정확도는 0.368에서 0.581로 뛰었고 GBM과의 격차는 36.0 퍼센트포인트에서 21.3퍼센트포인트로 좁혀졌다. 이 격차 축소 추세는 실재하지만, 5,000개와 9,900개 지점에서의 딥러닝 재측정은 완료하지 못해 교차점이 실제로 존재하는지, 존재한다면 어느 지점인지는 이 실험 범위 안에서 확인하지 못했다. 결론은 양방향으로 정직하다. 소규모에서 중간 규모의 물리 특징 데이터셋에서는 테이블러 부스팅이 실용적인 승자이고, 그 우위는 해석성과 학습 비용에서 더 벌어진다. 그러나 그 우위가 데이터가 아무리 늘어나도 무한히 유지된다는 근거는 이 실험에 없다.

2 왜 테이블러 부스팅인가: 해석성, 소데이터, 엣지

무선 신호 분류, 산업 설비 진동 진단, 의료 생체신호 판별처럼 물리 센서에서 나오는 시계열을 다루는 문제들은 공통적으로 세 가지 제약을 갖는다. 첫째, 라벨이 붙은 학습 데이터가 절대적으로 적다. 실제 현장에서 특정 장비의 결함 파형이나 특정 변조 방식의 샘플을 수만 개씩 모으는 일은 드물고, 대개는 수백에서 수천 개 수준에서 모델을 만들어야 한다. 둘째, 판정 근거를 설명해야 하는 요구가 강하다. 통신 규제, 산업 안전, 의료 인증처럼 오판의 대가가 큰 영역에서는 “왜 이 신호를 이 변조로 분류했는가”에 대한 답이 특징 중요도나 결정 경계로 제시될 수 있어야 승인 절차를 통과한다. 셋째, 추론이 엣지에서, 즉 서버가 아니라 소형 임베디드 장치나 저전력 게이트웨이에서 실시간으로 돌아가야 하는 경우가 많다.

이 세 제약은 딥러닝보다 그래디언트 부스팅(GBM) 계열의 테이블러 모델에 유리하게 작동한다. 물리 원리에서 유도한 특징, 예를 들어 신호의 고차 큐물런트나 스펙트럴 모멘트는 이미 그 자체로 클래스 간 판별력을 압축해 담고 있어서, 트리 앙상블은 수백 개의 학습 샘플만으로도 안정적인 분할 경계를 찾아낸다. 반면 원시 신호를 그대로 입력받는 딥러닝은 특징 추출 자체를 데이터로부터 학습해야 하므로, 같은 정보를 뽑아내는 데 훨씬 더 많은 샘플이 필요하다. 특징 중요도(feature importance)는 회귀나 딥러닝의 사후 설명 기법보다 직접적이고 안정적이며, 어떤 물리량이 판정에 실제로 기여했는지 엔지니어가 곧바로 검증할 수 있다. 그리고 부스팅 트리의 추론은 조건 분기의 연쇄일 뿐이라, GPU도 없는 저전력 마이크로컨트롤러에서도 밀리초 단위로 끝난다.

이 논문은 이 통념을 있는 그대로 믿지 않고, 하나의 구체적인 과제 위에서 세 가지를 동시에 측정한다. 첫째, 같은 물리 특징을 놓고 GBM과 최신 테이블러 학습기들, 그리고 원시 신호 딥러닝이 소규모 데이터에서 실제로 어떤 순위를 보이는가. 둘째, 학습 데이터를 늘려 갈 때 그 순위가 얼마나 빨리 바뀌는가. 셋째, 그 관찰로부터 어디까지를 자신 있게 말할 수 있고 어디부터는 아직 모른다고 말해야 하는가. 세 번째가 특히 중요하다. 벤치마크 논문들은 흔히 자사 방법이 이긴 지점만 보여주고 멈춘다. 이 논문은 이긴 지점과 이기지 못한 지점, 그리고 아직 답하지 못한 지점을 같은 무게로 보고한다.

3 방법: 특징과 모델군

과제는 RadioML2016.10a 6dB 부분집합에서 128샘플 길이의 IQ(동위상·직교위상) 관측창 하나를 11개 아날로그·디지털 변조 클래스(8PSK, AM-DSB, AM-SSB, BPSK, CPFSK, GFSK, PAM4, QAM16, QAM64, QPSK, WBFM) 중 하나로 분류하는 11-way 문제다. 무작위 추측의 정확도는 1/11, 약 0.091이다.

테이블러 계열 모델은 모두 같은 28차원 물리 특징 벡터를 입력으로 받는다. 이 특징은 네 갈래로 나뉜다. (1) IQ 불균형과 DC 오프셋 - 수신기 아날로그 프론트엔드가 남기는 흔적이자 변조에 따라 다르게 나타나는 위상 대칭성 지표, (2) 순시 진폭·위상·주파수의 통계 모멘트(표준편차·왜도·첨도) - 디지털 변조는 진폭이나 위상이 계단식으로 변하고 아날로그 변조는 연속적으로 변하므로 이 모멘트가 클래스를 강하게 구분한다, (3) Swami-Sadler 방식의 고차 큐물런트(2차, 4차, 6차 결합) - 변조 이론에서 클래스별로 값이 갈리도록 설계된 고전적인 판별 특징, (4) 스펙트럴 특징(대역별 전력, 스펙트럴 중심·평탄도·엔트로피·확산, 반송파주파수오프셋, 최대전력대평균전력비) - 주파수 영역에서 변조가 남기는 모양이다. 이 특징들은 초당 수천 창을 처리할 수 있을 정도로 계산이 가볍고, 표준화 스케일링 이후 곧바로 분류기에 들어간다.

비교한 모델군은 다섯 갈래다. 그래디언트 부스팅 트리로는 LightGBM, XGBoost, CatBoost를 놓았고, 배깅 트리로는 랜덤포레스트를 대조군으로 두었다. 딥 테이블러 아키텍처로는 RealMLP와 TabM(둘 다 pytabkit 구현), 그리고 검색 기반 테이블러 모델 TabR을 시도했다. 사전학습된 테이블러 파운데이션 모델로 TabPFN v2를 포함했는데, 이 모델은 네이티브로 최대 10개 클래스까지만 지원해서 11-way 문제에는 원-대-나머지(OneVsRest) 방식으로 감싸 사용했다는 점을 밝혀 둔다. 앙상블

스태킹의 상한선을 보기 위해 AutoGluon의 태블러 프리딕터를 시간제한 300초로 돌렸다. 마지막으로, 특징 엔지니어링을 전혀 거치지 않고 128샘플 원시 IQ를 그대로 입력받는 딥러닝 대조군으로, 최근 발표된 믹스처-오브-엑스퍼트 트랜스포머 방식의 변조분류 논문을 공식 코드 없이 그 서술을 따라 재현한 모델(합성곱 패치 임베딩과 4개 층의 트랜스포머 인코더, 상위-2 라우팅 방식의 전문가 혼합 피드포워드, 약 139만 개 파라미터)을 사용했다. 이 딥러닝 모델은 테이블러가 아니고, 28개 물리 특징이 아니라 원시 신호에서 직접 특징을 학습해야 한다는 점에서 나머지 모델군과 근본적으로 다른 입력 표현을 갖는다. 이 차이 자체가 이 논문이 답하려는 질문의 핵심이다. 특징 엔지니어링을 사람이 미리 해 주었을 때와, 모델이 그것을 데이터로부터 스스로 배워야 할 때 사이의 실용적 격차를 재는 것이기 때문이다.

TabR은 pytabkit 구현이 요구하는 추가 의존성(skorch, faiss-cpu) 설치 자체는 성공했지만, 학습 첫 에폭의 검증 단계에서 응답 없이 멈추는 현상이 반복돼 10분 제한을 넘긴 뒤 강제 종료하고 결과에서 제외했다. 이는 모델 성능에 대한 판단이 아니라 이 실험 환경(Apple Silicon, MPS 백엔드)에서의 실행 이슈로, 정확하게 미측정으로 표시한다.

4 데이터와 실험 설정

두 개의 서로 다른 실험을 같은 벤치마크(RadioML2016.10a 6dB) 위에서 진행했고, 각각의 목적이 다르다는 점을 분명히 구분해 둔다.

첫 번째는 모델군 비교(4절 표 1)로, 학습 539개·검증 1,100개로 고정된 하나의 분할 위에서 앞 절의 모델 전체를 붙였다. 이 분할에서 LightGBM의 정확도 0.855는 다섯 개의 서로 다른 무작위 시드로 재측정해도 0.8527에서 0.8564 사이(평균 0.8535)에 안정적으로 들어와, 단일 시드의 우연이 아니라는 점을 확인했다.

두 번째는 데이터 규모 스윙(4절 표 2)으로, 목적이 다르다. 학습 표본 수 N 을 539, 2,000, 5,000, 9,900으로 늘려 가면서, 같은 고정 검증 세트(1,100개, 모든 N 에서 동일) 위에서 GBM과 딥러닝의 격차가 어떻게 변하는지를 본다. 각 N 에서 클래스별 표본 수를 거의 균등하게 배분하는 계층 샘플링을 썼고, 딥러닝(믹스처-오브-엑스퍼트 트랜스포머)은 단일 GPU 위에서 600 에폭, 학습률 0.001, 드롭아웃 0.15, 레이블 스무딩 0.05, 가중치 감쇠 0.01로 학습했다. 이 두 번째 실험의 학습 표본은 첫 번째 실험과 같은 크기(539)라 해도 별도로 다시 뽑은 표본이라, 두 실험의 LightGBM 절대 수치가 정확히 일치하지는 않는다(표 1의 0.855 대 표 2의 $N=539$ 에서의 0.728). 두 표는 같은 질문에 대한 서로 다른 절단면이며, 절대값을 직접 비교하기보다는 각 표 안에서의 상대적 순위와 추세를 읽는 것이 올바른 해석이다.

5,000개와 9,900개 지점에서는 GBM 쪽 결과는 확보했지만, 같은 규모에서의 딥러닝 학습 작업은 완료되지 못했다(작업이 취소되거나 사라진 것으로 기록됨). 이는 이 논문이 안고 가는 명백한 공백이며, 5절에서 그 함의를 구체적으로 다룬다.

5 결과

5.1 표 1 - 모델별 정확도 (학습 539개, 28차원 물리 특징 위, 검증 1,100개)

모델	계열	정확도(11-way)	비고
LightGBM	그래디언트 부스팅	0.855	최고
TabPFN v2	사전학습 테이블러 파운데이션	0.848	OneVsRest 램핑 필요 (네이티브 10클래스 한도)
XGBoost	그래디언트 부스팅	0.848	
CatBoost	그래디언트 부스팅	0.848	
랜덤포레스트	배깅 트리	0.840	
AutoGluon	스태킹 앙상블	0.818	이 특징셋에서는 스태킹이 이득을 못 줌
TabM	딥 테이블러	0.781	
RealMLP	딥 테이블러	0.778	
원시 IQ 딥러닝(재현)	트랜스포머(MoE)	0.681	특징 미사용, 128샘플 원시 IQ 입력
TabR	딥 테이블러(검색 기반)	미측정	학습 데드락으로 스킵
무작위 추측	-	0.091	11-way 기준선

이 소규모 체제에서 가장 눈에 띄는 것은 순위의 응집이다. 그래디언트 부스팅 세 종(LightGBM, XGBoost, CatBoost)과 사전학습 파운데이션 모델 TabPFN v2가 0.840에서 0.855 사이에 몰려 있고, 그 다음으로 랜덤포레스트가 바로 뒤를 잇는다.




그림 1: 모델별 정확도

여러 모델을 쌓아 올리는 AutoGluon의 스택킹 앙상블은 오히려 단일 LightGBM보다 3.7퍼센트포인트 낮았는데, 이는 개별 모델 하나하나의 편차를 평균화해 얻는 이득이 이 특징셋과 이 데이터 규모에서는 크지 않다는 뜻으로 읽을 수 있다. 딥 테이블러 아키텍처(TabM, RealMLP)는 같은 28개 특징을 받았음에도 트리 앙상블에 6에서 8퍼센트 포인트 뒤졌다. 이는 중요한 신호다. 테이블러 신경망이 트리 계열보다 못한 이유가 “특징이 없어서”가 아니라 “데이터가 적어서”라는 뜻이기 때문이다. 마지막으로, 특징 엔지니어링 없이 원시 신호에서 직접 배우는 딥러닝은 0.681로 최하위였고, 최고 성적인 LightGBM과 17.4 퍼센트포인트 차이가 났다.

5.2 표 2 - 데이터 규모별 GBM과 원시 IQ 딥러닝의 격차

학습 표본 N	LightGBM	XGBoost	원시 IQ 딥러닝	GBM 우위 (퍼센트포인트)
539	0.728	0.719	0.368	36.0
2,000	0.794	0.780	0.581	21.3
5,000	0.814	0.817	미완(작업 실패)	-
9,900	0.844	0.831	미완(작업 실패)	-




그림 2: GBM 우위

확보한 두 지점만 보면 추세는 뚜렷하다. 학습 표본을 539개에서 2,000개로 약 3.7배 늘리자 원시 IQ 딥러닝의 정확도는 0.368에서 0.581로 21.3퍼센트포인트 뛰었다. 같은 구간에서 LightGBM은 0.728에서 0.794로 6.6퍼센트포인트만 올랐다. 결과적으로 GBM의 우위는 36.0퍼센트포인트에서 21.3퍼센트포인트로 거의 절반 가까이 줄었다. 딥러닝의 학습 곡선이 GBM 보다 훨씬 가파르다는 것은 이 두 지점만으로도 분명하다.

세부 지표를 보면 이 격차 축소가 클래스마다 균일하지 않다는 것도 드러난다. 원시 IQ 딥러닝의 클래스별 재현율에서, AM-SSB는 0.51에서 0.87로, BPSK는 0.25에서 0.79로 크게 뛰었다. 반면 QAM16은 0.14에서 0.24로, QAM64는 0.17에서 0.30으로 여전히 낮은 수준에 머물렀다. 고차 성상도를 갖는 변조일수록 미세한 성상점 간 거리를 구분해야 하므로 더 많은 데이터가 필요하다는 것이 합리적인 설명이다. 부가적으로 살펴본 2진 판별(실수 대 원형 성상도) 정확도는 0.714에서 0.905로, 3진 차수 판별(BPSK/QPSK/8PSK)은 0.19에서 0.47로 개선됐는데, 특히 3진 판별은 여전히 같은 데이터에서 고전적 신호처리 방식(사이클로스테이셔너리 특징, 충분한 적분 구간을 쓰는 조건에서 약 0.8)에 크게 못 미쳤다.

6 한계: 교차점은 대규모에서 재검토해야 한다

이 논문의 결론을 정직하게 좀더 말하면 다음과 같다. 학습 표본이 수백에서 수천 개 수준인 저데이터 체제에서, 28차원의 물리 특징 위에서는 그래디언트 부스팅이 실용적인 승자다. 그러나 “딥러닝은 데이터가 늘어나도 결코 GBM을 넘지 못한다”는 훨씬 더 강한 주장은 이 실험이 지지하지 않는다. 이유는 세 가지다.

첫째, 관찰된 격차 축소 추세(36.0에서 21.3퍼센트포인트)는 딱 두 개의 표본점에서 나온 것이다. 이 두 점을 잇는 직선을 5,000 개나 9,900개까지 그냥 연장하는 것은 통계적으로 정당화되지 않는다. 실제로 그 두 지점에서 딥러닝 재측정을 시도했지만 작업이 완료되지 못했고, 이 공백을 채우기 전까지는 교차점이 이 데이터셋의 범위(9,900개 이하) 안에 있는지조차 확인할 수 없다.

둘째, 이 비교는 순수하게 “아키텍처 대 아키텍처”의 비교가 아니다. GBM 계열은 사람이 미리 설계한 28개의 물리 특징이라는 정보 우위를 안고 시작하고, 원시 IQ 딥러닝은 그 특징 추출 작업 자체를 데이터로부터 배워야 한다. 이 논문에서 같은 28 개 특징을 받은 딥 테이블러 모델(TabM, RealMLP)도 GBM에 6에서 8퍼센트포인트 뒤졌다는 사실은, 격차의 상당 부분이 “신경망이라서 나쁘다”가 아니라 “이 정도 데이터로는 신경망 계열 전체가 아직 데이터를 다 못 썼다”는 쪽에 가깝다는 것을 시사한다. 딥러닝에 같은 물리 특징과 훨씬 많은 데이터를 동시에 주는 조건은 이 실험에서 다루지 않았다.

셋째, 이 실험은 하나의 SNR(6dB), 하나의 공개 시뮬레이션 데이터셋에 한정된다. 실제 무선 환경의 채널 왜곡, 하드웨어 개체 차이, 다중 SNR 혼합 조건에서 두 접근법의 순위가 유지되는지는 별도로 검증해야 한다. 원시 IQ 딥러닝이 재현한 방법론이 원 논문에서 보고한 수치(전체 RadioML, 다중 SNR 평균)와 이 실험의 수치를 직접 비교하는 것도 부적절하다. 원 논문은 클래스당 수천 개 수준의 훨씬 큰 학습 데이터를 쓰고, 이 실험은 클래스당 49개에서 시작하는 훨씬 작은 데이터 체제를 의도적으로 다루기 때문이다.

따라서 이 논문이 실제로 뒷받침하는 문장은 다음과 같다. 물리 특징을 뽑을 수 있는 신호 분류 과제에서, 학습 데이터가 수천 개 이하로 제한된다면 테이블러 부스팅을 기본 선택으로 삼는 것이 합리적이다. 그 우위가 데이터 규모가 아주 커져도 유지되는지는 별도의 실험으로 검증해야 하는 열린 질문이며, 지금까지의 추세는 격차가 좁혀지는 방향을 가리키고 있다.

7 재현

이 실험은 전적으로 공개 자산 위에서 구성할 수 있다. 데이터셋은 RadioML2016.10a (O’Shea & West, 2016)의 6dB SNR 부분집합이며, 128샘플 길이의 IQ 관측창과 클래스 라벨로 구성된다. 28차원 물리 특징은 표준적인 신호처리 연산의 조합이다. IQ 불균형·DC 오프셋 추정, 순시 진폭·위상·주파수의 통계 모멘트, Swami-Sadler 방식 2·4·6차 큐물런트, 대역 전력·스펙트럴 모멘트·반송파주파수오프셋·최대전력대평균전력비다. 이 특징들은 신호처리 교재에 공개된 정의를 그대로 구현하면 재현할 수 있다.

테이블러 모델은 모두 오픈소스로 공개돼 있다. LightGBM, XGBoost, CatBoost, scikit-learn의 랜덤포레스트, pytabkit의 RealMLP·TabM·TabR, TabPFN v2, AutoGluon-Tabular다. 모두 기본 하이퍼파라미터로 학습했고 별도의 튜닝을 하지 않았는데, 이는 실무에서 가장 흔한 시작점을 반영하려는 의도다. 튜닝을 더 깊게 하면 순위가 달라질 가능성은 열려 있다.

원시 IQ 딥러닝 대조군은 최근 발표된 믹스처-오브-엑스퍼트 트랜스포머 방식의 변조분류 논문(arXiv:2606.09085)의 서술을 따라 독자적으로 재현한 것으로, 공식 코드를 참고하지 않았고 원 논문의 보고 수치를 재현하려는 목적도 아니었다는 점을 다시 밝혀 둔다. 구조는 합성곱 패치 임베딩, 4개 층의 트랜스포머 인코더(모델 차원 128, 헤드 4개), 각 층의 피드포워드를 대체하는 4개 전문가·상위-2 라우팅의 믹스처-오브-엑스퍼트로 구성되며, 총 파라미터 수는 약 139만 개다. 학습은 Adam 계열 옵티마이저, 학습률 0.001, 드롭아웃 0.15, 레이블 스무딩 0.05, 가중치 감쇠 0.01, 600에폭으로 진행했다. 같은 하이퍼파라미터로 서로 다른 학습 표본 수(539, 2,000)에 적용한 것이 표 2의 스위치다.

데이터 규모 스위치에서 각 N에 대한 학습 표본은 전체 학습 풀에서 클래스별로 거의 균등하게 무작위 계층 추출했고, 검증 세트 1,100개는 모든 N에서 고정해 서로 다른 N 사이의 비교 가능성을 유지했다. 이 설계 전체를 재현하는 데 필요한 것은 공개 데이터셋 하나, 표준 신호처리 특징 추출 코드, 그리고 위에 나열한 오픈소스 라이브러리들뿐이며, 특수한 하드웨어는 그래디언트 부스팅 학습에는 필요하지 않다. 딥러닝 대조군만 GPU 한 장이 있으면 충분하다.

8 참고문헌

1. T. O’Shea, N. West, “Radio Machine Learning Dataset Generation with GNU Radio,” Proceedings of the GNU Radio Conference (GRCon), 2016. (RadioML2016.10a)

2. G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," Advances in Neural Information Processing Systems (NeurIPS), 2017.
3. T. Chen, C. Guestrin, "XGBoost: A Scalable Tree Boosting System," Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016.
4. L. Prokhorenkova et al., "CatBoost: Unbiased Boosting with Categorical Features," Advances in Neural Information Processing Systems (NeurIPS), 2018.
5. N. Hollmann et al., "Accurate Predictions on Small Data with a Tabular Foundation Model," Nature, 2025. (TabPFN v2)
6. D. Holzmüller et al., "Better by Default: Strong Pre-Tuned MLPs and Boosted Trees on Tabular Data," Advances in Neural Information Processing Systems (NeurIPS), 2024. (RealMLP)
7. N. Erickson et al., "AutoGluon-Tabular: Robust and Accurate AutoML for Structured Data," arXiv:2003.06505, 2020.
8. arXiv:2606.09085, 믹스처-오브-엑스퍼트 트랜스포머 기반 변조분류 방법론 서술 (공식 코드 미참조 재현).
9. A. Swami, B. Sadler, "Hierarchical Digital Modulation Classification Using Cumulants," IEEE Transactions on Communications, 2000. (고차 큐물런트 특징의 이론적 근거)