

WiFi-CSI 환경 이동과 소량 보정

환경/세션이 바뀌면 왜 무너지고 몇 샷으로 얼마나 회복되나, 실측

2i

2026-07-29

초록

WiFi 신호의 채널상태정보(CSI)로 사람의 활동을 인식하는 기술은 공유기 하나로 별도 센서 없이 재실, 낙상, 동작을 감지할 수 있다는 점에서 매력적이다. 그런데 이 기술의 배치 현장에서 가장 자주 나오는 질문은 '정확도가 몇 퍼센트냐'가 아니라 '설치한 방을 나가면 그 정확도가 얼마나 무너지느냐'다. CSI 진폭은 수신기의 자동이득제어, 안테나 배치, 벽과 가구가 만드는 다중경로 반사에 강하게 좌우되기 때문에, 학습에 쓴 환경과 다른 환경에서는 성능이 크게 떨어진다는 것이 이 분야의 오래된 통념이다. 이 논문은 그 통념을 실측으로 확인하고, 실측이 만만치 않게 까다로운 이유와 함께, 소량의 목표 도메인 라벨을 더하는 것으로 그 손실을 얼마나 되찾을 수 있는지를 정직하게 보고한다.

목차

1	요약	3
2	문제: CSI는 환경이 바뀌면 왜 무너지는가	3
3	방법: 도메인 분할과 zero-shot 대 few-shot 보정	3
4	데이터·설정: 실제로 가능했던 분할은 무엇이었나	4
5	결과	5
6	한계	6
7	재현	7
8	참고문헌	7

1 요약

WiFi 신호의 채널상태정보(CSI)로 사람의 활동을 인식하는 기술은 공유기 하나로 별도 센서 없이 재실, 낙상, 동작을 감지할 수 있다는 점에서 매력적이다. 그런데 이 기술의 배치 현장에서 가장 자주 나오는 질문은 “정확도가 몇 퍼센트냐”가 아니라 “설치한 방을 나가면 그 정확도가 얼마나 무너지느냐”다. CSI 진폭은 수신기의 자동이득제어, 안테나 배치, 벽과 가구가 만드는 다중경로 반사에 강하게 좌우되기 때문에, 학습에 쓴 환경과 다른 환경에서는 성능이 크게 떨어진다는 것이 이 분야의 오래된 통념이다. 이 논문은 그 통념을 실측으로 확인하고, 실측이 만만치 않게 까다로운 이유와 함께, 소량의 목표 도메인 라벨을 더하는 것으로 그 손실을 얼마나 되찾을 수 있는지를 정직하게 보고한다.

실험은 공개 데이터셋 UT-HAR(SenseFi 재배포본, 7종 활동, 250스텝×90채널 CSI 진폭 창)에 고전적 특징 추출(핸드크래프트 158차원)과 LightGBM을 적용한 7-way 활동 분류 파이프라인 위에서 진행했다. 처음 시도한 도메인 분할 측은 이 재배포본이 유일하게 제공하는 그룹 변수, 즉 공식 train/val/test 경계였다. 그러나 실측 결과 이 경계는 실질적인 도메인 이동을 전혀 보이지 않았다(zero-shot 정확도 94.7~94.9%, in-split 기준치 95.2%와 오차범위 안에서 일치). 이는 SenseFi 논문 자신이 밝힌 캐비어트, 즉 슬라이딩 윈도우 중첩이 표본 사이에 누출을 일으킨다는 사실과 정확히 부합하는 결과다. 공개된 메타데이터로는 방·피험자·날짜 측의 진짜 도메인 이동을 구성할 수 없었으므로, 채널별 평균 진폭(수신 이득·다중경로의 물리적 지표) 위에서 비지도 클러스터링으로 우리가 직접 도메인 이동 측을 구성했다. 이 구성된 분할(“pseudo-session”)에서는 이야기가 완전히 달라진다. 소스 도메인(3624개 창)에서 학습한 분류기를 목표 도메인(1349개 창)에 그대로 적용하면 정확도가 55.08%로 무너진다. 같은 목표 도메인 데이터만으로 학습했을 때의 상한은 92.37%이므로, 도메인 이동이 만든 격차는 37.29퍼센트포인트다. 이 격차에 클래스당 1, 5, 10, 20, 50개의 목표 도메인 라벨을 소스 학습셋에 추가하는 소량 보정을 적용하면 정확도는 각각 57.16%, 64.55%, 70.62%, 78.23%, 84.92%로 올라가고, 격차 회복률은 5.6%, 25.4%, 41.7%, 62.1%, 80.0%다. 클래스당 50개, 총 350개의 목표 도메인 라벨(소스 학습셋 규모의 9.7%에 불과)을 추가하는 것만으로 격차의 80%를 되찾는다는 것이 이 실험의 핵심 수치다.

2 문제: CSI는 환경이 바뀌면 왜 무너지는가

WiFi CSI 기반 사람 감지·활동 인식은 지난 10년간 학계에서 꾸준히 다뤄진 주제다. 별도 카메라나 웨어러블 없이, 이미 집에 있는 공유기의 물리계층 신호만으로 재실 여부와 동작을 읽어낼 수 있다는 점이 매력이다. 문제는 CSI 진폭이 활동 자체가 아니라 활동이 일어나는 물리적 환경에도 강하게 반응한다는 데 있다. 같은 사람이 같은 동작을 하더라도 수신기의 자동이득제어(AGC) 설정, 안테나와 신체 사이의 거리, 방의 크기와 가구 배치가 만드는 다중경로 반사 패턴이 다르면 CSI 진폭의 절대 스케일과 상대적 변동 구조가 통째로 바뀐다. 그래서 한 환경에서 학습한 분류기를 다른 환경에 그대로 옮기면 성능이 크게 떨어진다는 것이 이 분야에서 반복적으로 보고되는 현상이고, 실제 배치를 가로막는 핵심 난점으로 지목된다. Widar3.0(Zheng 외, 2019)을 비롯한 여러 연구가 “환경 독립적” 특징을 설계하려 시도한 이유도 여기에 있다.

이 논문이 답하려는 질문은 두 가지다. 첫째, 이 흔히 인용되는 “환경이 바뀌면 무너진다”는 현상을 우리가 가진 실험 하니스 위에서 실측으로 확인할 수 있는가. 둘째, 확인된다면 목표 도메인의 라벨을 소량만 확보해서 학습셋에 더하는 것, 즉 배치 현장에서 짧은 캘리브레이션 구간을 두는 것으로 그 손실을 얼마나 회복할 수 있는가. 두 번째 질문이 실무적으로 더 중요하다. 방을 새로 도입할 때 카메라 기반 시스템처럼 대규모 라벨링을 다시 하는 것은 비현실적이지만, 설치 기사가 몇 분 동안 정해진 동작을 몇 번씩 반복하며 라벨을 붙이는 것은 현실적인 운영 절차이기 때문이다. “몇 번이면 되느냐”에 대한 실측 답이 이 논문의 목표다.

3 방법: 도메인 분할과 zero-shot 대 few-shot 보정

실험 설계의 뼈대는 소스 도메인에서 학습한 분류기를 목표 도메인에서 세 가지 조건으로 평가하는 것이다. 첫째는 zero-shot으로, 목표 도메인 라벨을 전혀 쓰지 않고 소스에서 학습한 모델을 목표 도메인에 그대로 적용한다. 둘째는 few-shot 보정으로, 목표 도메인의 계산·평가 용도로 나눠 둔 표본 중 클래스당 N개(N은 1, 5, 10, 20, 50)만 뽑아 소스 학습셋에 더하고 다시 학습한다. 셋째는 상한(upper bound)으로, 목표 도메인 데이터만으로(소스를 전혀 쓰지 않고) 학습해 “목표 도메인 데이터를 이 실험이 손에 쥐여주는 만큼 전부 쓴다면 어디까지 갈 수 있는가”를 잴다.

측정의 공정성을 지키기 위해 목표 도메인을 매 반복(전체 12회 반복, 계층적 무작위 재추출)마다 70%의 보정 풀(pool)과 30%의 평가 폴드(eval fold)로 나눈다. 평가 폴드는 어떤 조건에서도 학습에 쓰지 않는다. zero-shot, few-shot, 상한 세 조건 모두 같은 평가 폴드로 채점하므로 세 수치는 서로 정확히 비교 가능하다. few-shot 보정에서 N개를 뽑는 대상은 항상 보정 풀이며,

클래스별로 보정 풀에 남은 표본이 N보다 적으면 있는 만큼만 뽑고 실제로 뽑힌 개수를 정직하게 기록한다(뒤에서 보듯 이 캡은 공식 분할 실험에서만 발생했고, 이 논문의 핵심 실험인 구성 분할에서는 발생하지 않았다). 특징 스케일러(StandardScaler)는 언제나 그 실험의 소스 쪽에서만 적합(fit)하고 목표 도메인에는 변환만 적용한다. 목표 도메인 통계로 정규화를 다시 하는 것은 이미 그 자체로 일종의 도메인 적응이므로, 그런 개입 없이 “라벨을 몇 개 더하는 것만으로” 회복되는 몫을 순수하게 재는 것이 이 실험의 취지다.

분류기는 classical_wifi_csi_sensing 파이프라인에서 그대로 가져온 158차원 고전적 CSI 특징(부반송파별 진폭 평균·분산·왜도·첨도, 안테나 간 진폭차 분산, 윈도우 내 주성분의 STFT 대역 에너지, 힐베르트 엔벨로프, 자기상관, 스펙트럼·히스토그램 엔트로피 등)과 LightGBM 다중클래스 분류기를 재사용했다. 이 논문이 검증하려는 것은 새로운 특징이나 모델이 아니라 같은 파이프라인이 도메인이 바뀌었을 때 어떻게 반응하는지, 그리고 그 반응을 소량의 라벨로 얼마나 고칠 수 있는지에므로, 특징 추출을 재구현하지 않고 그대로 재사용하는 쪽을 택했다. 반복마다 새로 학습하는 조건(few-shot, 상한)의 트리 수는 150, 리프 수는 15로, 원래 활동 분류 실험(트리 300·리프 31)보다 가볍게 잡았다. 반복 횟수(전체 12회 × 도메인 3개 × 조건 6가지)가 많아 실행 시간이 늘어나기 때문이며, 이 축소가 정확도에 실질적인 영향을 주지 않는다는 것은 사전 점검에서 확인했다.

4 데이터·설정: 실제로 가능했던 분할은 무엇이었나

이 절은 이 논문에서 가장 정직해야 하는 부분이다. UT-HAR는 Yousefi 외(2017)가 Intel 5300 무선랜 카드(안테나 3개 × 부반송파 30개 = 채널 90개)로 수집한 공개 CSI 활동 데이터셋이고, 이 실험은 SenseFi 벤치마크(Yang 외, 2023)가 재배포한 train(3977개)/val(496개)/test(500개) 분할을 그대로 받아 썼다. 문제는 이 재배포본이 방 번호, 피험자 ID, 녹화 날짜·시각 같은 메타데이터를 전혀 공개하지 않는다는 데 있다. 즉 “이 창은 몇 번 방에서, 누가, 언제 녹화했다”는 정보가 파일 어디에도 없다. 이런 상태에서 검증된 cross-room 분할이나 cross-subject 분할, cross-day 분할을 만드는 것은 원천적으로 불가능하고, 이 논문은 그런 분할을 만들었다고 주장하지 않는다.

가장 먼저 시도한 것은 그래도 데이터에 존재하는 유일한 그룹 변수, 즉 공식 train/val/test 경계를 도메인 이동의 대리 지표로 쓰는 것이었다. train에서 학습한 분류기를 val과 test에 각각 zero-shot으로 적용했다. 결과는 예상을 완전히 벗어났다. val에서 94.91%, test에서 94.67%의 정확도가 나왔고, 이는 같은 파이프라인의 원래 in-split 7-way 정확도인 95.2%와 표준편차 범위 안에서 거의 같은 값이다. 다시 말해 공식 분할 경계를 넘어가도 정확도가 거의 떨어지지 않았다. 이 결과 자체가 대단히 중요한 정보다. SenseFi 논문은 “슬라이딩 윈도우로 세그먼트를 만들다 보니 표본 사이에 반복되는 데이터가 불가피하게 생긴다”고 스스로 밝히고 있는데, 이 실험의 zero-shot 결과가 정확히 그 캐비어를 실측으로 재확인한다. 공식 분할의 val·test는 train과 물리적으로 다른 조건에서 수집됐다고 믿을 근거가 없고, 오히려 창이 겹치는 같은 녹화 구간에서 갈라져 나온 것처럼 행동한다. 이 상태에서 few-shot 보정 곡선을 그리는 것은 의미가 없다. 회복할 격차 자체가 없기 때문이다(회복률 수치가 -6%에서 +2% 사이에서 그냥 노이즈처럼 움직이는 것을 4절에서 확인할 수 있다). 흥미롭게도 목표 도메인 데이터만으로 학습한 “상한” 조건은 zero-shot보다 오히려 낮게 나왔는데(val 76.73%, test 75.89%), 이는 도메인이 실제로 다르기 때문이 아니라 단순히 학습 표본이 350개 안팎으로 훨씬 적어서 생기는 표본 크기 효과다. 이 수치를 “few-shot 보정이 성능을 깎는다”는 의미로 읽으면 안 된다는 점을 분명히 해 둔다.

공개된 메타데이터로 실제 도메인 이동을 잡을 수 없다는 것이 확인된 이상, 남은 선택은 두 가지였다. 도메인 이동 실험을 포기하고 부정적 결과만 보고하거나, 정직하게 표시한 대리 축을 우리가 직접 구성하는 것이다. 이 논문은 후자를 택했다. train·val·test를 모두 합쳐 4973개 창을 만든 뒤, 각 창의 채널별 평균 진폭(90차원, 분류에 쓴 158차원 특징과는 별도로 원시 데이터에서 바로 계산한 값)에 k-평균 군집화(k=2)를 적용했다. 채널별 평균 진폭은 CSI 문헌에서 수신 이득·다중경로의 물리적 지표로 통상 다루지는 값이므로, 이 값이 크게 다른 두 창 집단은 서로 다른 물리적 수신 조건(수신기 자동이득, 안테나-신체 거리, 방의 다중경로 구조 등)에서 나왔을 가능성이 높다는 것이 이 구성의 논리다. 군집화 결과 큰 군집은 3624개, 작은 군집은 1349개였고 두 군집 모두 7개 활동 클래스를 전부 포함했다(작은 군집 기준 클래스별 개수는 앞기/서기 계열 최소 90개에서 pickup 447개까지 분포). 큰 군집을 소스, 작은 군집을 목표 도메인으로 지정했다.

이 구성 방식의 한계를 숨기지 않고 명시한다. 이것은 검증된 방·피험자·날짜 라벨이 아니라 비지도 군집화로 유도한(inferred) 그룹이다. 두 군집이 실제로 갈리는 원인이 방인지, 피험자인지, 촬영 시점인지, 혹은 이들의 조합인지는 이 데이터로는 구분할 수 없다. 또한 채널별 평균 진폭은 분류에 쓰는 158차원 특징 중 몇몇 집계 통계(채널 평균의 평균·표준편차 등)와 완전히 무관하지 않다. 그럼에도 이 구성이 임의로 격차를 만들어낸 것이 아니라는 근거는 뒤에서 보이는 결과의 형태 자체에 있다. zero-shot 정확도가 크게 떨어지고, 목표 도메인 데이터를 조금씩 늘릴수록 정확도가 매끄럽게, 단조적으로 올라가는 곡선은 무작위 잡음으로는 나오기 어려운 패턴이고, 실제로 두 집단 사이에 분류기가 학습해야 할 무언가가 바뀌었다는 신호로 읽는 것이 합리적이다. 이 논문은 이 대리 축을 “cross-room”이나 “cross-subject”라고 부르지 않고 처음부터 끝까지 “pseudo-session(구성된 유사-환경 이동)”이라고만 부른다.

5 결과

아래 표는 12회 반복(무작위 시드 고정, 계층적 재추출)의 평균과 표준편차다. “회복률”은 (few-shot 정확도 - zero-shot 정확도) ÷ (상한 정확도 - zero-shot 정확도) × 100으로, zero-shot과 상한 사이의 격차 중 few-shot 보정이 되찾은 비율을 뜻한다.

조건	pseudo-session (구성 도메인 이동)	공식분할 test (대조군)
zero-shot 정확도	55.08% (±1.82%p)	94.67% (±1.72%p)
N=1 정확도 / 회복률	57.16% / 5.6%	94.56% / 0.6%
N=5 정확도 / 회복률	64.55% / 25.4%	94.67% / -0.0%
N=10 정확도 / 회복률	70.62% / 41.7%	95.17% / -2.7%
N=20 정확도 / 회복률	78.23% / 62.1%	95.06% / -2.1%
N=50 정확도 / 회복률	84.92% / 80.0%	95.50% / -4.4%
상한(목표 도메인만 학습)	92.37% (±1.48%p)	75.89% (±2.61%p)
zero-shot ↔ 상한 격차	37.29%p	-18.78%p (표본크기 효과)




그림 1: 환경 이동

곡선은 매끄럽게 단조 증가한다. 클래스당 1개만 더해도 2.08퍼센트포인트가 오르고, 5개에서 9.47포인트, 10개에서 15.54포인트, 20개에서 23.15포인트, 50개에서 29.84포인트가 오른다. 격차의 절반(18.65포인트)을 넘어서는 지점은 클래스당 10개와 20개 사이, 대략 14개 안팎이다. 클래스당 50개, 총 350개의 목표 도메인 라벨(소수 학습셋 3624개의 9.7%에 해당하는 양)을 추가하는 것만으로 전체 격차의 80%를 되찾고, 정확도는 84.92%까지 오른다. 남은 20%의 격차(7.45포인트)는 이 실험이 시도한 최대 샷 수 안에서는 닫히지 않았다. macro-F1로 보면 그림이 조금 더 뚜렷하다. zero-shot macro-F1은 43.68%로 accuracy보다 훨씬 낮는데, 이는 개수가 적은 소수 클래스(작은 군집에서 90~106개 수준)가 zero-shot 상태에서 특히 취약하다는 뜻이다. N=50에서 macro-F1은 82.19%까지 올라 accuracy(84.92%)와 격차가 크게 줄어드는데, 이는 소량 보정이 다수 클래스만이 아니라 소수 클래스의 인식률도 함께 끌어올린다는 신호로 읽을 수 있다.

대조군인 공식분할 test는 전혀 다른 그림을 보인다. zero-shot 정확도(94.67%)가 이미 in-split 기준치에 근접해 있어서, 클래스당 몇 개를 더 넣어도 회복률은 -4.4%에서 +0.6% 사이를 오갈 뿐 뚜렷한 방향성이 없다. 이는 few-shot 보정이 “효과가 없다”는 뜻이 아니라 “되찾을 격차 자체가 처음부터 거의 없었다”는 뜻이다. 3절에서 설명한 대로 상한 조건의 정확도(75.89%)가 zero-shot보다 낮게 나온 것도 도메인 이동 때문이 아니라 학습 표본이 350개 안팎으로 급격히 줄어든 표본크기 효과다. 이 대조군을 pseudo-session 결과와 나란히 두는 이유는 “같은 파이프라인, 같은 모델, 같은 반복 절차인데도 분할 방식에 따라 결과가 이렇게 달라진다”는 것을 보여주기 위해서다. 도메인 이동이라는 현상을 재는 실험 설계 자체가 얼마나 분할 선택에 민감한지를 이보다 명확하게 보여주는 방법은 찾기 어려웠다.

세 번째 차트는 이 논문의 방법론적 핵심을 한 장으로 압축한다. 공식분할은 zero-shot과 상한이 거의 같은 높이(오히려 상한이 표본크기 효과로 더 낮다)여서 도메인 이동을 쥔 수 없는 분할이라는 것이 시각적으로도 분명하다. 구성분할은 zero-shot이




그림 2: 샷당 격차 회복률




그림 3: 분할 방식 비교: zero-shot과 상한

뚝 떨어지고 상한이 그보다 훨씬 높은, 실제로 켈 것이 있는 분할이다. 이 차이가 왜 이 논문이 원래 계획했던 분할을 버리고 새 분할을 만들어야 했는지에 대한 가장 직접적인 답이다.

6 한계

이 실험이 보고하는 도메인 이동은 검증된 cross-room, cross-subject, cross-day 분할이 아니다. UT-HAR의 SenseFi 재배포본에는 방·피험자·시각 메타데이터가 전혀 없고, 이 논문은 그 부재를 감추지 않았다. pseudo-session 분할은 채널별 평균 진폭에 대한 비지도 군집화로 유도한 것이며, 두 군집이 실제로 어떤 물리적 차이를 반영하는지(방인지 피험자인지 장비 재부팅으로 인한 AGC 재설정인지)는 이 데이터만으로 확정할 수 없다. 결과의 패턴 (매끄러운 단조 회복 곡선)은 이 군집화가 무의미한 잡음이 아니라 실제 구조를 잡아냈다는 정황 증거이지 증명은 아니다.

둘째, 클러스터링에 쓴 채널별 평균 진폭은 분류에 쓰는 158차원 특징 중 몇몇 채널 집계 통계와 완전히 독립이 아니다. 이 때문에 관측된 격차의 일부가 “환경이 달라져서”가 아니라 “군집화 기준과 분류 특징이 부분적으로 겹쳐서 생긴 인위적 분리”일 가능성을 완전히 배제할 수는 없다. 다만 두 군집 모두 7개 활동 클래스를 온전히 포함하고 있고 클래스 불균형만으로는 55% 까지 떨어지는 zero-shot 정확도를 설명하기 어렵다는 점에서, 이 우려가 전체 결과를 무효화할 정도는 아니라고 판단한다.

셋째, 이 실험은 단 하나의 공개 데이터셋, 단 하나의 분류 파이프라인(고전적 특징 + LightGBM), 단 하나의 군집화 방법($k=2$ k-평균)에서 나온 결과다. 데이터셋을 바꾸거나 군집 개수를 늘리거나 딥러닝 기반 도메인 적응 기법을 적용하면 회복 곡선의 모양이나 필요한 샷 수는 달라질 수 있다. 이 논문은 “몇 샷이면 충분인가”에 대한 보편적 상수를 제시하는 것이 아니라, 이 특정 파이프라인·이 특정 데이터에서 실측한 하나의 사례를 보고하는 것이다.

넷째, 소수 클래스(작은 군집에서 90~106개)의 표본 수가 적어 개별 반복의 분산이 크다. 12회 반복 평균으로 이를 완화했지만, 클래스별 회복 속도의 차이까지는 이 논문에서 별도로 분해하지 않았다.

다섯째, “상한”은 목표 도메인 데이터만으로 학습했을 때의 성능일 뿐 진짜 이론적 상한이 아니다. 목표 도메인 데이터를 더 많이 모으거나 소스와 목표를 함께 쓰는 더 정교한 도메인 적응 기법(특징 정합, 적대적 학습 등)을 쓰면 이 상한 자체가 더 올라갈 수 있다.

7 재현

데이터는 UT-HAR(Yousefi 외, 2017)를 SenseFi 벤치마크(Yang 외, 2023)가 재배포한 train/val/test 세 개의 numpy 배열(각각 $X_{\{split\}}$.csv, $y_{\{split\}}$.csv, 실제로는 numpy 바이너리)로 받는다. 창 크기는 250스텝 × 90채널(안테나 3 × 부반송파 30)이고 7개 활동 클래스(bed/fall/pickup/run/sitdown/standup/walk, 알파벳 순서 관행)로 라벨링돼 있다.

특징 추출은 원래의 고전적 CSI 활동 분류 스크립트에 있는 158차원 핸드크래프트 특징 함수를 그대로 재사용한다(부반송파별 평균·분산·왜도·첨도, 전체 채널 집계 통계, 안테나 간 진폭차 분산, 주성분 STFT 대역 에너지, 힐베르트 엔벨로프, 단시간 에너지 피크성, 자기상관, 스펙트럼·히스토그램 엔트로피, 전역 에너지 지표). 창 단위로 독립적으로 계산되므로 어떤 분할에서도 표본 간 정보 누출이 없다.

공식분할 실험은 train 전체(3977개)에서 학습한 LightGBM 다중클래스 분류기(트리 150개, 리프 15개, 학습률 0.09)를 val(496개)과 test(500개)에 각각 적용한다. 구성분할 실험은 train·val·test를 합친 4973개 창에서 각 창의 채널별 평균 진폭(90차원)에 표준화를 적용한 뒤 k-평균($k=2$, 시드 0, $n_{\text{init}}=10$)으로 군집화하고, 큰 군집(3624개)을 소스, 작은 군집(1349개)을 목표로 지정한다. 두 실험 모두 목표 도메인을 매 반복(12회, 시드 1000부터 1011까지)마다 70% 보정 폴과 30% 평가 폴드로 계층적으로 나누고, zero-shot·few-shot(클래스당 1/5/10/20/50개)·상한 세 조건을 같은 평가 폴드로 채점한다. 특징 스케일링은 각 실험의 소스 데이터에서만 적합한다.

전체 파이프라인은 Python(numpy/scipy/scikit-learn/LightGBM), CPU 전용으로 동작하며 외부 GPU나 클라우드 자원이 필요하지 않다. 실행 시간은 특징 추출을 포함해 약 5분(12회 반복 × 3개 도메인 기준)이다.

8 참고문헌

1. S. Yousefi, H. Narui, S. Dayal, S. Ermon, S. Valaee, "A Survey on Behavior Recognition Using WiFi Channel State Information," IEEE Communications Magazine, vol. 55, no. 10, 2017 (UT-HAR 데이터셋 원 수집).
2. J. Yang, X. Chen, D. Wang, H. Zou, C. X. Lu, S. Sun, L. Xie, "SenseFi: A Library and Benchmark on Deep-Learning-Empowered WiFi Human Sensing," Patterns (Cell Press), vol. 4, no. 3, 2023 (본 실험이 쓴 재배포 분할의 출처).
3. Y. Zheng, Y. Zhang, K. Qian, G. Zhang, Y. Liu, C. Wu, Z. Yang, "Zero-Effort Cross-Domain Gesture Recognition with Wi-Fi," Proceedings of ACM MobiSys, 2019 (WiFi 센싱의 환경 간 일반화 문제를 다룬 대표 연구).
4. G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," Advances in Neural Information Processing Systems (NeurIPS), 2017.
5. F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," Journal of Machine Learning Research, vol. 12, 2011 (StandardScaler, KMeans, train_test_split 등 전처리·군집화·분할에 사용).